

UNIVERSIDAD PRIVADA ANTENOR ORREGO
FACULTAD DE INGENIERÍA
PROGRAMA DE ESTUDIO DE INGENIERÍA DE COMPUTACIÓN Y SISTEMAS



TESIS PARA OPTAR EL TÍTULO PROFESIONAL DE
INGENIERO DE COMPUTACIÓN Y SISTEMAS

Concordancia de un sistema GraphRAG con evaluación experta en detección de
inconsistencias en citas bibliográficas de tesis, UPAO 2024-2025

Línea de Investigación:

Robótica, automatización avanzada y sistemas inteligentes.

Sub Línea de Investigación: Sistemas Inteligentes

Autor: Alcalde Lavado Matias Felipe

Jurado evaluador:

Apellidos, Nombres

Presidente:

Apellidos, Nombres

Secretario:

Vocal:

Asesor:

Cueva Chavez, Walter

Código Orcid: <https://orcid.org/0000-0001-9660-6354>

TRUJILLO - PERÚ

2026

Fecha de sustentación:

MARCAR MODALIDAD: ☒ P ☐ SP ☐ D

Dedicatoria

A Dios, por ser la guía y fortaleza en cada etapa de mi vida y de mi formación profesional.

A mis padres y hermanos, por su amor incondicional, su sacrificio y su apoyo constante, que hicieron posible alcanzar esta meta.

Alcalde Lavado Matias Felipe

Agradecimiento

Expreso mi más sincero reconocimiento al asesor Walter Cueva Chávez, por su valiosa orientación metodológica, su rigor académico y su permanente disposición para absolver dudas y encaminar este trabajo hacia los más altos estándares de calidad investigativa. Su guía fue determinante para la consolidación de esta tesis.

A mis amigos, por su apoyo incondicional, sus palabras de aliento en los momentos de mayor exigencia y por haber sido una fuente constante de motivación a lo largo de esta etapa universitaria. Su compañía hizo más llevadera cada etapa de este proceso.

A la Universidad Privada Antenor Orrego, por brindarme una formación académica sólida, por los valores institucionales inculcados durante estos años y por proporcionar los recursos humanos y tecnológicos que hicieron posible el desarrollo de la presente investigación.

El autor.

Resumen

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones tienden a ser breves y fáciles de comprender, y su lenguaje es llano y accesible.

La intención única de los textos expositivos es la de agotar el tema, es decir, transmitir al lector una información. Comúnmente, los textos expositivos se circunscriben al asunto que abordan, sin ir más allá y sin echar mano a contenidos emotivos. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones tienden a ser breves y fáciles de comprender, y su lenguaje es llano y accesible.

Palabras clave: palabra 1; palabra 2; palabra3; palabra4; palabra5.

Abstract

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones tienden a ser breves y fáciles de comprender, y su lenguaje es llano y accesible.

La intención única de los textos expositivos es la de agotar el tema, es decir, transmitir al lector una información. Comúnmente, los textos expositivos se circunscriben al asunto que abordan, sin ir más allá y sin echar mano a contenidos emotivos. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones tienden a ser breves y fáciles de comprender, y su lenguaje es llano y accesible.

Keywords: palabra 1; palabra 2; palabra3; palabra4; palabra5.

Presentación

Señores miembros del jurado:

De acuerdo con el cumplimiento de las disposiciones del reglamento de grados y títulos de la Universidad Privada Antenor Orrego, exponemos a vuestra consideración la tesis titulada: Haga clic o pulse aquí para escribir texto.

Desarrollado con el fin de obtener el título de Ingeniero de yyyyyyyyyyyyyy yyyyyyyyyyyyyy yyyyyyyyyyyyyy. El objetivo principal es Haga clic o pulse aquí para escribir texto.

A ustedes miembros del jurado, mostramos nuestro especial y mayor reconocimiento por el dictamen que se haga merecedor y correspondiente del presente trabajo.

Nombres y Apellidos 1

DNI:

ORCID:

Nombres y Apellidos 2

DNI:

ORCID:

Índice de contenidos

Agradecimiento	iii
Resumen	iv
Abstract	v
Presentación	vi
Índice de contenidos	vii
Índice de figuras	ix
1. Introducción	10
1.1. Contexto y antecedentes	10
1.2. Descripción y justificación del estudio	10
1.3. Organización del documento	10
2. Planteamiento del problema de investigación	11
2.1. Descripción y delimitación del problema	11
2.1.1. Formulación del problema	11
2.1.2. Problema central del estudio	11
2.2. Objetivos de la investigación	13
2.2.1. Objetivo general	13
2.2.2. Objetivos específicos	13
2.3. Importancia del estudio	14
2.4. Justificación de la investigación	15
2.4.1. Justificación técnica	15
2.4.2. Justificación práctica	15
2.4.3. Justificación metodológica	16
2.4.4. Justificación social	16
2.5. Limitaciones del estudio	17
3. Marco teórico	17
3.1. Marco histórico	17
3.2. Investigaciones antecedentes relacionadas con el tema	18
3.3. Definición de términos básicos	27
3.3.1. RAG	27
3.3.2. GraphRAG	27
3.3.3. Grafo de conocimiento	28
3.3.4. Precisión Semántica	28
3.3.5. LLM	29

3.3.6.	Embeddings	30
3.3.7.	RAGAS	30
3.3.8.	G-Val ¡Error! Marcador no definido.	
4.	Hipótesis y variables	31
4.1.	Supuestos básicos	31
4.2.	Hipótesis general	32
4.3.	Variable	33
4.4.	Matriz de consistencia.....	34
5.	Marco metodológico	35
5.1.	Tipo de investigación	35
5.2.	Nivel de madurez tecnológica	35
5.3.	Método de investigación	35
5.4.	Diseño del estudio.....	35
5.5.	Población y muestra.....	36
4.4.2.	Muestra	36
5.6.	Técnicas e instrumentos de recolección de datos.	37
5.7.	Procedimientos de ejecución del estudio	37
6.	Presentación de resultados	42
6.1.	Resultados de la investigación.....	42
6.1.1.	Resultado del OE1:	42
6.1.2.	Resultado del OE2:	42
6.1.3.	Resultado del OE3:	45
6.1.4.	Resultado del OE4:	45
6.2.	Conclusiones	45
6.3.	Recomendaciones	45
7.	Referencias bibliográficas	45
8.	Anexos	50

Índice de tablas

Tabla 1. Operacionalización de variables..... ¡Error! Marcador no definido.

Tabla 2. Matriz de consistencia de la investigación. ¡Error! Marcador no definido.

Índice de figuras

Figura 1. Diseño con posprueba únicamente y grupo de control. **¡Error! Marcador no definido.**

1. Introducción

1.1. Contexto y antecedentes

1.2. Descripción y justificación del estudio

1.3. Organización del documento

2. Planteamiento del problema de investigación

2.1. Descripción y delimitación del problema

2.1.1. Formulación del problema

¿En qué medida concuerda un sistema GraphRAG de auditoría semántica con la evaluación experta en la detección de inconsistencias en citaciones bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025?

2.1.2. Problema central del estudio

La integridad del discurso científico descansa sobre la validez de sus citas y referencias, las cuales funcionan como el cimiento probatorio que permite la reproducibilidad y la inserción de nuevos hallazgos en el conocimiento existente. No obstante, investigaciones sobre la calidad de las tesis en el Perú revelan un escenario preocupante: la precisión bibliográfica suele alcanzar apenas un nivel "suficiente" o "regular", con deficiencias críticas en la exhaustividad y la exactitud de los datos (Hernández et al., 2019; Perdomo et al., 2020). Esta situación indica que, incluso antes del auge de la inteligencia artificial, los mecanismos institucionales ya presentaban fallas estructurales para garantizar el rigor científico en los trabajos de titulación.

La irrupción de los Modelos de Lenguaje de Gran Tamaño (LLM) ha exacerbado esta problemática al introducir una escala sin precedentes de alucinaciones bibliográficas en la literatura académica (Zhao et al., 2026). Se ha documentado un aumento drástico en la aparición de referencias inexistentes tras la adopción masiva de estas herramientas, estimándose que solo en el año 2025 se generaron más de 146,000 citas alucinadas en diversos repositorios científicos. Este fenómeno no se limita a autores aislados, sino que representa una contaminación difusa donde fuentes ficticias se integran silenciosamente en manuscritos aparentemente legítimos, desafiando la fiabilidad de los registros académicos (Zhao et al., 2026).

El problema central radica en que estas alucinaciones no son simples errores tipográficos, sino fabricaciones que mantienen una plausibilidad superficial diseñada para engañar a los revisores (Ansari, 2026). Los sistemas de inteligencia artificial son capaces de generar metadatos precisos como: nombres de autores, títulos de revistas y años de publicación que suenan técnicamente coherentes pero que no corresponden a ninguna obra real. En el área de ingeniería, esto se traduce en la incorporación de respaldos que utilizan terminología de dominio específica, logrando evadir los controles tradicionales basados en la similitud de texto o en la revisión humana superficial.

Además, se ha detectado la presencia de la "alucinación semántica", donde se inventan títulos que encajan perfectamente con el contexto de la investigación, creando una apariencia de respaldo académico impecable (Ansari, 2026). En las tesis de ingeniería de la UPAO, existe el riesgo de que los estudiantes utilicen estas herramientas para "rellenar" vacíos bibliográficos, generando una veta de plausibilidad que los filtros institucionales actuales no pueden detectar. Como resultado, una tesis puede ser aprobada y publicada en el repositorio institucional conteniendo vínculos fraudulentos que subvierten la trazabilidad del conocimiento científico.

La vulnerabilidad del sistema se ve agravada por las limitaciones en las competencias investigativas del profesorado. En el contexto universitario peruano, se ha identificado que el 53% de los docentes en facultades de ingeniería posee un nivel bajo en el dominio de procesos metodológicos (Turpo-Gebera et al., 2024). Esta carencia de habilidades técnicas para la supervisión exhaustiva, sumada a la falta de retroalimentación significativa, impide que los asesores actúen como un filtro eficaz contra la infiltración de contenidos sintéticos y alucinados en las investigaciones estudiantiles.

Esta vulnerabilidad sistémica no es solo teórica. Las entrevistas realizadas a docentes evaluadores de tesis de ingeniería en la UPAO revelan que el proceso de verificación de citas descansa, en la

práctica, en la revisión manual de una muestra mínima de referencias ,en algunos casos tan solo dos por tesis seleccionadas al azar, sin que exista un protocolo institucional estandarizado que garantice la precisión semántica. Dos de los tres evaluadores entrevistados reportaron haber detectado distorsión o tergiversación de fuentes de forma recurrente, y todos coincidieron en que Turnitin, la única herramienta de uso generalizado, carece de capacidad para detectar este tipo de errores. Adicionalmente, dos de los tres docentes señalaron que el tiempo asignado para la revisión es insuficiente, lo que reduce aún más la probabilidad de detectar referencias alucinadas o semánticamente incoherentes. Estos hallazgos confirman que existe una necesidad concreta de evaluar si un sistema automatizado basado en GraphRAG puede alcanzar una concordancia sustancial con el juicio experto en la detección de estas inconsistencias.

2.2. Objetivos de la investigación

2.2.1. Objetivo general

Evaluar la concordancia de un sistema GraphRAG de auditoría semántica con la evaluación experta en la detección de inconsistencias en citaciones bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025.

2.2.2. Objetivos específicos

OE1: Describir las inconsistencias presentes en el corpus de tesis de Ingeniería de Sistemas de la UPAO 2024-2025 mediante clasificación experta usando el esquema SUPPORTS, REFUTES y NO INFO.

OE2: Desarrollar e implementar el sistema GraphRAG de auditoría semántica para la detección automática de inconsistencias en citaciones bibliográficas de tesis de ingeniería.

OE3: Evaluar el desempeño del sistema GraphRAG en la detección de inconsistencias sobre el corpus de tesis midiendo precisión, recall, F1-score y métricas RAGAS.

OE4: Medir la concordancia del sistema GraphRAG con la clasificación experta mediante Kappa de Cohen.

2.3. Importancia del estudio

El rigor en la precisión semántica de las citas y referencias constituye un pilar fundamental para salvaguardar la integridad de la investigación universitaria, particularmente en las disciplinas de ingeniería. Arévalo et al. (2021) demuestran que los estudiantes de ingeniería tienden a priorizar el contenido técnico por encima de la redacción académica, lo que se traduce frecuentemente en descuidos y errores en la elaboración de sus bibliografías. A este reto formativo, que representa por sí solo una de las mayores dificultades en la redacción de trabajos de grado y la prevención del plagio se suma un riesgo silencioso pero crítico: los errores de citación semánticos (Samat et al., 2025). Las referencias académicas alcanzan tasas de error de hasta un 25%, donde las afirmaciones del autor tergiversan las fuentes originales o carecen del sustento afirmado (Hang et al., 2025). Esta problemática se ha agravado con el auge de las inteligencias artificiales generativas, las cuales tienden a producir citas y referencias que suenan plausibles pero que son inexactas, distorsionadas o completamente inventadas (Cheng et al., 2025; Haan, 2025).

Frente a este panorama, la presente investigación adquiere relevancia primordial al enfocarse en evaluar el desempeño y la concordancia de un sistema GraphRAG de auditoría semántica con la evaluación experta en la detección de inconsistencias en citaciones bibliográficas de tesis de ingeniería de la UPAO. Hu et al. (2024) señalan que GraphRAG, a diferencia de los modelos RAG tradicionales, procesa eficazmente redes de documentos integrando tanto la información textual como las topologías de las redes de citación, lo que lo convierte en una arquitectura analítica superior para este propósito. Al delimitar el estudio a medir la concordancia del sistema con el juicio experto mediante Kappa de Cohen y su desempeño mediante precisión, recall y F1-score, se obtendrá evidencia empírica rigurosa sobre la capacidad del sistema para clasificar las afirmaciones del tesista según el esquema SUPPORTS, REFUTES y NO INFO de Wadden et al. (2020), sentando un precedente científico sobre la utilidad de auditar

semánticamente la calidad investigativa y mitigar la propagación de conocimiento erróneo."

2.4. Justificación de la investigación

2.4.1. Justificación técnica

Esta investigación se justifica técnicamente por la necesidad de evaluar empíricamente el rendimiento de arquitecturas de recuperación avanzadas frente a las limitaciones de los sistemas tradicionales. Peng et al. (2024) señalan que el modelo RAG convencional suele ignorar las relaciones estructuradas entre documentos, limitando significativamente su capacidad de razonamiento complejo y de contexto global. En contraste, los sistemas GraphRAG modelan la literatura científica como un grafo de conocimiento interconectado, proporcionando una estructura explícita e interpretable que teóricamente mejora la precisión de la recuperación y mitiga las alucinaciones de los modelos de lenguaje (Roll et al., 2025). Por tanto, desarrollar e implementar un sistema auditor basado en GraphRAG y evaluar su desempeño aportará evidencia rigurosa sobre si la integración de grafos de conocimiento optimiza la detección de inconsistencias en citas bibliográficas de tesis de ingeniería.

2.4.2. Justificación práctica

La justificación práctica reside en la urgencia de validar la efectividad de soluciones automatizadas para los asesores y jurados de tesis, quienes enfrentan el reto insostenible de verificar manualmente la exactitud de las referencias. El uso no supervisado de inteligencia artificial generativa ha incrementado drásticamente la aparición de referencias fabricadas o inexactas; cuando se emplea IA sin supervisión humana, las tasas de error en las referencias pueden alcanzar hasta un 70% (Kacena et al., 2024). Dunford et al. (2024) afirman que ante la inviabilidad de una revisión humana exhaustiva, resulta imperativo contar con el análisis automatizado de las bibliografías para detectar problemas de integridad a gran escala.

Evaluar la concordancia del sistema con el juicio experto permitirá determinar su verdadera utilidad práctica para agilizar y asegurar el flujo de revisión de las tesis en la UPAO.

2.4.3. Justificación metodológica

Metodológicamente, esta investigación se justifica al proponer y aplicar un marco de evaluación estructurado para medir la fidelidad de las citas académicas en contextos donde interviene la inteligencia artificial. Magesh et al. (2025) sostienen que evaluar la fiabilidad de los sistemas de IA en dominios académicos requiere superar las métricas tradicionales de superposición de texto y adoptar tipologías que midan específicamente la corrección factual y la fundamentación real de las afirmaciones en las fuentes citadas. Asimismo, la evaluación integral de sistemas RAG exige marcos complejos que analicen la coherencia entre el texto y la evidencia recuperada, asegurando la trazabilidad de la información (Lyu et al., 2025). Al medir la concordancia del sistema con el esquema tripartito de Wadden et al. (2020) mediante Kappa de Cohen, este estudio consolidará una metodología estandarizada con indicadores métricos validados para auditar inconsistencias en citaciones bibliográficas.

2.4.4. Justificación social

A nivel social e institucional, el estudio se justifica por su enfoque en salvaguardar la integridad de la producción científica y frenar la propagación de la desinformación académica. Históricamente, las tesis universitarias han presentado altas tasas de errores bibliográficos, dificultando el acceso a las fuentes originales y mermando la credibilidad de las instituciones educativas (Gupta, 2020). Chen et al. (2025) describen este fenómeno como un efecto de teléfono roto, donde la pérdida de fidelidad semántica al citar distorsiona el conocimiento original, propagando información no verificada en cadena a través de la literatura científica. Los errores de citación tienen la peligrosa consecuencia de consolidar falsedades

como hechos establecidos, afectando directamente a la sociedad y a futuros investigadores (Wakeling et al., 2025). Al evaluar el desempeño y la concordancia del sistema GraphRAG con el juicio experto, esta investigación contribuye directamente a garantizar un ecosistema de conocimiento más ético, transparente y de alta calidad en la UPAO.

2.5. Limitaciones del estudio.

La presente investigación reconoce las siguientes limitaciones que deben considerarse al interpretar sus resultados.

En primer lugar, la auditoría semántica del sistema está condicionada por la disponibilidad de texto abierto de las fuentes citadas. Cuando un paper no cuenta con PDF de acceso abierto indexado en Unpaywall, el sistema recurre únicamente al abstract provisto por CrossRef, el cual comprende entre 150 y 300 palabras, lo que puede resultar insuficiente para verificar afirmaciones específicas que involucren estadísticas o datos metodológicos detallados.

En segundo lugar, la cobertura del sistema se limita a fuentes indexadas en CrossRef. Referencias de fuentes en español, libros, actas de congresos nacionales o documentos sin DOI asignado podrían no ser localizadas correctamente, lo que podría subestimar la tasa real de errores bibliográficos en tesis que citen predominantemente literatura iberoamericana.

Finalmente, los resultados obtenidos corresponden exclusivamente al corpus de tesis de ingeniería de la UPAO, por lo que no son generalizables a otras instituciones universitarias ni a otras disciplinas académicas. Asimismo, la concordancia medida entre el sistema y el experto está condicionada por el criterio del evaluador externo seleccionado, por lo que los resultados podrían variar con un experto distinto.

3. Marco teórico

3.1. Marco histórico

No aplica.

3.2. Investigaciones antecedentes relacionadas con el tema

Walters y Wilder (2023), en el contexto de la fidelidad documental para la investigación científica, tuvieron como objetivo evaluar la prevalencia de referencias bibliográficas fabricadas y los errores sustantivos generados por modelos de lenguaje como ChatGPT-3.5 y ChatGPT-4. Su diseño empírico consistió en solicitar a los modelos la redacción de 84 revisiones de literatura enfocadas en 42 temas multidisciplinarios, extrayendo 636 citas que fueron verificadas sistemáticamente en múltiples bases de datos académicas. Los resultados revelaron que el 55% de las citas generadas por GPT-3.5 y el 18% de las producidas por GPT-4 fueron completamente fabricadas; además, el 43% y el 24% de las referencias reales en cada modelo respectivamente presentaron errores sustantivos graves en metadatos como nombres de autores, títulos o números de volumen. Este trabajo incide de manera crítica en la presente investigación, ya que demuestra estadísticamente que los modelos generativos estándar son altamente propensos a comprometer la integridad documental, justificando la necesidad de incorporar un auditor semántico avanzado para revisar bibliografía compleja como las tesis de ingeniería.

Cabezas-Clavijo y Sidorenko-Bautista (2026), con el objetivo de evaluar la confiabilidad de ocho chatbots de inteligencia artificial generativa en la generación de referencias bibliográficas académicas, diseñaron un estudio comparativo que analizó 400 referencias producidas por herramientas como ChatGPT, Claude, Gemini y DeepSeek en cinco áreas del conocimiento universitario. Su metodología empleó un protocolo de prompting estandarizado y verificó cada referencia contra cinco criterios formales: autoría, año, título, fuente y datos de localización, mediante búsquedas manuales en Google Scholar. Los resultados revelaron que solo el 26.5% de las referencias generadas fueron completamente correctas, mientras que el 39.8% resultaron incorrectas o completamente fabricadas, siendo el área de Ingeniería y Tecnología la que registró la mayor tasa de referencias fabricadas con un 52.5%, superando a todas las demás disciplinas evaluadas. Este antecedente aporta evidencia empírica directa sobre la magnitud del problema en el contexto universitario de ingeniería,

justificando la urgencia de evaluar el efecto de un sistema auditor automatizado sobre la precisión semántica de las citas en tesis de ingeniería de la UPAO.

Ipanaqué-Zapata et al. (2023), con el objetivo de evaluar las propiedades psicométricas de un instrumento de habilidades investigativas y caracterizar su desarrollo en estudiantes universitarios peruanos de cursos de tesis en modalidad e-learning, aplicaron un estudio psicométrico y descriptivo a 1598 estudiantes de una universidad privada peruana distribuidos en cinco regiones del país, entre ellas La Libertad. Su diseño empleó análisis factorial exploratorio y confirmatorio con estimadores robustos, junto con análisis de invarianza de medición por sexo y grupo etario, evaluando dimensiones como el uso de catálogos bibliográficos, la formulación del problema de investigación y el procesamiento estadístico de datos. Los resultados evidenciaron que los estudiantes presentaron niveles medio-ade cuados en el uso de material bibliográfico, con apenas el 22.24% haciendo uso de Scopus y el 17.26% de Web of Science, siendo las habilidades de formulación del problema de investigación y el procesamiento estadístico las de menor dominio. Este antecedente contextualiza empíricamente las limitaciones bibliográficas de los tesis tas peruanos de pregrado, justificando la necesidad de evaluar el efecto de un sistema auditor automatizado que refuerce la precisión semántica de las citas en tesis de ingeniería de la UPAO, institución ubicada precisamente en La Libertad.

Magesh et al. (2025), con el objetivo de contrastar las aseveraciones sobre la mitigación de alucinaciones mediante el uso de bases de datos integradas, evaluaron la confiabilidad real de las principales herramientas comerciales de investigación legal fundamentadas en RAG. Su diseño empleó un conjunto pre-registrado con más de 200 consultas analíticas complejas ejecutadas en sistemas líderes de la industria, sometiendo las respuestas a una evaluación experta manual centrada en la corrección y la fundamentación. Los hallazgos evidenciaron que, pese a estar anclados en arquitecturas RAG, los sistemas de inteligencia artificial aún alucinan en una proporción de entre un 17% y un 33% de las ocasiones, donde gran parte de los fallos no radican en inventar casos sino en proporcionar citas

descontextualizadas, empleando fuentes reales que no respaldan el enunciado original. Este antecedente valida empíricamente que el enfoque RAG tradicional no elimina las alucinaciones ni asegura el sustento contextual, reforzando la decisión metodológica de escalar hacia arquitecturas topológicas como GraphRAG.

Han, Ma, et al., (2025), con el objetivo de establecer una comprensión sistemática de las fortalezas, limitaciones y compromisos entre RAG y GraphRAG sobre tareas de texto de uso general, presentaron un estudio comparativo controlado que evaluó cuatro categorías representativas de sistemas GraphRAG frente a RAG convencional en tareas de respuesta a preguntas y resumen basado en consultas, introduciendo un protocolo de evaluación unificado que estandarizó el preprocesamiento de datos, las configuraciones de recuperación y los ajustes de generación para garantizar comparaciones justas y reproducibles entre paradigmas, empleando los modelos Llama-3.1-8B-Instruct y Llama-3.1-70B-Instruct como generadores y métricas de Precisión, Recall y F1 para respuesta a preguntas, y ROUGE-2 y BERTScore para tareas de resumen. Los resultados demostraron que RAG y GraphRAG exhiben comportamientos complementarios en lugar de una dominancia consistente, donde RAG supera en consultas de un solo salto orientadas al detalle factual con un F1 de 64.78% en el dataset NQ, mientras que GraphRAG Community-based (Local) supera en consultas de múltiples saltos que requieren razonamiento relacional complejo, alcanzando un 69.01% de precisión global en MultiHop-RAG frente al 67.02% de RAG, y que las estrategias híbridas de selección e integración que combinan ambos paradigmas producen mejoras consistentes de hasta 6.4% sobre el mejor baseline individual. Este antecedente aporta evidencia empírica directa sobre la superioridad de GraphRAG frente a RAG convencional en tareas que exigen razonamiento relacional sobre múltiples documentos, condición análoga a la verificación semántica de citas en tesis de ingeniería donde las afirmaciones del tesista deben contrastarse con redes de fuentes interconectadas, validando la decisión arquitectónica del presente sistema auditor de emplear GraphRAG como motor de recuperación semántica.

Nagori et al. (2025), con el objetivo de superar las limitaciones de los pipelines estáticos de recuperación en la revisión automatizada de literatura científica, desarrollaron un marco agéntico de código abierto que integra GraphRAG y VectorRAG de forma dinámica sobre un grafo de conocimiento construido en Neo4j y una base vectorial FAISS. Su diseño ingirió datos bibliométricos de PubMed, ArXiv y Google Scholar, procesando los textos completos en formato PDF mediante segmentación semántica, y evaluó tres configuraciones comparativas mediante remuestreo bootstrap sobre 40 pares de preguntas sintéticas balanceadas entre ambos modos de recuperación. Los resultados demostraron que el agente con ajuste fino mediante optimización de preferencias directas superó ampliamente al RAG no agéntico, alcanzando una ganancia de 0.63 en recuperación de contexto vectorial y de 0.56 en precisión de contexto global, con mejoras adicionales en fidelidad y relevancia de respuesta. Este estudio aporta evidencia empírica directa de que GraphRAG aplicado sobre corpus de documentos científicos en PDF mejora sustancialmente la precisión y fidelidad de la recuperación semántica, validando su idoneidad como arquitectura base para el sistema auditor evaluado en la presente investigación.

Hang et al. (2025), en la búsqueda por erradicar las falsedades documentales generadas por la IA, establecieron como objetivo diseñar TrumorGPT, una solución de inteligencia artificial generativa construida específicamente para ejecutar labores rigurosas de verificación de hechos destinadas a combatir la desinformación. Su diseño propuso una infraestructura híbrida que integra un modelo de lenguaje con GraphRAG, aplicando algoritmos de centralidad mejorada por temas y herramientas de inferencia como TextRank para construir dinámicamente grafos de conocimiento semántico jerarquizado. Cuantitativamente, TrumorGPT lideró el rendimiento en todas las métricas evaluadas frente a otros LLMs, registrando un 88.5% en precisión total de fact-checking y una puntuación F1 del 88.1%, con explicaciones resolutivas usando un promedio de solo 2.8 oraciones por justificación. Este estudio delinea el núcleo tecnológico exacto bajo el cual GraphRAG funciona de manera óptima como agente

automatizado de auditoría, verificando sistemáticamente enunciados mediante su acoplamiento con entidades y aristas de conocimiento.

Sarmah et al. (2024), con el objetivo de superar las limitaciones de los sistemas RAG convencionales en la extracción e interpretación de información compleja desde documentos financieros no estructurados con terminología especializada, propusieron HybridRAG, un enfoque que integra GraphRAG basado en grafos de conocimiento con VectorRAG basado en bases de datos vectoriales, construyendo el grafo de conocimiento mediante una cadena de dos niveles de LLMs para extracción de entidades y relaciones desde transcripciones de llamadas de resultados financieros de 50 empresas del índice Nifty 50, generando 13,950 tripletas con 11,405 nodos y 13,883 aristas, y evaluando los tres pipelines, VectorRAG, GraphRAG e HybridRAG, mediante el framework RAGAS con las métricas de Faithfulness, Answer Relevancy, Context Precision y Context Recall sobre un conjunto de 400 pares de preguntas y respuestas reales extraídos de los propios documentos financieros que servían como ground truth. Los resultados demostraron que GraphRAG superó a VectorRAG en Faithfulness con 0.96 frente a 0.94 y en Context Precision con 0.96 frente a 0.84, siendo especialmente superior en preguntas extractivas donde la información está explícitamente representada como entidades y relaciones en el grafo, mientras que HybridRAG alcanzó el mejor desempeño global con Faithfulness de 0.96, Answer Relevancy de 0.96 y Context Recall perfecto de 1.0, evidenciando que la integración de recuperación estructural mediante grafos de conocimiento con recuperación semántica vectorial produce respuestas más fieles y contextualmente relevantes que cualquiera de los enfoques individuales. Este antecedente es directamente relevante para la presente investigación al demostrar empíricamente, mediante exactamente las mismas métricas RAGAS adoptadas como instrumentos de medición en este estudio, que GraphRAG supera a RAG convencional en fidelidad semántica y precisión de contexto al procesar documentos especializados con terminología técnica densa, condición estructuralmente análoga a la auditoría de citas en tesis de

ingeniería donde las afirmaciones del tesista deben verificarse contra el contenido técnico específico de los papers referenciados.

Scaffidi et al. (2025), con el objetivo de evaluar el impacto de diferentes esquemas de grafos de conocimiento sobre la calidad de las respuestas del pipeline Microsoft GraphRAG al procesar informes técnicos especializados con terminología densa de dominio, aplicaron el pipeline de Microsoft GraphRAG sobre un corpus de 15 informes técnicos de geología, química y procesamiento de minerales publicados por el Minerals Research Institute of Western Australia con aproximadamente 2.7 millones de tokens en total, comparando cuatro configuraciones de esquemas de grafos de conocimiento: un esquema de cinco clases desarrollado por expertos del dominio mineral, un esquema expandido de ocho clases, un esquema autogenerado por el Prompt Tuner de GraphRAG y un pipeline sin esquema, evaluando todas las configuraciones contra un baseline RAG convencional mediante un sistema de clasificación de cinco niveles desarrollado por expertos de la materia que consideró relevancia de respuesta, robustez al ruido y presencia de alucinaciones, con un acuerdo inter-evaluador de Cohen's Kappa de 0.804 sobre 675 evaluaciones binarias. Los resultados demostraron que el esquema de cinco clases específico del dominio mineral extrajo aproximadamente un 10% más de entidades que las demás configuraciones generando 218,274 nodos relacionales, produciendo las respuestas con mayor corrección factual y el menor número de alucinaciones, mientras que el baseline RAG convencional produjo respuestas un 39.64% más cortas e incompletas con el doble de tasa de alucinaciones, evidenciando que un esquema de grafos de conocimiento alineado al dominio técnico específico del corpus mejora sustancialmente la calidad de recuperación semántica al enriquecer la ventana de contexto del LLM con entidades de alto valor relevantes para la consulta. Este antecedente es directamente relevante para la presente investigación al demostrar empíricamente sobre la misma implementación de Microsoft GraphRAG adoptada como arquitectura base del sistema auditor que los grafos de conocimiento con esquemas orientados al dominio técnico específico superan estructuralmente al RAG convencional en documentos

con léxico denso y especializado, condición análoga a la que presentan las tesis de ingeniería de la UPAO cuyos papers referenciados contienen terminología técnica que dificulta la recuperación semántica mediante vectorización genérica.

Besrou et al. (2025), con el objetivo de superar las limitaciones de los sistemas RAG convencionales en la respuesta a preguntas científicas de dominio abierto donde las consultas complejas demandan respuestas precisas con citas verificables y recuperación a través de millones de documentos académicos, desarrollaron SQuAI, un framework multi-agente de RAG construido sobre 2.3 millones de papers de texto completo de arXiv, implementando cuatro agentes colaborativos donde el primero descompone consultas complejas en sub-preguntas, el segundo genera respuestas iniciales por documento recuperado mediante recuperación híbrida sparse-densa, el tercero filtra tripletas pregunta-respuesta-evidencia mediante puntuación de relevancia adaptativa, y el cuarto sintetiza la respuesta final con citas en línea granulares que vinculan cada afirmación con su fuente documental específica, evaluando el sistema sobre tres benchmarks de QA científica, LitSearch con 478 preguntas derivadas de papers de ciencias de la computación, unarXive Simple con 500 preguntas de complejidad general y unarXive Expert con 500 preguntas técnicas especializadas, utilizando el framework DeepEval con métricas implementadas mediante razonamiento chain-of-thought siguiendo el paradigma G-Eval (Liu et al., 2023) para calcular Answer Relevance, Contextual Relevance y Faithfulness como scores continuos entre 0 y 1 con justificaciones intermedias generadas por el LLM para cada par pregunta-respuesta-evidencia evaluado. Los resultados demostraron que SQuAI superó al RAG estándar en todos los benchmarks alcanzando mejoras de hasta +0.088 en el score combinado de las tres métricas, con Faithfulness superior a 0.95 en todas las configuraciones, Answer Relevance de 0.937 frente a 0.897 del baseline en LitSearch y Contextual Relevance de 0.782 frente a 0.562 en unarXive Simple, evidenciando que la arquitectura multi-agente con descomposición de consultas y filtrado adaptativo de documentos mejora sustancialmente la precisión semántica de la recuperación y la fidelidad de las respuestas sobre

corpus de documentos científicos académicos. Este antecedente valida empíricamente el paradigma G-Eval como instrumento de evaluación semántica aplicado sobre documentos científicos académicos, demostrando que sus métricas basadas en razonamiento chain-of-thought son sensibles y discriminativas para detectar diferencias de calidad en sistemas que deben verificar la consistencia entre afirmaciones generadas y sus fuentes documentales, lo que fundamenta la adopción de G-Eval como base metodológica del juicio clasificatorio del sistema auditor propuesto en la presente investigación.

Thakur et al. (2025), con el objetivo de determinar si un juez LLM puede reemplazar de manera confiable a un juez humano en la evaluación de soporte en sistemas RAG, donde el soporte se define como la medida en que el documento citado respalda factualmente la afirmación presente en la respuesta generada, condujeron un estudio comparativo a gran escala sobre 45 submissions de 20 grupos participantes en el TREC 2024 RAG Track evaluadas sobre 36 tópicos de consulta multifacética y no factioidea, implementando un juez automático basado en GPT-4o mediante un prompt estructurado que clasifica cada par afirmación-documento citado en tres niveles de soporte, Full Support, Partial Support y No Support, y contrastando sus predicciones contra anotaciones humanas bajo dos condiciones: evaluación manual desde cero con 6,742 anotaciones sobre 22 tópicos y evaluación manual con post-edición de predicciones LLM con 4,165 anotaciones sobre 14 tópicos, calculando métricas de precisión ponderada y recall ponderado a nivel de sistema para cuantificar el acuerdo entre ambos tipos de jueces. Los resultados demostraron que GPT-4o y los jueces humanos concordaron perfectamente en el 56% de las evaluaciones en la condición manual desde cero, incrementando al 72% en la condición con post-edición, con una correlación a nivel de sistema superior a Kendall τ de 0.79 en ambas condiciones, y que en el análisis de desacuerdos con un juez humano independiente, este concordó más con GPT-4o que con el juez humano original con un Cohen κ de 0.29 frente a -0.03, sugiriendo que los LLMs constituyen una alternativa confiable para la evaluación de soporte en sistemas RAG con citas documentales. Este antecedente valida

empíricamente el mecanismo central del presente sistema auditor, donde un LLM emite juicios clasificatorios sobre si una afirmación del tesista está respaldada por el contenido del paper citado, demostrando que este paradigma de evaluación alcanza niveles de concordancia con el juicio humano experto suficientemente altos para ser adoptado como instrumento de auditoría semántica automatizada a escala, lo que fundamenta la adopción del protocolo G-Eval como base metodológica del juicio clasificatorio del sistema propuesto.

Antal y Buza (2025), con el objetivo de proporcionar una evaluación integral de modelos de lenguaje grande de código abierto dentro de sistemas RAG utilizando un corpus derivado de abstracts de tesis de pregrado, construyeron el dataset SapiTheses compuesto por 227 documentos correspondientes a abstracts de tesis de licenciatura en ciencias de la computación redactadas en inglés por estudiantes húngaros, generando mediante RAGAS un benchmark de 122 preguntas con respuestas de referencia categorizadas en tres tipos: fact-based con 25 preguntas, reasoning con 73 preguntas y summary con 24 preguntas, evaluando el sistema RAG con Elasticsearch como recuperador en modalidades léxica y semántica y seis modelos de lenguaje generativos de código abierto como generadores, Mistral, DeepSeek-r1 y Llama3, midiendo el desempeño del componente de recuperación mediante MRR y Recall@k y el componente de generación mediante el framework RAGAS con las métricas de Faithfulness, Answer Relevance, Semantic Similarity y Answer Correctness sobre los 122 pares pregunta-respuesta-contexto del corpus académico universitario. Los resultados demostraron que Llama3 alcanzó la mayor Faithfulness con 0.82 en el escenario ideal y 0.76 en el escenario real con recuperación automática, seguido de los modelos Mistral con valores de 0.76 a 0.78 en escenario ideal, evidenciando que las preguntas de tipo factual obtienen los mayores scores de Faithfulness mientras que las preguntas de razonamiento representan el mayor desafío para todos los modelos con valores consistentemente menores, y que la calidad de recuperación impacta directamente en la generación dado que todos los modelos experimentaron degradación al pasar del escenario ideal al real,

concluyendo que Faithfulness y Answer Correctness son las métricas RAGAS más efectivas para evaluar sistemas RAG en dominios académicos universitarios. Este antecedente es directamente relevante para la presente investigación al demostrar empíricamente que el framework RAGAS con sus métricas de Faithfulness y Answer Relevance constituye un instrumento válido y sensible para evaluar la calidad de sistemas RAG aplicados específicamente sobre corpus de tesis universitarias, validando la adopción de estas métricas como instrumentos de medición de la precisión semántica en el presente sistema auditor de citas y referencias en tesis de ingeniería de la UPAO.

3.3. Definición de términos básicos

3.3.1. RAG

Es un marco de inteligencia artificial que combina las capacidades generativas de los grandes modelos de lenguaje con conocimientos externos extraídos de una base de datos separada e independiente. Este enfoque funciona integrando la memoria paramétrica del modelo con una memoria no paramétrica externa, lo cual permite mejorar notablemente el rendimiento de la IA en tareas que requieren información intensiva o específica de un dominio. RAG opera mediante un flujo de trabajo de tres pasos principales: la recuperación de información relevante en la base de datos, la aumentación de la consulta inicial utilizando ese contexto, y la generación final de la respuesta por parte del modelo. Su propósito central es dotar a la IA de datos adicionales para generar resultados precisos vinculados directamente a ese conocimiento de referencia, reduciendo drásticamente el riesgo de alucinaciones y mejorando la confiabilidad general del sistema (Klesel y Wittmann, 2025)

3.3.2. GraphRAG

GraphRAG es una técnica avanzada que integra la Generación Aumentada por Recuperación (RAG) con datos estructurados en forma de grafos para codificar información masiva, heterogénea y relacional mediante nodos interconectados por bordes, lo cual le

permite superar las limitaciones de la simple búsqueda de similitud léxica o semántica del RAG tradicional al aprovechar el conocimiento relacional a través de técnicas de aprendizaje automático de grafos y algoritmos de recorrido, mejorando sustancialmente la ejecución de tareas complejas al proporcionar un contexto mucho más rico para los modelos generativos (Han, Wang, et al., 2025). En su implementación más difundida, Microsoft GraphRAG (Edge et al., 2024) construye automáticamente un grafo de conocimiento a partir de documentos no estructurados mediante un modelo de lenguaje grande, extrayendo entidades y relaciones que se organizan en comunidades jerárquicas mediante el algoritmo de Leiden, generando resúmenes de cada comunidad que permiten tanto búsquedas locales orientadas a entidades específicas como búsquedas globales orientadas a síntesis temáticas de alto nivel sobre el corpus completo.

3.3.3. Grafo de conocimiento

Un grafo de conocimiento es una extensa estructura de datos que sirve para mapear la complicada red de relaciones entre diversas entidades, como fármacos, enfermedades, genes y proteínas en el ámbito biomédico; dentro de este sistema, cada entidad se representa como un nodo que almacena detalles específicos, como su nombre y tipo, mientras que los bordes o enlaces muestran cómo se conectan e interactúan entre sí, ya sea mediante tratamientos o asociaciones; gracias a esta arquitectura de red, es posible procesar grandes volúmenes de información compleja de manera muy eficiente, permitiendo a los modelos de inteligencia artificial analizar estas conexiones subyacentes para predecir nuevas aplicaciones terapéuticas y facilitar los descubrimientos científicos (George et al., 2025).

3.3.4. Precisión Semántica

La precisión semántica de las citas académicas se define como la capacidad de una afirmación citante de reflejar fielmente el significado y la intención del trabajo original referenciado. En el ámbito académico, una cita no constituye necesariamente un acto de

respaldo, sino que puede expresar diferentes relaciones semánticas con la fuente: puede respaldarla, simplemente mencionarla, o contrastarla. La precisión semántica se alcanza cuando la relación que el autor citante establece con la fuente corresponde con exactitud al contenido real del trabajo citado, sin distorsiones, exageraciones ni atribuciones incorrectas. La ausencia de esta precisión genera una ruptura en la cadena evidencial del conocimiento científico, comprometiendo la confiabilidad de la literatura académica (Bakker et al., 2023)

Para la verificación automatizada de esta propiedad, Wadden et al., (2020) formalizaron la tarea de verificación semántica de afirmaciones científicas mediante el dataset SciFact, estableciendo que la relación entre una afirmación citante y su fuente puede clasificarse en tres categorías: SUPPORTS, cuando el documento fuente respalda la afirmación; REFUTES, cuando la contradice; y NO INFO, cuando no contiene evidencia suficiente para determinar su veracidad. Este esquema tripartito constituye el precedente conceptual del sistema de clasificación adoptado en la presente investigación.

3.3.5. LLM

Un Modelo de Lenguaje Grande es una clase de modelo de lenguaje basado en redes neuronales que cuentan con miles de millones de parámetros, entrenados utilizando cantidades gigantescas de texto no etiquetado a través de aprendizaje autosupervisado. Estos modelos, que usualmente emplean la arquitectura de transformers, utilizan técnicas de aprendizaje profundo para procesar y comprender el lenguaje natural. Al preentrenarse y ajustarse con volúmenes masivos de datos, los LLMs logran aprender patrones en secuencias de texto no estructuradas y construyen una extensa base de conocimiento del lenguaje, convirtiéndolos en modelos fundacionales con capacidades de propósito general que les permiten sobresalir en un amplio espectro de tareas de Procesamiento de Lenguaje Natural en lugar de estar diseñados para una sola función específica (Fan et al., 2024).

3.3.6. Embeddings

Los embeddings de palabras son representaciones vectoriales densas que ubican a las palabras dentro de un espacio dimensional específico, aprendidas mediante algoritmos no supervisados que procesan grandes cantidades de datos o secuencias de tokens. Existen principalmente dos tipos de enfoques para estas representaciones: los libres de contexto, que generan una matriz global asignando un único vector a cada palabra sin contemplar los distintos significados que puede tener un mismo término en diferentes situaciones, y los contextuales, que solucionan esta limitación asociando diferentes vectores a una misma palabra variando su significado en función del contexto específico en el que se utilice (Mars, 2022).

3.3.7. RAGAS

Es un framework de evaluación automatizada y libre de anotaciones humanas diseñado para medir la calidad de los sistemas de Generación Aumentada por Recuperación a través de métricas que operan de forma complementaria sobre las distintas dimensiones que determinan el desempeño de estos sistemas, sin requerir conjuntos de datos etiquetados ni respuestas de referencia predefinidas Es et al. (2025), comprendiendo tres métricas centrales que en la presente investigación se emplean como indicadores de la variable dependiente. **Faithfulness** cuantifica el grado en que las afirmaciones de la respuesta generada pueden ser inferidas a partir del contexto recuperado, descomponiendo el texto en proposiciones individuales y verificando mediante un LLM si cada una está respaldada por dicho contexto, produciendo un score entre 0 y 1 donde valores cercanos a 1 indican alta consistencia factual; en el presente sistema auditor responde a la pregunta: ¿la afirmación del tesista es consistente con el contenido real del fragmento del paper recuperado por GraphRAG? **Answer Relevance** evalúa si la respuesta aborda de manera directa y apropiada la consulta de entrada, penalizando respuestas incompletas o con información redundante; en el presente sistema

responde a la pregunta: ¿el juicio emitido sobre la cita responde directamente a si esa afirmación específica está respaldada por el paper referenciado, sin desviarse hacia información irrelevante?

Context Precision cuantifica la proporción de fragmentos recuperados que son genuinamente relevantes para evaluar la consulta; en el presente sistema responde a la pregunta: ¿GraphRAG recuperó los fragmentos del paper donde efectivamente debería encontrarse la evidencia que respalda o refuta la afirmación del tesista, o trajo ruido irrelevante al contexto de evaluación?

4. Hipótesis y variables

4.1. Supuestos básicos

Para la evaluación del efecto del sistema auditor, se asume que las tesis seleccionadas del repositorio de la UPAO cuentan con un nivel de legibilidad digital suficiente para permitir la extracción de texto mediante técnicas de procesamiento de lenguaje natural. Se parte de la premisa de que los documentos en formato PDF no presentan corrupciones técnicas que impidan el reconocimiento de las entidades y las relaciones necesarias para la construcción del grafo de conocimiento.

Asimismo, se asume que el modelo de lenguaje (LLM) y la infraestructura de GraphRAG seleccionados mantienen una estabilidad operativa constante durante las fases de evaluación. Se presupone que las capacidades de razonamiento semántico del modelo son capaces de interpretar las aserciones técnicas de ingeniería a partir de los artículos descargados automáticamente por el sistema desde bases de datos académicas accesibles en línea.

Se asume que una proporción suficiente de las fuentes referenciadas en las tesis seleccionadas se encuentra indexada en bases de datos académicas accesibles, ya sea mediante texto completo en acceso abierto a través de Unpaywall o mediante abstract provisto por CrossRef, de modo que el sistema pueda construir una base de conocimiento de auditoría que permita contrastar la mayoría de las afirmaciones del tesista con el contenido de las fuentes citadas.

Se asume que el experto externo designado para la clasificación del ground truth posee los conocimientos disciplinares suficientes para emitir juicios confiables sobre la coherencia entre las afirmaciones de los tesisistas y el contenido de los papers referenciados, aplicando de manera consistente el esquema tripartito SUPPORTS, REFUTES y NO INFO de Wadden et al., 2020).

Finalmente, se parte del supuesto de que el acceso a las APIs y recursos computacionales necesarios permanecerá disponible y sin variaciones críticas en sus políticas de uso que puedan alterar el comportamiento del sistema o los tiempos de respuesta durante la fase de validación experimental.

4.2. Hipótesis general

H1: "El sistema GraphRAG de auditoría semántica alcanza una concordancia sustancial o superior con la evaluación experta (Kappa de Cohen ≥ 0.61) en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025."

H0: El sistema GraphRAG de auditoría semántica no alcanza una concordancia sustancial con la evaluación experta (Kappa de Cohen < 0.61) en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025.

Hipótesis específicas:

H1 (OE3): "El sistema GraphRAG de auditoría semántica obtiene un F1-score mayor o igual a 0.75 en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025."

H2 (OE4): "Existe concordancia sustancial o superior (Kappa de Cohen ≥ 0.61) entre las clasificaciones del sistema GraphRAG y las del experto al aplicar el esquema tripartito SUPPORTS, REFUTES y NO INFO sobre el corpus de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025."

4.3. Variable

Variable	Definición conceptual de la variable	Definición operacional de la variable	Dimensiones	Indicador	Ítems	Escala de Medición
Variable Independiente: Sistema GraphRAG de auditoría semántica	El sistema GraphRAG de auditoría semántica es una arquitectura de recuperación aumentada por grafos de conocimiento con un pipeline automatizado de detección de inconsistencias, construyendo un grafo de entidades y relaciones a partir de los papers citados en las tesis para recuperar fragmentos relevantes y emitir juicios clasificatorios sobre la consistencia de las afirmaciones del tesista (Edge et al., 2024; Han, Wang, et al., 2025).	El sistema GraphRAG de auditoría semántica se operacionaliza mediante su desempeño medido a través de dos niveles: el nivel de concordancia con el experto, evaluado mediante precisión, recall, F1-score y Kappa de Cohen comparando las clasificaciones del sistema contra el ground truth experto; y el nivel de calidad interna del sistema RAG, evaluado mediante el framework RAGAS con las métricas Faithfulness, Context Precision y Context Recall.	Desempeño de clasificación	Precisión	¿Qué proporción de las inconsistencias detectadas por el sistema son reales según el experto?	Razón (0-1)
				Recall	¿Qué proporción de las inconsistencias reales identificadas por el experto detectó el sistema?	
				F1-score	¿Qué tan equilibrado es el sistema entre precisión y recall en la detección de inconsistencias?	
			Concordancia con experto	Kappa de Cohen	¿En qué medida coinciden las clasificaciones del sistema con las del experto eliminando el efecto del azar?	Razón (-1 a 1)
			Calidad interna RAG (Indicadores Complementarios)	Faithfulness	¿El juicio emitido por el sistema es consistente con el fragmento del paper recuperado por GraphRAG?	Razón (0-1)
				Context Precision	¿GraphRAG recuperó los fragmentos del paper genuinamente relevantes para evaluar la afirmación del tesista?	
				Context Recall	¿GraphRAG recuperó todos los fragmentos relevantes del paper para evaluar la afirmación del tesista?	
Variable Dependiente: Inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025	Las inconsistencias en citas bibliográficas son desviaciones entre lo que el tesista afirma que dice una fuente y lo que la fuente realmente contiene, comprometiendo la trazabilidad y confiabilidad del conocimiento científico (Bakker et al., 2023).	Las inconsistencias en citas bibliográficas se operacionalizan mediante la distribución de clasificaciones emitidas sobre cada citación auditada, aplicando el esquema tripartito de (Wadden et al., 2020), SUPPORTS cuando el paper respalda la afirmación del tesista, REFUTES cuando la contradice, y NO INFO cuando no contiene evidencia suficiente para determinar su veracidad, produciendo tres indicadores cuantificables: tasa de citas SUPPORTS, tasa de citas REFUTES y tasa de citas NO INFO sobre el total del corpus auditado.	Validez de la cita	Tasa de citas SUPPORTS	¿Qué proporción de citas auditadas son respaldadas por el contenido real del paper referenciado?	Razón (0-1)
			Ambigüedad de la cita	Tasa de citas REFUTES	¿Qué proporción de citas auditadas son contradichas por el contenido real del paper referenciado?	Razón (0-1)
			Falsedad de la cita	Tasa de citas NO INFO	¿Qué proporción de citas auditadas no tienen evidencia suficiente en el paper referenciado para determinar su veracidad?	Razón (0-1)

4.4. Matriz de consistencia

Problemas	Objetivos	Hipótesis	Variable	Indicadores	Metodología
General	General	General	VI: Sistema GraphRAG de auditoría semántica	Precisión Recall F1-score Faithfulness Context Precision Context Recall Kappa de Cohen	Enfoque: Cuantitativo
¿En qué medida concuerda un sistema GraphRAG de auditoría semántica con la evaluación experta en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025?	Evaluar la concordancia de un sistema GraphRAG de auditoría semántica con la evaluación experta en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025.	El sistema GraphRAG de auditoría semántica alcanza una concordancia sustancial o superior con la evaluación experta (Kappa de Cohen ≥ 0.61) en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025."			Tipo de investigación: Aplicada Nivel: Explicativa Diseño de investigación: Cuasi-experimental Población: 26 tesis de Ingeniería de Sistemas de la UPAO, periodo 2024-2025 Muestra: 269 citas bibliográficas seleccionadas mediante muestreo probabilístico para población finita (95% confianza, 5% error) Tipo de muestreo: Probabilístico estratificado por tesis
Específicos	Específicos	Específicas			Unidad de análisis: Citación bibliográfica individual
PE1: ¿Cuáles son las inconsistencias presentes en el corpus de tesis de Ingeniería de Sistemas de la UPAO 2024-2025 según la clasificación experta?	OE1: Describir las inconsistencias presentes en el corpus de tesis mediante clasificación experta usando el esquema SUPPORTS, REFUTES y NO INFO.	Sin hipótesis	VD: Inconsistencias en citas bibliográficas	Tasa SUPPORTS Tasa REFUTES Tasa NO INFO	Instrumento de ground truth: Ficha de clasificación experta basada en el esquema tripartito: SUPPORTS, REFUTES y NO INFO Instrumento de evaluación del sistema: Framework RAGAS con métricas Faithfulness, Context Precision y Context Recall
PE2: ¿Cómo se desarrolla e implementa un sistema GraphRAG de auditoría semántica para la detección automática de inconsistencias en citas bibliográficas?	OE2: Desarrollar e implementar el sistema GraphRAG de auditoría semántica para la detección automática de inconsistencias en citas bibliográficas.	Sin hipótesis			Prueba estadística: Kappa de Cohen para concordancia entre sistema y experto. Shapiro-Wilk para normalidad. T de Student o Wilcoxon según distribución para F1-score
PE3: ¿Qué desempeño obtiene el sistema GraphRAG en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025?	OE3: Evaluar el desempeño del sistema GraphRAG en la detección de inconsistencias midiendo precisión, recall, F1-score y métricas RAGAS.	H1: El sistema GraphRAG obtiene un F1-score ≥ 0.75 en la detección de inconsistencias en citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025.			
PE4: ¿Qué nivel de concordancia alcanza el sistema GraphRAG con la evaluación experta en la clasificación de citas bibliográficas de tesis de Ingeniería de Sistemas de la UPAO, 2024-2025?	OE4: Medir la concordancia del sistema GraphRAG con la clasificación experta mediante Kappa de Cohen.	H2: Existe concordancia sustancial o superior (Kappa ≥ 0.61) entre las clasificaciones del sistema y las del experto al aplicar el esquema SUPPORTS, REFUTES y NO INFO.			

5. Marco metodológico

5.1. Tipo de investigación

Investigación Aplicada de acuerdo a la Orientación, Explicativa según el Nivel y Cuasi-experimental según la Contrastación.

5.2. Nivel de madurez tecnológica

"El sistema GraphRAG de auditoría semántica propuesto en la presente investigación se ubica en el Nivel de Madurez Tecnológica TRL 4, según la escala adoptada por CONCYTEC mediante la Directiva 001-2022. Este nivel corresponde a la validación del componente tecnológico en entorno de laboratorio, donde el sistema ha sido desarrollado, integrado y probado de forma controlada sobre un corpus de 269 citaciones bibliográficas extraídas de 26 tesis de Ingeniería de Sistemas de la UPAO periodo 2024-2025, demostrando su capacidad para construir un grafo de conocimiento a partir de los papers citados, recuperar fragmentos relevantes y emitir clasificaciones según el esquema SUPPORTS, REFUTES y NO INFO, sin haber sido desplegado a escala institucional completa."

5.3. Método de investigación

El método de investigación es de enfoque cuantitativo. Se basa en la recolección de datos numéricos provenientes de los indicadores de ambas variables: el desempeño del sistema GraphRAG medido mediante precisión, recall, F1-score, Kappa de Cohen y métricas RAGAS, y la distribución de clasificaciones SUPPORTS, REFUTES y NO INFO sobre el corpus de 269 citaciones bibliográficas. El análisis estadístico posterior permitirá la contrastación formal de las hipótesis mediante Kappa de Cohen y F1-score, cumpliendo con el rigor de la metodología cuasi-experimental.

5.4. Diseño del estudio

El diseño seleccionado es el cuasi-experimental con dos condiciones comparables sobre el mismo corpus controlado, representado de la siguiente manera:

G: $X1 \rightarrow O \leftarrow X2$

Donde:

G: Corpus controlado de 269 citaciones bibliográficas extraídas de 26 tesis de Ingeniería de Sistemas de la UPAO, 2024-2025.

X1: Clasificación experta mediante el esquema tripartito de Wadden et al. (2020): SUPPORTS, REFUTES y NO INFO (ground truth).

X2: Clasificación automática del sistema GraphRAG de auditoría semántica sobre el mismo corpus.

O: Medición de concordancia entre X1 y X2 mediante Kappa de Cohen, y medición de desempeño mediante precisión, recall y F1-score."

5.5. Población y muestra

La población de estudio comprende la totalidad de citaciones bibliográficas presentes en los informes de tesis de Ingeniería de Sistemas de la UPAO del periodo 2024-2025. Dado que el repositorio institucional cuenta con 26 tesis accesibles en dicho periodo, con un promedio estimado de 30 a 40 citas por tesis, la población total se estima en aproximadamente 900 citaciones bibliográficas, constituyendo una población finita y conocida.

4.4.2. Muestra

Para determinar el tamaño representativo se aplicó la fórmula de estimación de proporciones para poblaciones finitas:

$$n = (Z^2 \times p \times q \times N) / (d^2 \times (N-1) + Z^2 \times p \times q)$$

Donde:

Z = 1.96 corresponde al nivel de confianza del 95%, p = 0.5 es la probabilidad de éxito, q = 0.5 la probabilidad de fracaso, d = 0.05 el margen de error del 5% y N = 900 la población total estimada.

$$n = (3.8416 \times 0.5 \times 0.5 \times 900) / (0.0025 \times 899 + 3.8416 \times 0.25)$$

$$n = 864.36 / 3.2079$$

$$n \approx 269 \text{ citaciones bibliográficas}$$

La muestra con la que se trabajará será de 269 citas bibliográficas seleccionadas mediante muestreo probabilístico estratificado por tesis, garantizando representatividad de todas las tesis del corpus.

5.6. Técnicas e instrumentos de recolección de datos.

Técnicas: Se emplearán tres técnicas de recolección de datos. La observación documental permitirá recopilar las 26 tesis de Ingeniería de Sistemas del repositorio de la UPAO periodo 2024-2025 y extraer las 269 citas bibliográficas que conforman el corpus de análisis. El análisis de contenido automatizado se realizará mediante el sistema GraphRAG de auditoría semántica desarrollado en la presente investigación, el cual procesará cada cita para recuperar los fragmentos relevantes del paper referenciado y emitir una clasificación según el esquema SUPPORTS, REFUTES y NO INFO. La entrevista semiestructurada se mantuvo como técnica complementaria para el relevamiento de los métodos tradicionales de revisión utilizados por asesores y jurados de la facultad, cuyos resultados constituyen el diagnóstico que justifica la necesidad del sistema.

Instrumentos: Se utilizarán tres instrumentos. Primero, una Ficha de Clasificación Experta basada en el esquema tripartito de Wadden et al. (2020), donde el experto externo clasificará cada una de las 269 citas como SUPPORTS, REFUTES o NO INFO, constituyendo el ground truth oficial de la investigación. Segundo, un Reporte de Auditoría Semántica generado por el sistema GraphRAG, que registrará para cada cita la clasificación emitida y los valores de Faithfulness, Context Precision y Context Recall calculados mediante el framework RAGAS. Tercero, una Guía de Entrevista Semiestructurada dirigida a asesores y jurados de la Facultad de Ingeniería de la UPAO, orientada a identificar los métodos de revisión de citas actualmente utilizados en la práctica institucional.

5.7. Procedimientos de ejecución del estudio

Fase 1 — Recopilación y preparación del corpus: Descarga de las 26 tesis de Ingeniería de Sistemas del repositorio de la UPAO periodo 2024-2025 y conversión de los archivos PDF a texto estructurado. Extracción de las

citaciones bibliográficas y sus afirmaciones correspondientes. Selección de las 269 citas mediante muestreo probabilístico estratificado por tesis. Previamente se realizará una prueba piloto con un subconjunto de 10 tesis para validar el correcto funcionamiento del sistema antes de la ejecución a escala completa.

Fase 2 — Identificación de métodos tradicionales: Realización de entrevistas semiestructuradas a asesores y jurados de la Facultad de Ingeniería de la UPAO para caracterizar los métodos actuales de revisión de citas y establecer el diagnóstico institucional que justifica la necesidad del sistema.

Fase 3 — Construcción del ground truth: Entrega al experto externo de un Excel con las 269 citas, incluyendo para cada una la afirmación del tesisista y el fragmento correspondiente del paper referenciado. El experto clasificará cada cita como SUPPORTS, REFUTES o NO INFO según el esquema de Wadden et al. (2020), sin conocer las predicciones del sistema.

Fase 4 — Desarrollo e implementación del sistema: Diseño de la arquitectura GraphRAG, construcción del grafo de conocimiento a partir de los papers citados en las tesis, implementación del módulo de detección de inconsistencias y validación del funcionamiento con casos de prueba controlados.

Fase 5 — Ejecución de la auditoría: Aplicación del sistema GraphRAG sobre las 269 citas del corpus, registrando para cada una la clasificación emitida (SUPPORTS, REFUTES o NO INFO) y los valores de Faithfulness, Context Precision y Context Recall mediante el framework RAGAS.

Fase 6 — Contraste y análisis: Comparación estadística entre las clasificaciones del sistema y el ground truth del experto. Cálculo de precisión, recall y F1-score para contrastar H1. Cálculo del Kappa de Cohen para contrastar H2. Aplicación previa de la prueba de normalidad Shapiro-Wilk; si los datos cumplen normalidad se empleará T de Student, en caso contrario Wilcoxon, trabajando con nivel de significancia $\alpha = 0.05$ mediante Python con la librería `scipy.stats`.

Técnicas de procesamiento y análisis de datos

Para el primer objetivo, se aplicará estadística descriptiva sobre las 269 citas clasificadas por el experto, reportando la distribución de frecuencias de las categorías SUPPORTS, REFUTES y NO INFO mediante tablas y gráficos que caractericen el estado actual de las inconsistencias en el corpus.

Para el segundo objetivo, se documentará el proceso de desarrollo e implementación del sistema GraphRAG, describiendo la arquitectura construida, las decisiones de diseño adoptadas y los resultados de la prueba piloto.

Para el tercer objetivo, se calcularán precisión, recall y F1-score comparando las clasificaciones del sistema contra el ground truth experto, organizando los resultados en una matriz de confusión por categoría. Se aplicará previamente la prueba de normalidad Shapiro-Wilk; si los datos cumplen normalidad se empleará T de Student, en caso contrario Wilcoxon, con nivel de significancia $\alpha = 0.05$ mediante Python scipy.stats. Complementariamente se reportarán los valores de Faithfulness, Context Precision y Context Recall mediante RAGAS.

Para el cuarto objetivo, se calculará el Kappa de Cohen entre las clasificaciones del sistema y las del experto, interpretando el resultado según la escala de Landis y Koch (1977).

5.8. Diagnóstico institucional previo

Previo a la ejecución del experimento principal, se realizaron entrevistas semiestructuradas a tres ingenieros con experiencia como asesores y jurados de tesis en la Facultad de Ingeniería de la UPAO, con el objetivo de caracterizar los métodos actuales de revisión de citas bibliográficas y validar empíricamente la necesidad del sistema propuesto. Los hallazgos confirmaron que el proceso de verificación descansa predominantemente en la revisión manual por muestreo aleatorio y en el uso de Turnitin como única herramienta institucional, sin contemplar verificación semántica automatizada.

Análisis de convergencias y divergencias

A partir de los hallazgos obtenidos en las entrevistas realizadas es posible identificar convergencias y divergencias significativas entre los ingenieros entrevistados respecto a los métodos de revisión de citas y referencias en las tesis de ingeniería de la UPAO.

En cuanto a las convergencias, los tres ingenieros coinciden en que el proceso de revisión implica algún grado de verificación directa de las fuentes citadas y que Turnitin se emplea como herramienta complementaria sin capacidad de validación semántica. Asimismo, tanto el Ingeniero Cieza como el Ingeniero Huapaya coinciden en que no existe un instrumento formal, rúbrica o protocolo específico para verificar la precisión semántica de las citas, y ambos aplican una revisión por muestreo aleatorio. Los tres ingenieros también reconocen, en distinta medida, haber detectado o considerado posibles problemas de precisión en las citas de sus evaluados. Respecto a las divergencias, se identifican posiciones diferenciadas en cuatro dimensiones. En cuanto a la existencia de una rúbrica formal, el Ingeniero Leutria señala que sí dispone de una rúbrica que contempla la contextualización, el formato APA y el juicio crítico del citante, contrastando con la posición de los ingenieros Cieza y Huapaya, quienes coinciden en que dicho instrumento no existe. En relación con la suficiencia del tiempo disponible, el Ingeniero Cieza lo califica como insuficiente, el Ingeniero Leutria también lo considera insuficiente —señalando que supera con frecuencia los siete días asignados—, mientras que el Ingeniero Huapaya lo considera adecuado. Sobre el impacto de la inteligencia artificial generativa, los ingenieros Cieza y Leutria sostienen que ha incrementado los errores semánticos en las citas, con ejemplos concretos de ambos, mientras que el Ingeniero Huapaya considera que la IA ha mejorado la calidad de las citas. Finalmente, respecto a la profundidad de la revisión, el Ingeniero Leutria revisa la totalidad de las citas y ha desarrollado herramientas propias para sistematizar este proceso, mientras que los ingenieros Cieza y Huapaya aplican una muestra aleatoria de dos referencias por tesis.

Bloque temático	Ingeniero Segundo Cieza	Ingeniero Jorge Huapaya	Ingeniero Walter Leturia
Perfil y experiencia	Más de 10 años. Asesor y jurado. Más de 100 tesis. 30 tesis por semestre.	33 años. Asesor y jurado. Aproximadamente 4 sustentaciones por semestre.	3 años. Asesor, vocal, presidente y secretario. Entre 10–15 tesis en proyecto por ciclo; 2–3 sustentaciones formales por ciclo.
Métodos de revisión	Selección aleatoria de 2 citas. Verifica coincidencia con Zotero manualmente.	Accede a enlaces de referencias para verificar existencia. Contrasta abstract con afirmación del tesista solo por excepción.	Revisa la totalidad de las citas. Verifica formato, coherencia con la fuente y que exista juicio crítico. Usa una herramienta propia.
Uso de Turnitin	Lo usa obligatoriamente para detectar IA y porcentaje de copia. Reconoce que no valida semánticamente.	Lo usa para similitudes textuales. Menciona potencial de Scite como herramienta especializada.	No lo usa directamente; confía en la evaluación previa del asesor. Utiliza herramientas propias para detectar formulaciones generadas por IA.
Instrumentos formales	No existe rúbrica ni protocolo específico. Solo función general en reglamento de grados y títulos.	No existe. Considera que debería aplicarse en la etapa de proyecto, no en el informe final.	Cuenta con una rúbrica que evalúa contextualización correcta, formato APA y postura crítica del citante, no solo descriptiva.
Detección de errores	Frecuentemente detecta distorsión de fuentes. No ha detectado referencias inventadas por no verificar URLs.	No ha detectado distorsión ni referencias inventadas. Atribuye esto a que su revisión es por excepción.	Sí, frecuentemente. Ha identificado citas con autor y año incorrectos producto del uso irreflexivo de IA.
Suficiencia del tiempo	El tiempo es claramente insuficiente.	Suficiente.	Insuficiente. Los 7 días asignados no bastan
Impacto de la IA generativa	Ha incrementado los errores semánticos. Los estudiantes copian y pegan sin verificar.	Ha mejorado la calidad de las citas.	Ha incrementado los errores semánticos.
Utilidad de sistema automatizado	Totalmente a favor. Lo califica como herramienta maravillosa.	Defiende la revisión humana como único método válido, aunque reconoce el potencial de herramientas especializadas.	Favorable con matiz: considera que es responsabilidad compartida entre el sistema y el tesista. Ya utiliza automatización parcial en su propio flujo.
Mejoras necesarias	Normalización formal del proceso y disponibilidad de herramientas tecnológicas de apoyo.	Adopción de un modelo de revisión grupal y consensuada entre los miembros del jurado.	Mayor rigor institucional en la ponderación de las citas dentro de la rúbrica de evaluación

6. Presentación de resultados

6.1. Resultados de la investigación

6.1.1. Resultado del OE1:

- 6.1.1.1. Distribución general de clasificaciones
- 6.1.1.2. Distribución por tesis
- 6.1.1.3. Caracterización cualitativa de los tipos de inconsistencia
- 6.1.1.4. Síntesis del hallazgo

6.1.2. Resultado del OE2:

Arquitectura general del sistema


El sistema GraphRAG de auditoría semántica se estructura en tres capas principales: una interfaz frontend, una API backend, y un conjunto de servicios y bases de datos externas. El frontend, desarrollado con React y Vite, expone una página de aterrizaje y una página de auditoría organizada en pestañas que permiten visualizar la lista de citaciones, la lista de referencias, el grafo de conocimiento, el estado del motor de recuperación, los veredictos emitidos, las alertas de inconsistencias y alucinaciones, y el reporte de métricas RAGAS; esta interfaz se comunica con el backend mediante una API REST y mediante eventos enviados por el servidor (Server-Sent Events) para transmitir el progreso del procesamiento en tiempo real.

La API backend, implementada con FastAPI, organiza su lógica en cuatro grupos de rutas que se apoyan en una capa de servicios. El primer grupo, de ingesta, recibe el archivo PDF de la tesis, extrae su texto mediante PyMuPDF4LLM y dispara dos flujos asíncronos: uno de extracción, que emplea el modelo OpenAI GPT-5.4-mini para identificar las referencias bibliográficas en formato APA y las citas en el texto, cargando posteriormente esta información como un grafo de conocimiento en Neo4j; y otro de verificación, que consulta las APIs de CrossRef y Unpaywall para validar y recuperar el texto completo de las fuentes citadas, generando luego los embeddings de sus fragmentos mediante el modelo text-embedding-3-small de OpenAI y

almacenándolos en la base de datos vectorial de Supabase (pgvector). El segundo grupo de rutas expone los nodos Documento, Referencia, Autor y Cita almacenados en Neo4j, permitiendo consultar la lista de referencias y citaciones, el resumen del grafo y su visualización interactiva, además de admitir la carga manual de PDFs para referencias que el sistema no logró recuperar automáticamente. El tercer grupo corresponde al motor híbrido de recuperación GraphRAG, que combina el recorrido del grafo de conocimiento en Neo4j (siguiendo la ruta cita → referencia → DOI) con la búsqueda por similitud vectorial en Supabase, devolviendo para cada citación el fragmento del paper más relevante junto con la ruta de evidencia dentro del grafo. El cuarto grupo, de auditoría, orquesta el proceso de verificación semántica: invoca al motor híbrido de recuperación para obtener el fragmento de evidencia correspondiente, envía dicho fragmento junto con la afirmación del tesista al modelo GPT-5.4-mini para que emita un veredicto de SUPPORTS, REFUTES o NO INFO, persiste el resultado en el nodo Cita de Neo4j, detecta inconsistencias estructurales (referencias citadas en el texto pero no listadas en la bibliografía, o viceversa) y posibles alucinaciones bibliográficas, y calcula las métricas del framework RAGAS.

Finalmente, el sistema se apoya en un conjunto de servicios y recursos externos: Neo4j como base de datos de grafos, que almacena las entidades y relaciones del corpus auditado; Supabase con la extensión pgvector como base de datos vectorial para la búsqueda semántica de fragmentos; las APIs de CrossRef y Unpaywall para la validación bibliográfica y la recuperación de texto completo en acceso abierto; y la API de OpenAI, de la cual el sistema utiliza dos modelos: GPT-5.4-mini, empleado tanto para la extracción de referencias y citas como para la generación de los veredictos de auditoría, y text-embedding-3-small, empleado para generar los embeddings de los fragmentos indexados en la recuperación vectorial.

GraphRAG Auditor — System Architecture



Tecnologías y herramientas empleadas en el desarrollo del sistema

Categoría	Tecnología / Herramienta	Rol en el sistema
Frontend	React 19 + Vite	Interfaz de usuario para la carga de la tesis y visualización de resultados
Backend	Python 3.11 + FastAPI	API REST y orquestación del pipeline de auditoría
Comunicación en tiempo real	Server-Sent Events (SSE)	Transmisión del progreso del procesamiento al frontend
Base de datos de grafos	Neo4j AuraDB	Almacenamiento del grafo de conocimiento (Documento, Referencia, Autor, Cita)
Base de datos vectorial	Supabase (pgvector)	Indexación y búsqueda semántica de fragmentos de los papers referenciados
Verificación bibliográfica	Unpaywall API	Validación de existencia y metadatos de las referencias
	CrossRef API	Recuperación de texto completo en acceso abierto de los papers citados
Modelo de lenguaje (LLM)	OpenAI GPT-5.4-mini	Extracción de referencias y citas; generación de veredictos de auditoría semántica
Modelo de embeddings	OpenAI text-embedding-3-small	Generación de embeddings para la indexación vectorial de los fragmentos

6.1.2.1. Metodología de desarrollo de software aplicada

6.1.2.2. Resultado de prueba piloto

6.1.2.3. Caso ilustrativo de funcionamiento

6.1.2.4. Evidencia de ejecución

6.1.3. Resultado del OE3:

6.1.4. Resultado del OE4:

6.2. Conclusiones

6.3. Recomendaciones

7. Referencias bibliográficas

- Ansari, S. (2026). *Compound Deception in Elite Peer Review: A Failure Mode Taxonomy of 100 Fabricated Citations at NeurIPS 2025* (arXiv:2602.05930). arXiv. <https://doi.org/10.48550/arXiv.2602.05930>
- Antal, M., y Buza, K. (2025). Evaluating Open-Source LLMs in RAG Systems: A Benchmark on Diploma Theses Abstracts Using Ragas. *Acta Universitatis Sapientiae, Informatica*, 17(1), 5. <https://doi.org/10.1007/s44427-025-00006-3>
- Arévalo, M.-J., Cantera, M. A., García-Marina, V., y Alves-Castro, M. (2021). Analysis of University STEM Students' Mathematical, Linguistic, Rhetorical–Organizational Assignment Errors. *Education Sciences*, 11(4), 173. <https://doi.org/10.3390/educsci11040173>
- Bakker, C., Theis-Mahon, N., y Brown, S. J. (2023). Evaluating the Accuracy of scite, a Smart Citation Index. *Hypothesis: Research Journal for Health Information Professionals*, 35(2). <https://doi.org/10.18060/26528>
- Besrou, I., He, J., Schreieder, T., y Färber, M. (2025). *SQuAI: Scientific Question-Answering with Multi-Agent Retrieval-Augmented Generation* (Versión 1). arXiv. <https://doi.org/10.48550/ARXIV.2510.15682>
- Cabezas-Clavijo, Á., y Sidorenko-Bautista, P. (2026). Assessing the Performance of 8 AI Chatbots in Bibliographic Reference Retrieval: Grok and DeepSeek Outperform ChatGPT, but None are Entirely Accurate. *Journal of Data and Information Science*. <https://doi.org/10.1515/jdis-2025-0326>
- Chen, H., Teplitskiy, M., y Jurgens, D. (2025). *The Noisy Path from Source to Citation: Measuring How Scholars Engage with Past Research*.
- Cheng, A., Calhoun, A., y Reedy, G. (2025). Artificial intelligence-assisted academic writing: Recommendations for ethical use. *Advances in Simulation*, 10(1), 22. <https://doi.org/10.1186/s41077-025-00350-6>
- Dunford, R., Rosenblum, B., y Izzo Hunter, S. (2024). Using automated analysis of the bibliography to detect potential research integrity issues. *Learned Publishing*, 37(2), 147-153. <https://doi.org/10.1002/leap.1600>
- Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., y Larson, J. (2024). *From Local to Global: A GraphRAG Approach to Query-Focused Summarization*. <https://doi.org/10.48550/arXiv.2404.16130>
- Es, S., James, J., Espinosa-Anke, L., y Schockaert, S. (2025). *Ragas: Automated Evaluation of Retrieval Augmented Generation* (arXiv:2309.15217). arXiv. <https://doi.org/10.48550/arXiv.2309.15217>
- Fan, L., Li, L., Ma, Z., Lee, S., Yu, H., y Hemphill, L. (2024). A Bibliometric Review of Large Language Models Research from 2017 to 2023. *ACM Transactions on Intelligent Systems and Technology*, 15(5), 1-25. <https://doi.org/10.1145/3664930>

- George, H., Baratam, G., y Ds, D. (2025). *Deep Learning-Based Drug Repurposing Using Knowledge Graph Embeddings and GraphRAG*. <https://doi.org/10.64898/2025.12.08.693009>
- Gupta, V. (2020). Accuracy of references in the doctoral theses in library and information science submitted to Banasthali Vidyapith. *Annals of Library and Information Studies*. <https://doi.org/10.56042/alis.v67i3.37856>
- Haan, S. (2025). *SemanticCite: Citation Verification with AI-Powered Full-Text Analysis and Evidence-Based Reasoning* (Versión 1). arXiv. <https://doi.org/10.48550/ARXIV.2511.16198>
- Han, H., Ma, L., Wang, Y., Shomer, H., Lei, Y., Qi, Z., Guo, K., Hua, Z., Long, B., Liu, H., Aggarwal, C. C., y Tang, J. (2025). *RAG vs. GraphRAG: A Systematic Evaluation and Key Insights* (Versión 3). arXiv. <https://doi.org/10.48550/ARXIV.2502.11371>
- Han, H., Wang, Y., Shomer, H., Guo, K., Ding, J., Lei, Y., Halappanavar, M., Rossi, R. A., Mukherjee, S., Tang, X., He, Q., Hua, Z., Long, B., Zhao, T., Shah, N., Javari, A., Xia, Y., y Tang, J. (2025). *Retrieval-Augmented Generation with Graphs (GraphRAG)* (arXiv:2501.00309). arXiv. <https://doi.org/10.48550/arXiv.2501.00309>
- Hang, C. N., Yu, P.-D., y Tan, C. W. (2025). TrumorGPT: Graph-Based Retrieval-Augmented Large Language Model for Fact-Checking. *IEEE Transactions on Artificial Intelligence*, 6(11), 3148-3162. <https://doi.org/10.1109/TAI.2025.3567369>
- Hernández, R. M., Arias Chávez, D., Flores Sotelo, W. S., Arévalo Tuesta, J. A., Antón De Los Santos, P. J., Yépez Muñiz, L. A., y Lagos Videla, J. (2019). Indicadores de evaluación de citas y referencias en tesis de maestría en educación: Una muestra peruana. *Apuntes Universitarios*, 9(3), 67-84. <https://doi.org/10.17162/au.v9i3.382>
- Hu, Y., Lei, Z., Zhang, Z., Pan, B., Ling, C., y Zhao, L. (2024). *GRAG: Graph Retrieval-Augmented Generation*.
- Ipanaqué-Zapata, M., Figueroa-Quinones, J., Bazalar-Palacios, J., Arhuis-Inca, W., Quinones-Negrete, M., y Villarreal-Zegarra, D. (2023). Research skills for university students' thesis in E-learning: Scale development and validation in Peru. *Heliyon*, 9(3), e13770. <https://doi.org/10.1016/j.heliyon.2023.e13770>
- Kacena, M. A., Plotkin, L. I., y Fehrenbacher, J. C. (2024). The Use of Artificial Intelligence in Writing Scientific Review Articles. *Current Osteoporosis Reports*, 22(1), 115-121. <https://doi.org/10.1007/s11914-023-00852-0>
- Klesel, M., y Wittmann, H. F. (2025). Retrieval-Augmented Generation (RAG). *Business & Information Systems Engineering*, 67(4), 551-561. <https://doi.org/10.1007/s12599-025-00945-3>
- Liu, Y., Iter, D., Xu, Y., Wang, S., Xu, R., y Zhu, C. (2023). G-Eval: NLG Evaluation using Gpt-4 with Better Human Alignment. *Proceedings of the 2023*

Conference on Empirical Methods in Natural Language Processing, 2511-2522. <https://doi.org/10.18653/v1/2023.emnlp-main.153>

Lyu, Y., Li, Z., Niu, S., Xiong, F., Tang, B., Wang, W., Wu, H., Liu, H., Xu, T., y Chen, E. (2025). CRUD-RAG: A Comprehensive Chinese Benchmark for Retrieval-Augmented Generation of Large Language Models. *ACM Transactions on Information Systems*, 43(2), 1-32. <https://doi.org/10.1145/3701228>

Magesh, V., Surani, F., Dahl, M., Suzgun, M., Manning, C. D., y Ho, D. E. (2025). Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools. *Journal of Empirical Legal Studies*, 22(2), 216-242. <https://doi.org/10.1111/jels.12413>

Mars, M. (2022). From Word Embeddings to Pre-Trained Language Models: A State-of-the-Art Walkthrough. *Applied Sciences*, 12(17), 8805. <https://doi.org/10.3390/app12178805>

Nagori, A., Casonatto, R. A., Gautam, A., Cheruvu, A. M. S., y Kamaleswaran, R. (2025). *Open-Source Agentic Hybrid RAG Framework for Scientific Literature Review* (arXiv:2508.05660). arXiv. <https://doi.org/10.48550/arXiv.2508.05660>

Peng, B., Zhu, Y., Liu, Y., Bo, X., Shi, H., Hong, C., Zhang, Y., y Tang, S. (2024). *Graph Retrieval-Augmented Generation: A Survey* (arXiv:2408.08921). arXiv. <https://doi.org/10.48550/arXiv.2408.08921>

Perdomo, B., Portales, M., Horna, I., Barrutia, I., Villon, S., y Martinez, E. (2020). *Calidad de las tesis de pregrado en universidades peruanas* [Revista]. https://www.researchgate.net/publication/343106526_Calidad_de_las_tesis_de_pregrado_en_universidades_peruanas_Quality_of_thesis_of_undergraduate_students_from_Peruvian_universities

Roll, D. S., Kurt, Z., Li, Y., y Woo, W. L. (2025). Augmenting Orbital Debris Identification with Neo4j-Enabled Graph-Based Retrieval-Augmented Generation for Multimodal Large Language Models. *Sensors*, 25(11), 3352. <https://doi.org/10.3390/s25113352>

Samat, P. I., Wahrini, R., y Ganggang Canggih Arnanto. (2025). Competency Improvement Training in Compiling Final Thesis Assignments. *ENGAGEMENT: Jurnal Pengabdian Masyarakat*, 4(1), 1-8. <https://doi.org/10.58355/engagement.v4i1.134>

Sarmah, B., Mehta, D., Hall, B., Rao, R., Patel, S., y Pasquali, S. (2024). HybridRAG: Integrating Knowledge Graphs and Vector Retrieval Augmented Generation for Efficient Information Extraction. *Proceedings of the 5th ACM International Conference on AI in Finance*, 608-616. <https://doi.org/10.1145/3677052.3698671>

- Scaffidi, H., Hodkiewicz, M., Woods, C., y Roocke, N. (2025). *GraphRAG on Technical Documents – Impact of Knowledge Graph Schema*. <https://doi.org/10.4230/TGDK.3.2.3>
- Thakur, N., Pradeep, R., Upadhyay, S., Campos, D., Craswell, N., y Lin, J. (2025). *Support Evaluation for the TREC 2024 RAG Track: Comparing Human versus LLM Judges*. <https://doi.org/10.48550/arXiv.2504.15205>
- Turpo-Gebera, O., Martínez-Puma, E., Diaz-Zavala, R., y Rivera-Mansilla, E. (2024). Competencias investigativas docentes en la producción científica estudiantil del área de ingeniería en una universidad peruana. *European Public & Social Innovation Review*, 9, 1-17. <https://doi.org/10.31637/epsir-2024-1556>
- Wadden, D., Lin, S., Lo, K., Wang, L. L., Van Zuylen, M., Cohan, A., y Hajishirzi, H. (2020). Fact or Fiction: Verifying Scientific Claims. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 7534-7550. <https://doi.org/10.18653/v1/2020.emnlp-main.609>
- Wakeling, S., Paramita, M. L., y Pinfield, S. (2025). How do authors perceive the way their work is cited? Findings from a large-scale survey on quotation accuracy. *Journal of the Association for Information Science and Technology*, 76(10), 1396-1410. <https://doi.org/10.1002/asi.70000>
- Walters, W. H., y Wilder, E. I. (2023). Fabrication and errors in the bibliographic citations generated by ChatGPT. *Scientific Reports*, 13(1), 14045. <https://doi.org/10.1038/s41598-023-41032-5>
- Zhao, Z., Wang, Y., y Stuart, T. (2026). *LLM hallucinations in the wild: Large-scale evidence from non-existent citations*. <https://doi.org/10.48550/arXiv.2605.07723>

8. Anexos

Anexo 1. Instrumentos de recolección de datos.

Cuestionario de Entrevista

Métodos de revisión de citas y referencias en tesis de ingeniería de la UPAO

Dirigido a: Asesores y jurados de tesis de la Facultad de Ingeniería — UPAO

Instrucciones: A continuación se presentan las preguntas de la entrevista. Las respuestas serán utilizadas exclusivamente con fines académicos y de investigación. La información proporcionada es confidencial.

1. ¿Cuál es su rol en el proceso de evaluación de tesis? ¿Ha sido asesor de tesis, miembro de jurado o ambas?

Respuesta:

2. ¿Cuánto tiempo lleva evaluando tesis en ingeniería específicamente?

Respuesta:

3. ¿Cuántas tesis evalúa aproximadamente por ciclo o semestre?

Respuesta:

4. ¿Utiliza algún método o herramienta específica para verificar las citas y referencias de las tesis que evalúa? ¿Cómo lo realiza?

Respuesta:

5. ¿Cuántas citas revisa aproximadamente por cada tesis?

Respuesta:

6. ¿Utiliza Turnitin o algún otro software de similitud textual como parte del proceso de validación de las citas?

Respuesta:

7. ¿Existe en la UPAO algún instrumento formal, rúbrica o protocolo para verificar la precisión semántica de las citas?

Respuesta:

8. ¿Ha detectado casos donde algún tesista ha distorsionado o tergiversado el contenido de la fuente citada?

Respuesta:

9. ¿Ha encontrado alguna vez referencias bibliográficas inventadas o con datos incorrectos?

Respuesta:

10. ¿Considera que el tiempo disponible para revisar una tesis es suficiente para verificar el contenido de las citas? (Escala del 1 al 5, donde 1 es totalmente en desacuerdo y 5 totalmente de acuerdo)

Respuesta:

11. ¿Considera que el uso de inteligencia artificial generativa ha incrementado la cantidad de errores semánticos en las citas de las tesis?

Respuesta:

12. ¿Considera que sería útil contar con un sistema automatizado que verifique si las fuentes citadas realmente respaldan las afirmaciones del tesista?

Respuesta:

13. ¿Considera que la falta de un instrumento formal de validación semántica representa un riesgo para la integridad científica de las tesis?

Respuesta:

14. ¿Cómo describe su proceso actual de revisión de citas y referencias de una tesis?

Respuesta:

15. ¿Qué mejoras consideraría necesarias en los procesos actuales de verificación de citas y referencias en la UPAO?

Respuesta:

Anexo 2. Transcripciones de entrevistas

Transcripción de Entrevista

Entrevistado: Segundo Cieza

Entrevistador: Matías Felipe Alcalde Lavado

Entrevistador: Buenas tardes, profesor. Me llamo Matías Felipe Alcalde Lavado. El día de hoy vengo a hacerle una entrevista para poder recopilar información acerca de los métodos o técnicas que se utilizan actualmente para validar semánticamente las citas en los informes de tesis, en las tesis de ingeniería.

Entrevistador: Bueno, para iniciar, quisiera saber si usted me da el permiso para utilizar esta grabación para poder completar con mis objetivos.

Segundo Cieza: Sí, sí, sí, claro. Siempre y cuando no lo proyectes ante un jurado, ante usted, es para ti nada más.

Entrevistador: Para mí, sí.

Segundo Cieza: Ok.

Entrevistador: Ok, bueno, primera pregunta. Quisiera saber cuál es su rol en el proceso de las evaluaciones de tesis. ¿Ha sido asesor de tesis, miembro de jurado o ambas?

Segundo Cieza: Sí, bueno, ya tengo bastante tiempo siendo jurado como asesor, ¿no? Más experiencia es como asesor. Tengo bastantes, bastantes ya tesis y ahí tú lo puedes ver en mi CTI Vitae, ¿no? Más de 100, inclusive.

Entrevistador: ¿Cuánto tiempo lleva evaluando tesis en ingeniería específicamente?

Segundo Cieza: ¿Cuánto tiempo? Estamos más o menos hablando del año 2014, 2014. Estaríamos hablando de más de 10 años.

Entrevistador: Estaríamos hablando de más de 10 años.

Segundo Cieza: Sí, más de 10 años, sí, claro, más de 10 años.

Entrevistador: ¿Cuántas tesis se evalúa aproximadamente por ciclo o por semestre?

Segundo Cieza: Bueno, en la universidad, pues a mí me asignan, ¿no? Unos, dentro del proceso del curso, por ejemplo, proyecto de investigación, TET-1, estamos hablando de un promedio de 30, 30.

Entrevistador: ¿30 cada semestre?

Segundo Cieza: 30 cada semestre. 30, ¿no? Porque es parte del curso, es parte del curso. Sí, y tengo varias secciones, más o menos son 30.

Entrevistador: ¿Utiliza algún método o herramienta específica para verificar las citas y las referencias de las tesis que evalúa?

Segundo Cieza: Bueno. Yo de forma obligatoria les digo que utilicen un software de gestión de citas y referencias como el Zotero, esa es la primera. Y luego la verificación lo hago manual, no lo hago con inteligencia artificial.

Entrevistador: ¿Cómo lo realiza?

Segundo Cieza: Lo que hago yo, de todas las citas que tienen, yo elijo al azar, ¿no? Al azar dos, de las 30 que tengan. Y les digo, a ver, muéstrame el Zotero, que debe estar marcado y leo, ¿no? Si lo que ha dicho el autor en el Zotero, en ese artículo marcado, coincide con lo que tú has parafraseado. Y esa es mi evaluación, de esa forma lo hago.

Entrevistador: Claro, entonces a la siguiente pregunta ya me la contestó, que sería ¿cuántas citas revisa aproximadamente por cada tesis? Me dice que un promedio de dos, ¿no?

Segundo Cieza: Dos. Dos al azar.

Entrevistador: Al azar.

Segundo Cieza: Al azar.

Entrevistador: ¿Utiliza Turnitin o algún otro software de similitud textual como parte del proceso de la validación de las citas?

Segundo Cieza: Sí, todo. Bueno, las citas no tanto, no se valida con el Turnitin. Se valida la redacción, las coincidencias, ¿no? Con respecto al parafraseo, ¿no? El porcentaje de copia, ¿no? Entonces sí utiliza Turnitin de forma obligatoria.

Entrevistador: ¿Y en la UPAO existe algún instrumento formal, rúbrica o protocolo para verificar la precisión semántica de las citas?

Segundo Cieza: No. No, no. Porque existe un reglamento que te dice que el asesor cumple el tema de poder evaluar ese documento. Que esté bien, que cumpla con el tema ético, ¿no? Es un rol, es como una función. Está en el reglamento de grados y títulos. Pero no específicamente qué es lo que tengo que hacer. No, no existe eso. Existe una función, ¿no? O sea, tengo que verificar que el documento se haya elaborado de forma ética y que cumpla con el tema de las citas, el tema de redacción, ¿no? Eso es lo que dice.

Entrevistador: ¿Ha detectado casos donde algún tesista ha distorsionado o tergiversado el contenido de la fuente citada?

Segundo Cieza: Por supuesto, ¿no? Generalmente eso es lo que yo encuentro, ¿no? Cuando hago este tipo de evaluaciones, ¿no? Eligiendo esos dos al azar veo que a veces no cumple. Entonces ahí, ¿qué ocurre? Ocurre que el estudiante no es... Se saca pues una media, ¿no? Y mira, si en las dos que he corregido están mal, se supone que lo demás también tiene que corregir, ¿no?

Entrevistador: ¿Y ha encontrado alguna vez referencias bibliográficas inventadas?

Segundo Cieza: Mmm. No, no, no, no.

Entrevistador: ¿Con datos incorrectos?

Segundo Cieza: Claro, con datos incorrectos sí, pero inventadas no, no, no. Porque no hago la verificación de la cita. No le hago clic, ¿no? Para poder ver la URL, no, no lo hago.

Entrevistador: ¿Considera que el tiempo disponible para revisar una tesis es suficiente para verificar el contenido de las citas? Del 1 al 5, donde 1 sería totalmente en desacuerdo y 5 totalmente de acuerdo.

Segundo Cieza: No, desacuerdo. No, no, el tiempo es corto. No, no, no. Es 1. 1, 1.

Entrevistador: ¿Considera que el uso de inteligencia artificial generativa ha incrementado la cantidad de errores semánticos en las citas de las tesis?

Segundo Cieza: Por supuesto, totalmente de acuerdo. Sobre todo cuando se dice a veces sí o sí, ¿no? Sí, por eso que yo les digo a los estudiantes que deben utilizar la inteligencia artificial, pero de forma responsable. O sea, pero algunos copian y pegan y ahí se complica. Me doy cuenta porque lo que presentan no está en la forma de redacción que yo pido, ¿no?

Entrevistador: ¿Considera que sería útil contar con un sistema automatizado que verifique si las fuentes citadas realmente respaldan las afirmaciones del tesista?

Segundo Cieza: Por supuesto, pues es una herramienta maravillosa, pues que a mí lo suba al documento y me saque, perfecto.

Entrevistador: ¿Considera que la falta de un instrumento formal de validación semántica representa un riesgo para la integridad científica de las tesis?

Segundo Cieza: Bueno, el problema es que existe un alto índice de tesis que están mal elaboradas, ¿correcto? Por lo tanto, pues sí es un riesgo fuerte.

Entrevistador: ¿Cómo describe usted su proceso actual de revisión de citas y referencias de una tesis? ¿Un flujo simplificado?

Segundo Cieza: Bueno, flujo. El tesista sube su trabajo al Turnitin. Lo que yo hago en el Turnitin es verificar que no tenga IA. Si tiene IA, lo mando a que corrija. Si hubo un trabajo con menos del 20% que se impone en la universidad, lo que

hago es empezar a revisar párrafo por párrafo. A ojo, veo, elijo un párrafo al azar, ¿no? Y sobre eso evalúo. Finalmente, el estudiante, si no cumplió, si las dos referencias no están correctas, entonces simplemente lo mando a corregir.

Entrevistador: Bueno, última pregunta. ¿Qué mejora consideraría necesaria en los procesos actuales de verificación de las citas y referencias en la UPAO?

Segundo Cieza: Bueno, que esté normado. Primero, para poder tener un respaldo. Porque antes dicen, oye, pero no, ¿por qué lo haces así? No está normado. Es un respaldo ahí. Lo otro es que si tengo una herramienta, ¿no? Para poder hacer una herramienta para formar.

Entrevistador: Bueno, eso sería todo, profesor. Muchísimas gracias por su tiempo.

Segundo Cieza: Listo, Matías. Un gusto.

Transcripción de Entrevista

Entrevistado: Jorge Huapaya

Entrevistador: Matías Felipe Alcalde Lavado

Entrevistador: Buenas noches profesor, me llamo Matías Felipe Alcalde Lavado, el día de hoy vengo a hacerle una encuesta para cumplir con uno de los objetivos de mi tesis, específicamente conocer un poco sobre las técnicas o herramientas que se utilizan a día de hoy para validar la precisión semántica de las citas en los informes de tesis.

Entrevistador: Entonces, primero preguntarle si nos da autorización para grabar y para poder...

Jorge Huapaya: Sí, está bien.

Entrevistador: Listo. En ese caso, empezaríamos con la primera pregunta. Quería saber cuál es su rol en el proceso de evaluación de tesis. ¿Usted ha sido asesor de tesis, ha sido jurado o ambos?

Jorge Huapaya: En ambos, ambos.

Entrevistador: ¿Y cuántos años ha cumplido este rol?

Jorge Huapaya: 33 años que tengo en la universidad.

Entrevistador: ¿Los 33 años ha sido...?

Jorge Huapaya: Sí, todos los semestres ahí. O rol de asesor o rol de jurado y a veces en algunos casos, ambos, ¿no? Algunos semestres, digo, ¿no?

Entrevistador: ¿Actualmente está cumpliendo o ejerciendo alguno de estos roles?

Jorge Huapaya: Claro, el viernes tengo una sustentación de tesis y los invito a las 8 de la mañana.

Entrevistador: ¿Y cuántas tesis se evalúan aproximadamente por ciclo, por semestre?

Jorge Huapaya: Bueno, particularmente en forma individual, yo a veces tengo cuatro sustentaciones, ¿no? Ya sea de mis asesorados o de como miembro del

jurado. Pero evidentemente la cantidad de sustentaciones es más, ¿no? En promedio yo no tengo muchas, yo tengo pocas.

Entrevistador: ¿Actualmente usted utiliza algún método o una herramienta específica para verificar las citas y las referencias de las tesis que evalúa?

Jorge Huapaya: No, herramientas no, solamente utilizo el documento que se me entrega, accedo a los enlaces que se mencionan en el documento, en las referencias bibliográficas, y ahí verifico que existe, por el principio que existe el libro, ¿no? Que existe la referencia o la revista. Y como generalmente las tesis hacen una recopilación de lo que dice el abstract o el resumen del documento, entonces es fácil de verificar, ¿no? Y no es al 100%, sino una especie de una muestra, ¿no? Una muestra aleatoria, ¿no? Y luego de eso digo, le doy validez. Y además aplicamos el Turnitin para chequear también copia o algo por el estilo, y además también ahí hace referencia a las citas y también a través de ella ingresamos.

Entrevistador: ¿Actualmente en la UPAO existe algún instrumento formal, una rúbrica o protocolo institucional para verificar la precisión de las citas?

Jorge Huapaya: No. Solo para la evaluación de, en general, los contenidos, ¿no? Ya sea el problema, la hipótesis, la operación de las variables, el informe o los resultados, en qué medida se han cumplido los objetivos, las conclusiones, la recomendación. Pero para medir o evaluar las citas, no. Eso quizás se tenga que referir en el proyecto de investigación. Porque el proyecto de investigación ya debe incluir las citas, porque ahí debe estar el marco teórico que se va a usar. El marco teórico y conceptual. Ahí es donde debe ponerse o aplicarse una rúbrica, si fuera el caso. Ya en el informe, no, pues ya se supone que ha utilizado eventualmente, como mínimo, las citas referenciadas en el proyecto.

Entrevistador: De la escala del 1 al 5, siendo 1 nunca, 2 casi nunca, 3 a veces, 4 casi siempre y 5 siempre. Primero, ¿verifica usted si la fuente citada realmente respalda la afirmación del tesista?

Jorge Huapaya: A veces.

Entrevistador: ¿Accede al artículo o documento original para contrastar su contenido con lo que afirma el tesista?

Jorge Huapaya: A veces, pero solamente por excepción, pues, no de todas las citas.

Entrevistador: ¿Ha encontrado algún caso donde el tesista distorsiona o tergiversa el contenido de la fuente citada?

Jorge Huapaya: No.

Entrevistador: ¿Se verifica o ha verificado si las referencias citadas realmente existen en bases de datos académicas?

Jorge Huapaya: Sí, porque generalmente se les exige que sean bases o referencias de los últimos 5 años. Y en algunos casos se está exigiendo que sean Q1 o Q2, ¿no? Que tengan un nivel de calidad aceptable.

Entrevistador: ¿Ha detectado en algún momento referencias bibliográficas inventadas o con datos incorrectos?

Jorge Huapaya: No.

Entrevistador: Del 1 al 5, donde 1 es totalmente en desacuerdo y 5 totalmente de acuerdo, ¿es suficiente el tiempo para revisar una tesis actualmente?

Jorge Huapaya: Sí.

Entrevistador: ¿Considera que la verificación manual de las citas es un proceso que demanda demasiado tiempo y recursos?

Jorge Huapaya: Necesariamente tiene que ser así porque no hay otra forma de hacer una revisión. Con la IA, etcétera, no es válido, aquí tiene que ser una revisión de la persona. La IA puede dar opinión sobre de repente un trabajo excelente o lo contrario, entonces comienza a alucinar la IA. Tiene que ser en base al conocimiento que existe acá en la universidad y que se supone que está en el poder o en posesión de los docentes.

Entrevistador: ¿Considera que el uso de inteligencia artificial generativa ha incrementado los errores semánticos en las citas de las tesis?

Jorge Huapaya: No, al contrario, creo que los ha mejorado.

Entrevistador: ¿Turnitin o alguna otra herramienta de similitud textual considera que es suficiente para detectar problemas de precisión en las citas?

Jorge Huapaya: Puede ser el uso de la IA para efectos de, por ejemplo, Scite, es una IA que garantiza y verifica que las citas sean correctas, te dice y te avisa si hay alguna cita que no es correcta o que no existe. Es excelente esa IA, eso con buena cuenta podría ser una herramienta que sea implementada formalmente para verificar el sistema de las citas.

Entrevistador: ¿Considera que la falta de un instrumento formal de validación semántica representa un riesgo para la integridad científica de las tesis?

Jorge Huapaya: No, la investigación pues no se sustenta solamente en la semántica. La sustentación es en la propuesta y el desarrollo de la propuesta o del trabajo propiamente dicho. La semántica es una cosa que eventualmente puede estar rigurosamente utilizada para trabajos de carácter social, literario o publicaciones que tengan que ver con la imagen de la institución o de la universidad, o la reputación. Esas publicaciones deberían pasar por ese tipo de revisiones semánticas para que no sean publicadas y meden la imagen o la reputación de la institución.

Entrevistador: ¿Cómo describe usted su proceso actual para la revisión de citas y referencias de una tesis?

Jorge Huapaya: Bueno, actualmente cada jurado, cada miembro del jurado hace las revisiones de manera particular. La revisión debería ser, creo que, de manera grupal. El trabajo es una especie de juicio de expertos pero todos a la vez, es una sesión única en la que después de la reunión salen las observaciones y se llena una sola rúbrica, una sola, que es consecuencia del consenso de los miembros del jurado. Naturalmente cada miembro tiene que hacer una revisión previa. Repito, hace el uso de su rúbrica cada uno por su cuenta y después para llegar a consensos. Entonces ahí se genera pues una especie de desconcierto entre citas, el jurado A le dice eso está bien, el jurado B le dice esto no está bien, ¿qué cosa está bien? Entonces ahí se genera el desconcierto. Cuando se hace el trabajo en equipo, en grupo, ya no hay desconcierto porque es una sola opinión, es un acta que firman los tres miembros del jurado y la calificación es única.

Entrevistador: Bueno, ahí ya respondió la última pregunta, que era ¿qué mejora considera necesaria para los procesos actuales de verificación?

Jorge Huapaya: Eso, ya lo estaba mencionando. Tenemos que llegar a un punto de consenso.

Entrevistador: Eso sería todo profesor, muchísimas gracias.

Jorge Huapaya: Muy bien, encantado.

Transcripción de Entrevista

Entrevistado: Walter Leutria

Entrevistador: Matías Felipe Alcalde Lavado

Entrevistador: Buenas noches, ingeniero. Vengo a realizarle hoy una breve entrevista acerca de cómo es que usted realiza la revisión de citas y referencias en tesis de ingeniería en la UPAO.

Entrevistador: Primera pregunta: quisiera saber cuál es su rol o cuál ha sido su rol en el proceso de evaluación de tesis. ¿Ha sido asesor o miembro de jurado, o ambas?

Walter Leutria: He sido asesor, vocal, presidente y secretario. Los cuatro roles.

Entrevistador: ¿Cuánto tiempo lleva evaluando tesis o siendo asesor en ingeniería específicamente?

Walter Leutria: Tres años, el mismo tiempo que tengo de docente.

Entrevistador: ¿Y cuántas tesis aproximadamente evalúa por ciclo?

Walter Leutria: Uy, por ciclo, en proyecto de tesis, que son las que más vienen, suelen ser en promedio casi unos 10, 15 quizás, pero que si vienen a sustentar como tesis en promedio para mí son solo 2 a 3 por ciclo.

Entrevistador: ¿Cuántas citas revisa aproximadamente por cada tesis?

Walter Leutria: Todas.

Entrevistador: ¿Cada una de las citas?

Walter Leutria: Todas.

Entrevistador: ¿Utiliza Turnitin o algún otro software de similitud textual como parte del proceso de la validación?

Walter Leutria: No, eso confiamos en la evaluación que realiza el asesor. Lo que yo hago es validar primero que la cita esté correctamente formulada y entro a los documentos y veo que la información sea coherente con lo que se presenta.

Entrevistador: ¿Actualmente existe en la UPAO algún instrumento formal, una rúbrica o un protocolo para verificar la precisión semántica de las citas?

Walter Leutria: Claro. Tenemos una rúbrica que nos ayuda a entender si la cita está correctamente contextualizada, si está correctamente en el formato APA y sobre todo si es que la postura del autor, en este caso de la investigación, es una postura crítica, no solo descriptiva o tratando de resumir las ideas del autor.

Entrevistador: ¿Ha detectado algún caso donde el tesista haya distorsionado o tergiversado el contenido de la fuente citada?

Walter Leutria: Sí, esta semana justo: 17 referencias no se encontraban en el documento, 13 referencias no tenían como tal un juicio crítico. Es decir, por darles un ejemplo, mencionaban sobre cómo es que el sistema tenía escalabilidad y al final citaban un paper relacionado a base de datos. O sea, mencionaban una cosa y ponían al final según tres autores que coincidían su cuestión de capacidad. No es la forma de citar.

Entrevistador: ¿Considera que el tiempo disponible para revisar una tesis es suficiente para verificar el contenido de las citas?

Walter Leutria: No, nos dan solo 7 días y siempre me demoro más. Yo suelo demorarme entre 10, a veces 12 días, dependiendo. Si es en exámenes o en últimas semanas que subimos notas, sí me suelo demorar muchos días más y siempre pido disculpas por el caso. Sé que debemos atender cuanto antes, pero la revisión no puede ser únicamente una revisión al paso, tiene que ser detallada; es un documento formal de investigación.

Entrevistador: ¿Considera que el uso de inteligencia artificial generativa ha incrementado la cantidad de errores semánticos en las citas de las tesis?

Walter Leutria: Sí. Justo una tesis que estoy revisando ahora, conversando con el asesor: colocaron un segundo autor, ponen el nombre del autor, el año 2017, y las ideas son correctas, o sea, ni siquiera leyeron lo que pegaron; lo pasaron a GPT, lo pegaron tal cual. Yo utilizo herramientas también para detectar este tipo de formulaciones y me ayudan, porque leer el documento sí lo hago completo, pero a veces por el cansancio uno pasa algo por alto. Asumo que es lo que les ha pasado a mis colegas, pero eso trato de poner énfasis siempre en estas partes.

Entrevistador: ¿Considera que sería útil contar con un sistema automatizado que verifique si las fuentes citadas realmente respaldan las afirmaciones del tesista?

Walter Leutria: Acá depende mucho. Considero que es un rol de ambas partes. El tesista debe tener en cuenta que lo que está haciendo es un documento académico y debería presentar la seriedad del caso. Teniendo en cuenta que también nuestros nombres van ahí aprobando, desaprobando, dando sugerencias, debemos tener en cuenta que no es únicamente aprobarlo por aprobarlo, sino que tenemos que darles las herramientas para que puedan mejorar esta parte. A veces recomiendo incluir bibliografía cuando tengo el tiempo o es un tema de mucho interés, les recomiendo bibliografía complementaria.

Entrevistador: ¿Cómo describe su proceso actual de revisión de citas y referencias en una tesis, brevemente?

Walter Leutria: Normalmente lo que hago es primero verificar que sea el formato correcto de todas las citas, me tomo un tiempo de entre 1 y 2 horas. Después de revisarlas, tengo una herramienta que me facilita bastante el uso; he creado un skill propio en Claude, porque antes me tomaba mucho tiempo entrar en la cita y sacar un extracto, el abstract como tal. Tengo una tablita que me genera Claude

con la cita, cómo la han colocado en el documento, el párrafo exacto y lo que dice como tal, en este caso el DOI o el link de referencia. Entonces cuando falta, es un indicador y lo reviso manualmente. Antes lo hacía todo a mano, me tomaba casi 2 a 3 días solo en la parte de citas, que creo que pesa algo de 10 puntos como máximo. Ahora como ya lo hago un poco automatizado, mi tarea es más la lectura del documento completo mientras sale esa tablita, y luego verificar donde mi herramienta no logra detectar.

Entrevistador: ¿Y qué mejoras consideraría necesarias en los procesos actuales de verificación de citas y referencias en la UPAO?

Walter Leutria: Más rigor, más rigor. Como te digo, son solo 10 puntos y para una rúbrica de tesis me parece que tiene 50 y algo puntos, entonces casi no tiene el peso necesario. Teniendo en cuenta que es el primer documento académico, es la base, es el pilar; ustedes son bachilleres, no están planteando nuevos teoremas, están utilizando herramientas existentes. Se basan en la lectura, la documentación y el juicio crítico sobre esto. Ahí considero que deberíamos ser un poco más rigurosos.

Entrevistador: Bueno, eso sería todo, muchísimas gracias, profesor.

Walter Leutria: De nada. Gracias.

Anexo 2. Evidencias de la ejecución de la investigación.

Anexo 3. Resolución de aprobación dl proyecto de investigación.

Anexo 4. Constancia de autorización y asentimiento de la organización.

Anexo 5. Constancia del asesor.

Anexo 6. Metodología de desarrollo de software.