

UNIVERSIDAD PRIVADA ANTENOR ORREGO
FACULTAD DE INGENIERÍA
PROGRAMA DE ESTUDIO DE INGENIERÍA DE SISTEMAS E INTELIGENCIA
ARTIFICIAL



TESIS PARA OPTAR EL TÍTULO PROFESIONAL DE
INGENIERO COMPUTACIÓN Y SISTEMAS

**Evaluación de la exactitud funcional de un intérprete semántico en bases de
datos relacionales usando Procesamiento de Lenguaje Natural**

Línea de Investigación: Robótica, automatización avanzada y sistemas inteligentes.

Sub - línea de Investigación: Sistemas inteligentes

Autores:

Medina Villena Danna Ayelén

Reátegui Licham Steven

Jurado evaluador:

Presidente: Urrelo, Vladimir

Secretario: Diaz, Jaime

Vocal: Castillo, Edward

Asesor:

Cueva Chavez, Walter Manuel

Código Orcid: <https://orcid.org/0000-0001-9660-6354>

TRUJILLO - PERÚ

2026

Fecha de sustentación:

MARCAR MODALIDAD: ☒ P ☐ SP ☐ D

Dedicatoria

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones.

Apellidos y Nombres del (la) autor (a) 1

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones.

Apellidos y Nombres del (la) autor (a) 2

Agradecimiento

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones

El texto expositivo es aquel texto que ofrece al lector una información explícita sobre un tema puntual, de manera objetiva, es decir, sin que medie en ningún momento la opinión del autor o sus posicionamientos. En consecuencia, tampoco necesita utilizar argumentaciones para convencer. Textos expositivos divulgativos. Son aquellos que están dirigidos a un público amplio, sin requerimientos previos especializados, y, por lo tanto, abordan temas de interés general, usualmente desde una perspectiva relativamente simple. Sus oraciones

Los (as) autores (as).

Resumen

La presente investigación, de diseño tecnológico evaluativo bajo el paradigma Design Science Research (DSR), tuvo como objetivo evaluar la exactitud funcional de un intérprete semántico en la traducción de peticiones de lenguaje natural a código SQL. Para ello, se implementó un protocolo de ejecución automatizada cruzada directamente sobre un motor de base de datos, utilizando el modelo Qwen2.5-Coder-3B-Instruct (cuantizado a 4-bit) y una muestra estratificada de 96 consultas extraídas del benchmark internacional Spider, divididas equitativamente en tres niveles de complejidad sintáctica y relacional (Baja, Media y Alta). Los resultados globales evidenciaron un desempeño algorítmico moderado, alcanzando una exactitud de ejecución de 61.46% y un F1-Score global de 61.10%, derivado de una precisión de 79.43% y un recall crítico de 49.64%. El análisis estadístico inferencial (prueba de Kruskal-Wallis, $p = 0.0645$) demostró que no existe una caída de rendimiento lineal inversamente proporcional a la complejidad, obteniendo el mejor desempeño en el nivel medio (F1-Score de 80.40%). Mediante técnicas de clustering multivariado, se determinó que la deficiencia principal del algoritmo radica en la omisión de información (282 falsos negativos) producto de vulnerabilidades en el emparejamiento de entidades (schema linking) y desajustes léxicos, más que en la intrincación estructural de la consulta. Se concluye que el modelo evaluado no supera el umbral competitivo del 85%, demostrando que aún carece de la madurez técnica necesaria para operar de forma autónoma sin supervisión humana en entornos relacionales del mundo real.

Palabras clave: intérprete semántico; Text-to-SQL; procesamiento de lenguaje natural; exactitud de ejecución; schema linking; benchmark Spider.

Abstract

The present research, employing an evaluative technological design under the Design Science Research (DSR) paradigm, aimed to evaluate the functional accuracy of a semantic interpreter in translating natural language requests into SQL code. To this end, an automated cross-execution protocol was implemented directly on a database engine, utilizing the Qwen2.5-Coder-3B-Instruct model (4-bit quantized) and a stratified sample of 96 queries extracted from the international Spider benchmark, equally divided into three levels of syntactic and relational complexity (Low, Medium, and High). Global results showed moderate algorithmic performance, achieving an execution accuracy of 61.46% and a global F1-Score of 61.10%, derived from a precision of 79.43% and a critical recall of 49.64%. Inferential statistical analysis (Kruskal-Wallis test, $p = 0.0645$) demonstrated that there is no linear performance drop inversely proportional to complexity, obtaining the best performance at the medium level (80.40% F1-Score). Through multivariate clustering techniques, it was determined that the algorithm's main deficiency lies in information omission (282 false negatives) caused by entity matching vulnerabilities (schema linking) and lexical mismatches, rather than the structural intricacy of the query. It is concluded that the evaluated model does not surpass the 85% competitive threshold, demonstrating it still lacks the necessary technical maturity to operate autonomously without human supervision in real-world relational environments.

Keywords: semantic interpreter; Text-to-SQL; natural language processing; execution accuracy; schema linking; Spider benchmark.

Presentación

Señores miembros del jurado:

De acuerdo con el cumplimiento de las disposiciones del reglamento de grados y títulos de la Universidad Privada Antenor Orrego, exponemos a vuestra consideración la tesis titulada: Evaluación de la exactitud funcional de un intérprete semántico en bases de datos relacionales usando Procesamiento de Lenguaje Natural.

Desarrollado con el fin de obtener el título de Ingeniero de Computación y Sistemas. El objetivo principal es evaluar la exactitud funcional de la traducción del intérprete semántico mediante un protocolo de ejecución automatizada y el análisis de las métricas de precisión, recall y F1-Score, en función de los niveles de complejidad sintáctica y relacional.

A ustedes miembros del jurado, mostramos nuestro especial y mayor reconocimiento por el dictamen que se haga merecedor y correspondiente del presente trabajo.

Medina Villena Danna Ayelén

DNI:

ORCID:

Reátegui Licham Steven

DNI:

ORCID:

Índice de contenidos

Dedicatoria	2
Agradecimiento	3
Resumen	4
Abstract	5
Presentación	6
Índice de contenidos	8
Índice de tablas	10
Índice de figuras	11
1. Introducción	12
1.1. Contexto y antecedentes	12
1.2. Descripción y justificación del estudio	13
1.3. Organización del documento	15
2. Planteamiento del problema de investigación	17
2.1. Descripción y delimitación del problema	17
2.2. Objetivos de la investigación	19
2.3. Importancia del estudio	20
2.4. Justificación de la investigación	21
2.5. Limitaciones del estudio	25
3. Marco de referencia	27
3.1. Marco histórico	27
3.2. Investigaciones antecedentes relacionadas con el tema	28
3.3. Base teórica – científica	48
3.4. Definición de términos básicos	52
4. Hipótesis y variables	55
4.1. Supuestos básicos	55
4.2. Hipótesis general	56
4.3. Hipótesis específicas	56
4.4. Variables	58
4.5. Matriz de consistencia	60
5. Marco metodológico	62
5.1. Tipo de investigación	62
5.2. Nivel de madurez tecnológica	62
5.3. Método de investigación	62
5.4. Diseño del estudio	63
5.5. Población y muestra	63
5.6. Técnicas e instrumentos de recolección de datos	65
5.7. Procedimientos de ejecución del estudio	67
5.8. Técnicas de procesamiento y análisis de datos	69
6. Presentación de resultados	72
6.1. Resultados de la investigación	72

6.2. Discusión de resultados	85
6.3. Conclusiones	94
6.4. Recomendaciones	97
7. Referencias bibliográficas	98
8. Anexos	101

Índice de tablas

Tabla 1. Operacionalización de variables.	17
Tabla 2. Matriz de consistencia de la investigación.	18

Índice de figuras

Figura 1. Diseño con posprueba únicamente y grupo de control.	24
---	----

1. Introducción

1.1. Contexto y antecedentes

En la era actual, las bases de datos relacionales constituyen el pilar fundamental para el almacenamiento, gestión y análisis de información en prácticamente todos los sectores. Sin embargo, la extracción de estos datos exige un conocimiento técnico avanzado en lenguajes estructurados como SQL, lo que impone una barrera de entrada significativa para los usuarios no expertos. Esta limitación genera una fuerte dependencia hacia intermediarios técnicos y especialistas en datos, ralentizando el proceso de toma de decisiones operativas y estratégicas, además de producir un cuello de botella operativo cuantificable (Elgohary et al., 2020). Al respecto, estudios tecnológicos evidencian que el uso de interacciones basadas en lenguaje natural para la extracción de información llega a ser hasta 6.7 veces más rápido que los métodos convencionales de entrada para la generación de consultas a bases de datos (Baig et al., 2022). Dimensionando la urgencia de cerrar esta brecha de accesibilidad, analistas de la industria como Gartner Inc. proyectan que la adopción de interfaces en lenguaje natural y chatbots se convertirá en el canal principal de servicios e interacción de datos para aproximadamente una cuarta parte de las organizaciones para el año 2027 (Kanburoğlu & Tek, 2024). Para democratizar el acceso a la información y eliminar este cuello de botella, el desarrollo de interfaces de lenguaje natural para bases de datos se ha convertido en una solución clave, cuyo objetivo es permitir a los usuarios consultar bases de datos complejas formulando sus necesidades directamente en lenguaje natural.

El estado del arte en la traducción de lenguaje natural a SQL ha evolucionado notablemente, transitando desde los primeros sistemas basados en reglas o coincidencia de patrones hasta llegar a arquitecturas modernas impulsadas por el aprendizaje profundo y los grandes modelos de lenguaje (Abedini, 2026). A pesar de estos avances técnicos, la traducción precisa sigue presentando desafíos

críticos, especialmente al enfrentarse a esquemas de bases de datos masivos y consultas multitabla que requieren operaciones complejas, agrupaciones o subconsultas. El riesgo de interpretaciones erróneas algorítmicas ha evidenciado que las métricas de evaluación tradicionales, como la coincidencia exacta o también conocida como “exact match” de cadenas de texto, resultan insuficientes y propensas a generar falsos negativos al penalizar consultas que son semánticamente válidas pero sintácticamente distintas (Pourreza & Rafiei, 2023).

Ante esta problemática, la comunidad científica ha establecido la necesidad de utilizar herramientas y protocolos de evaluación deterministas que reflejen escenarios del mundo real. Actualmente, el benchmark internacional Spider se ha consolidado como el estándar de oro para medir la generalización de estos modelos en entornos de dominio cruzado, debido a que clasifica de forma intrínseca las consultas en distintos grados de dificultad sintáctica y relacional (Lima et al., 2025). Para garantizar la fiabilidad del sistema y la autonomía del usuario final sin riesgo de recuperar datos incorrectos, la validación del desempeño requiere medir la exactitud funcional directamente sobre la base de datos. Este contexto justifica plenamente la integración de módulos de evaluación automatizados y matrices de complejidad que, apoyados en métricas estadísticas robustas como precisión, recall y F1-Score, certifiquen que la traducción algorítmica coincida de forma exacta y determinista con el estándar de referencia (Yalova et al., 2025).

1.2. Descripción y justificación del estudio

La presente investigación, de tipo tecnológica evaluativa, se centra en el diseño y evaluación de un intérprete semántico basado en procesamiento de lenguaje natural, capaz de traducir comandos conversacionales a consultas estructuradas a bases de datos relacionales. El estudio propone medir la fiabilidad algorítmica con base en la exactitud funcional de este artefacto mediante un protocolo de ejecución experimental cruzada sobre una muestra

estratificada de 96 consultas extraídas del benchmark internacional Spider. Para llevar a cabo esta validación, la investigación se apoya en dos instrumentos fundamentales: una matriz de ponderación de complejidad, encargada de clasificar las sentencias según su grado de dificultad sintáctica y relacional, y un módulo de evaluación automatizado que determinará el desempeño del sistema utilizando métricas estadísticas de precisión, recall y F1-Score.

La justificación principal de este desarrollo radica en la necesidad imperante de eliminar la barrera de entrada técnica que restringe el acceso directo a la información. En los entornos actuales, la extracción de datos complejos exige el dominio de lenguajes de consulta, lo que relega a los usuarios con conocimientos técnicos limitados a depender de analistas o intermediarios, impidiéndoles acceder a las bases de datos con facilidad (Baig et al., 2022). Al implementar una interfaz semántica, este estudio busca democratizar los datos y otorgar al usuario final una mayor independencia operativa, permitiéndole interactuar con sistemas robustos multitabla sin necesidad de conocer la estructura, las relaciones o la sintaxis subyacente. Desde una perspectiva práctica, el proyecto busca demostrar empíricamente si este artefacto tecnológico es capaz de superar un umbral de exactitud funcional global del 85% y un recall superior al 80%. Validar estadísticamente estos umbrales permitirá confirmar la viabilidad de la herramienta para su despliegue en entornos empresariales reales.

Adicionalmente, el estudio se justifica desde una perspectiva metodológica al abordar el riesgo crítico de las interpretaciones algorítmicas erróneas. Evaluar el rendimiento de estos sistemas basándose únicamente en la coincidencia exacta de texto ha demostrado ser insuficiente, ya que suele penalizar traducciones que son semánticamente válidas pero sintácticamente distintas (Pourreza & Rafiei, 2023). Al enfocar esta investigación en la exactitud funcional; es decir, ejecutando las consultas directamente en la base de datos para asegurar que las tablas y filas recuperadas

coincidan de forma determinista con el estándar de referencia, se garantiza la validación rigurosa de una herramienta no solo accesible, sino altamente segura y fiable para la industria.

1.3. Organización del documento

El presente trabajo de investigación se encuentra estructurado en seis capítulos, los cuales detallan el proceso de desarrollo y validación del intérprete semántico propuesto.

En el capítulo I, se expone la realidad problemática respecto a las barreras de acceso a bases de datos relacionales para usuarios no técnicos. Asimismo, se definen los objetivos de la investigación, la justificación técnica basada en la autonomía operativa y las limitaciones del estudio.

El capítulo II, presenta los antecedentes nacionales e internacionales que sustentan el uso de modelos de lenguaje en tareas de Text-to-SQL. Se definen los conceptos fundamentales de procesamiento de lenguaje natural, la arquitectura de los modelos Transformer y los estándares de evaluación funcional.

En el capítulo III, se describe el tipo y diseño de investigación, definiendo las variables de exactitud funcional y complejidad sintáctica. Se detalla la selección de la muestra estratificada de 96 consultas del benchmark Spider y se describen los instrumentos utilizados, como la matriz de ponderación de complejidad.

El capítulo IV, detalla la implementación técnica del intérprete semántico y el diseño del módulo de evaluación automatizado. Se describe el flujo de procesamiento desde la entrada en lenguaje natural hasta la ejecución experimental cruzada en el motor de base de datos.

En el capítulo V, se presentan los hallazgos obtenidos tras la ejecución de las pruebas. Se analizan las métricas de precisión, recall y F1-Score en contraste con la hipótesis planteada, comparando el rendimiento del artefacto frente al estado del arte.

Finalmente, en el capítulo VI, se sintetizan los logros alcanzados en relación con los objetivos específicos y se proponen futuras líneas de investigación para optimizar la fiabilidad algorítmica en entornos de datos masivos.

2. Planteamiento del problema de investigación

2.1. Descripción y delimitación del problema

Actualmente, las bases de datos relacionales juegan un papel fundamental respecto al almacenamiento y gestión de grandes volúmenes de información, siendo clave en la toma de decisiones dentro de diversas organizaciones y sectores (Karadjian & Blasco, 2024). Sin embargo, el acceso a esta información requiere que los usuarios formulen consultas en un lenguaje formal como lo es el structured query language. Siendo que esto genera una barrera técnica para aquellos que no poseen conocimientos especializados en bases de datos, esta restricción a su vez genera una brecha operativa; ya que al triangular las solicitudes formuladas en lenguaje natural es frecuente que se pierda el contexto o la intención original de la consulta, derivando en cuellos de botella y demoras cuantificables en la extracción de datos (Salem, 2024).

Si bien se asume comúnmente que los usuarios no técnicos son los únicos afectados por esta barrera, la literatura reciente revela que la problemática se extiende de igual manera a los perfiles con experiencia. En escenarios que involucran bases de datos a gran escala, lógica compleja o múltiples tablas, la formulación manual de consultas SQL eficientes y correctas resulta ser una tarea no trivial y sumamente propensa a errores, incluso para ingenieros y usuarios con una sólida formación técnica (Abedini, 2026). Para estos expertos, las limitaciones y la rigidez sintáctica del SQL ralentizan drásticamente los procesos de diagnóstico y extracción de datos en situaciones críticas. Esto evidencia que el problema trasciende la simple curva de aprendizaje de los usuarios novatos, apuntando a una necesidad transversal de optimizar la eficiencia operativa mediante herramientas de traducción semántica que aseguren respuestas precisas e inmediatas (Salem, 2024).

Aunque en la actualidad existen intérpretes basados en modelos de lenguaje que buscan mitigar estas barreras, la alta sensibilidad de la información gestionada exige ir más allá de la mera traducción (Lima

et al., 2025). Tradicionalmente, la evaluación de estos sistemas se ha basado en la coincidencia exacta de texto, una métrica que resulta insuficiente al generar falsos negativos, pues penaliza consultas que son semánticamente equivalentes pero poseen estructuras sintácticas diferentes. Por lo tanto, el problema central de esta investigación se delimita a la necesidad de validar la eficacia algorítmica real de estos intermediarios semánticos mediante procedimientos de evaluación objetivos y deterministas (Pourreza, 2024). Resulta imperativo transitar hacia métricas de exactitud funcional o de ejecución, garantizando que las tablas y registros recuperados por el sistema coincidan fielmente con el estándar de referencia ante distintos grados de dificultad relacional.

En respuesta a la problemática estipulada, y bajo el enfoque de investigación tecnológica evaluativa, el presente estudio se centrará en validar el desempeño de un intérprete semántico mediante un protocolo de ejecución experimental cruzada. Utilizando métricas de rendimiento basadas en estándares internacionales y el benchmark Spider, se analizará sistemáticamente el comportamiento del sistema ante una muestra estratificada por niveles de complejidad. Esta evaluación permite determinar la fiabilidad algorítmica del artefacto desarrollado, garantizando que los resultados recuperados coincidan de forma determinista con el estándar de referencia y reduciendo así la dependencia técnica para promover una mayor independencia operativa del usuario en la gestión de bases de datos relacionales.

2.1.1. Formulación del problema

En base a lo expuesto, se plantea la siguiente interrogante de investigación: ¿En qué medida los diferentes grados de complejidad sintáctica y relacional influyen en el nivel de exactitud funcional de un intérprete semántico al transformar consultas en lenguaje natural a código SQL estructurado?

2.1.2. Problema central del estudio

Existe una carencia de validación empírica y rigurosa respecto a la fiabilidad de los intérpretes semánticos actuales cuando enfrentan consultas de alta complejidad sintáctica y relacional. Esta falta de certeza sobre la exactitud de la traducción funcional genera una dependencia persistente de intermediarios técnicos, restringiendo la independencia operativa de los usuarios y poniendo en riesgo la precisión de la información recuperada en entornos de gestión de datos críticos.

2.2. Objetivos de la investigación

2.2.1. Objetivo general

Evaluar la exactitud funcional de la traducción del intérprete semántico mediante un protocolo de ejecución automatizada y el análisis de las métricas de precisión, recall y F1-Score, en función de los niveles de complejidad sintáctica y relacional.

2.2.2. Objetivos específicos

OE 1: Establecer los parámetros empíricos y requerimientos de exactitud funcional para el intérprete semántico, tomando como marco de referencia los estándares de rendimiento de los benchmarks internacionales.

OE 2: Diseñar el protocolo de evaluación automatizada, estructurada sobre una matriz de ponderación de complejidad sintáctica y un corpus estratificado de validación del benchmark Spider.

OE 3: Cuantificar la precisión del intérprete mediante la comparación de los resultados de ejecución de las sentencias SQL generadas frente al estándar de referencia.

OE 4: Cuantificar el recall del intérprete para determinar su capacidad de recuperación total de los requisitos semánticos sobre el corpus de prueba.

OE 5: Juzgar el desempeño global del F1-Score en función de la complejidad sintáctica y relacional, identificando la sensibilidad del modelo ante estructuras de alta dificultad.

2.3. Importancia del estudio

La presente investigación adquiere un nivel fundamental de relevancia al impulsar la democratización en el acceso a los datos. Históricamente, la extracción de información desde bases de datos relacionales ha estado condicionada al dominio de lenguajes estructurados como SQL, lo que impone una barrera técnica severa para el usuario común o no experto. Al evaluar y validar rigurosamente un intérprete semántico de lenguaje natural a SQL, este estudio promueve una mayor independencia operativa para el usuario final, permitiéndole formular consultas intuitivas en su idioma nativo sin la necesidad de comprender esquemas relacionales complejos ni sintaxis de programación. Esto mitiga la brecha tecnológica, garantizando que el acceso a la información sea más inclusivo y directo para cualquier persona que necesite interactuar con sistemas de datos (Sura, 2025).

En el ámbito corporativo y de negocios, la dependencia de analistas de datos o ingenieros especializados para la extracción de información genera cuellos de botella operativos que ralentizan la agilidad de la organización. Este estudio genera un impacto directo en los entornos de business intelligence, ya que permite a los tomadores de decisiones y partes interesadas no técnicas generar reportes e insights de forma más ágil e independiente. Al reducir la necesidad de intermediarios técnicos, las empresas experimentan

una mejora en los tiempos de respuesta y una optimización de sus recursos laborales y costos operativos. Además, al establecer métricas empíricas para asegurar una alta fiabilidad algorítmica y evitar interpretaciones erróneas en las consultas, se sientan las bases para que las organizaciones garanticen que sus decisiones estratégicas estén fundamentadas en datos extraídos de manera precisa, segura y determinista (Abedini, 2026).

Desde la perspectiva científica, este trabajo aborda directamente los vacíos y limitaciones metodológicas presentes en la evaluación del estado del arte de los sistemas NL2SQL. Gran parte de la literatura actual evalúa la calidad de la traducción basándose en la coincidencia exacta de texto, una métrica que la comunidad científica considera insuficiente, ya que suele generar falsos negativos al penalizar traducciones que tienen una estructura sintáctica diferente pero que son semánticamente correctas (Pourreza & Rafiei, 2023).

2.4. Justificación de la investigación

En lo que respecta a las bases de datos relacionales, la falta de acceso a la información para los usuarios no expertos en su lenguaje formal ha originado deficiencias operativas en cuanto a eficacia y agilidad al momento de adquirir información necesaria para las organizaciones. Debido a la falta de capacidades y conocimientos sobre el lenguaje formal de las bases de datos, los usuarios deben confiar en intermediarios técnicos para acceder a información, restringiendo la capacidad de datos a su disposición, proceso que suele retrasar la toma de decisiones. La presente investigación se justifica en la necesidad de realizar la evaluación rigurosa de la exactitud funcional de un intérprete semántico. El estudio se centra en validar la fiabilidad de esta tecnología mediante la verificación automatizada de resultados de ejecución, con el fin de simplificar la obtención de datos y optimizar la toma de decisiones, subrayando el impacto práctico, la contribución teórica y la robustez metodológica de esta validación.

2.4.1. Justificación Práctica

Actualmente, la extracción de información en bases de datos empresariales se encuentra restringida debido a la carencia de conocimientos técnicos en SQL por parte de los usuarios finales. Por ello, el fundamento práctico de este estudio radica en la necesidad de superar dicha restricción técnica y eliminar las demoras en la adquisición de datos esenciales. En el estudio de Baig et al. (2022) se refuerza esta dificultad, mencionando que la interfaz de lenguaje natural con una base de datos relacional ha llegado a ser un problema desafiante e importante, "en particular para las personas con conocimientos básicos limitados que no pueden acceder a las bases de datos con facilidad".

Además, la evaluación de la exactitud del intérprete ante consultas de complejidad variada ofrece una solución crítica, ya que la fiabilidad de la traducción impacta directamente en la calidad del dato recuperado. Al emplear una validación basada en la exactitud de ejecución, se garantiza que la herramienta sea una solución técnica viable. Esto no solo democratiza el acceso a la información para el usuario común, sino que, como señala Salem (2024), acelera significativamente el acceso a los datos incluso para usuarios expertos. De este modo, se alivian las tareas complejas y propensas a errores de los administradores y analistas de bases de datos, eliminando los cuellos de botella técnicos e impulsando la eficiencia operativa y la escalabilidad en la toma de decisiones (Rajesh Sura, 2025).

Por consiguiente, desde una perspectiva práctica, el proyecto se compromete a demostrar empíricamente que el artefacto tecnológico evaluado es capaz de superar un umbral de exactitud funcional global del 85% y un recall superior al 80%. Validar estadísticamente estos umbrales permitirá confirmar la

viabilidad operativa de la herramienta para su despliegue seguro en entornos empresariales reales.

2.4.2. Justificación Teórica

Desde el fundamento teórico, el empleo del procesamiento de lenguaje natural para la interpretación de consultas en bases de datos relacionales ha sido investigado de manera amplia, destacando el desarrollo de interfaces de lenguaje natural a bases de datos como la solución principal a las barreras tecnológicas que enfrentan los usuarios. Como señala [Abedini \(2026\)](#), estos sistemas permiten a los usuarios interactuar con las bases de datos utilizando su lenguaje cotidiano, traduciendo automáticamente las preguntas a consultas SQL ejecutables y permitiéndoles enfocarse en la información que desean obtener en lugar de en cómo expresarla técnicamente. Además, [Karadjian y Blasco \(2024\)](#) apoyan esta idea al afirmar que esta tecnología "abrirá nuevas oportunidades para una amplia gama de usuarios, incluidos aquellos que no tienen experiencia técnica en bases de datos". Esto valida el consenso teórico de que los intérpretes semánticos democratizan el acceso a la información para todos los perfiles. Para sustentar este proceso de traducción algorítmica, la presente investigación se apoya en teorías fundamentales (Kernel Theories), específicamente en la arquitectura transformer y los grandes modelos de lenguaje, las cuales explican los mecanismos subyacentes de atención y comprensión semántica necesarios para el funcionamiento del artefacto [\(Kanburoğlu & Tek, 2024\)](#).

Sin embargo, la literatura reciente advierte que aún existe una laguna de investigación en la operacionalización y evaluación formal de la exactitud de la traducción en función de la complejidad estructural de las consultas, ya que la evaluación tradicional suele carecer de análisis profundos en entornos de

múltiples tablas. La presente investigación busca contribuir al conocimiento estableciendo y validando un modelo de medición cuantitativa basado en la equivalencia lógica y funcional, analizando el desempeño del intérprete con base en las dimensiones de complejidad estructural, semántica y relacional para garantizar su aplicabilidad en escenarios del mundo real.

2.4.3. Justificación Metodológica

Metodológicamente, este estudio se justifica por la adopción del paradigma de investigación tecnológica evaluativa bajo el marco de design science research (DSR), el cual garantiza la objetividad de los resultados mediante la automatización de las pruebas de ejecución determinista. El rigor metodológico se basa en la operacionalización de las variables a través de matrices alineadas con benchmarks internacionales de dominio cruzado como Spider, el cual es considerado el estándar global para evaluar el desempeño ante consultas de alta complejidad relacional (Kanburoğlu & Tek, 2024; Mitsopoulou & Koutrika, 2025).

Asimismo, la medición estandarizada se realiza mediante métricas de exactitud funcional, superando así las deficiencias de la simple coincidencia de cadenas de texto, la cual suele penalizar injustamente consultas que son semánticamente válidas y operativas (Lima et al., 2025; Pourreza & Rafiei, 2023). Este enfoque metodológico elimina el sesgo del juicio humano o la subjetividad en la calificación de las traducciones, comparando los resultados directamente contra el estándar de referencia en la base de datos, lo que consolida la creación del módulo de evaluación automatizado como un aporte metodológico en sí mismo. De este modo, se asegura que las conclusiones sobre la fiabilidad algorítmica del intérprete sean estadísticamente válidas, altamente objetivas y rigurosamente replicables.

2.5. Limitaciones del estudio

A pesar de la robustez del diseño metodológico, la presente investigación presenta ciertas limitaciones que deben ser consideradas al momento de interpretar los resultados. En primer lugar, la delimitación de la muestra a 96 consultas extraídas del benchmark Spider restringe la evaluación a los esquemas de bases de datos contenidos en dicho conjunto. Aunque Spider es el estándar internacional para pruebas de dominio cruzado, la literatura reciente señala que la mayoría de sus bases de datos poseen esquemas relativamente pequeños, a menudo con menos de cinco tablas, lo que las clasifica como bases de datos a pequeña escala. Por lo tanto, los resultados sobre la fiabilidad algorítmica podrían no ser directamente extrapolables a bases de datos empresariales, industriales o científicas masivas que contienen cientos de tablas, esquemas complejos, nombres de columnas crípticos y terminología altamente especializada (Zhang et al., 2023).

En segundo lugar, existen limitaciones inherentes al módulo de evaluación automatizado y sus métricas. Si bien el uso de la exactitud funcional supera los falsos negativos de la simple coincidencia de texto, esta métrica no es estadísticamente perfecta. La evaluación basada en la ejecución en una única instancia de base de datos corre el riesgo de generar falsos positivos; es decir, casos en los que una consulta generada que es semánticamente incorrecta devuelve casualmente el mismo resultado que la consulta del estándar de referencia. Además, la evaluación automatizada por ejecución es vulnerable a problemas estructurales de los datos, como el manejo de registros empatados al emplear funciones de límite, lo que puede penalizar al intérprete de manera errónea si el ordenamiento interno difiere del esperado por el benchmark (Pourreza & Rafiei, 2023).

Finalmente, el desempeño del intérprete semántico está fuertemente condicionado por la ambigüedad intrínseca del lenguaje natural y el problema de vinculación de esquemas. Las consultas formuladas

por usuarios no expertos a menudo omiten información implícita o utilizan un vocabulario que no coincide o no se alinea directamente con las descripciones de las tablas y columnas. Dado que el alcance de esta investigación evaluativa no contempla la integración exhaustiva de ontologías externas de dominio ni mecanismos de aprendizaje interactivo con retroalimentación del usuario, la capacidad del modelo para deducir intenciones altamente ambiguas o resolver referencias lingüísticas ausentes en el esquema relacional representará una limitación natural del artefacto (Lima et al., 2025).

3. Marco de referencia

3.1. Marco histórico

La evolución de la traducción de lenguaje natural a SQL ha sido un área de investigación activa durante varias décadas y ha experimentado transformaciones paradigmáticas impulsadas por los avances en la inteligencia artificial.

Los primeros esfuerzos por democratizar el acceso a las bases de datos surgieron en la década de 1970 con sistemas como LUNAR, diseñado para responder preguntas sobre muestras de rocas lunares, y LADDER, utilizado para bases de datos de la Marina de los Estados Unidos. En sus inicios, "las primeras interfaces de lenguaje natural para bases de datos se basaban en técnicas basadas en reglas y de coincidencia de patrones" (Abedini, 2026). Estos enfoques dependían de gramáticas lingüísticas codificadas manualmente y diccionarios diseñados a medida para convertir el texto en consultas ejecutables. Sin embargo, a pesar de demostrar la viabilidad del concepto, estos primeros sistemas eran frágiles y carecían de escalabilidad y generalización. Cualquier desviación leve en la estructura de la consulta o en el vocabulario del usuario provocaba el fallo del sistema, limitando su adopción a dominios extremadamente cerrados y específicos.

Con el auge de las redes neuronales, la investigación abandonó la codificación manual de reglas y reformuló el problema del Text-to-SQL como una tarea de traducción automática. La introducción de las arquitecturas de secuencia a secuencia (Seq2Seq) permitió que los modelos aprendieran autónomamente a mapear representaciones de lenguaje natural hacia estructuras SQL. Modelos pioneros en esta etapa, como Seq2SQL y SQLNet, incorporaron redes neuronales para predecir componentes específicos de la consulta basándose en las dependencias de las palabras. Aunque esto permitió superar las barreras de los dominios cerrados, los modelos Seq2Seq tradicionales seguían perdiendo información en consultas largas y complejas (Yalova et al., 2025).

Un hito disruptivo ocurrió en 2017 con la introducción de la arquitectura Transformer, la cual eliminó la necesidad de componentes recurrentes al depender exclusivamente de mecanismos de autoatención. Esto dio paso a la era de los modelos de lenguaje preentrenados como BERT y T5, los cuales lograron mejoras sustanciales en la comprensión semántica. La literatura destaca que "la introducción de PLMs como BERT y T5 en 2018 condujo a avances significativos en los métodos NL2SQL basados en PLMs, logrando un rendimiento competitivo en varios benchmarks" (Liu et al., 2020). Estos modelos comenzaron a incorporar estructuras conscientes de las relaciones de la base de datos y esquemas de grafos, mejorando drásticamente el emparejamiento entre las palabras del usuario y las columnas del esquema relacional.

Actualmente, el estado del arte está dominado por los grandes modelos de lenguaje como GPT-4, Llama y DeepSeek. A diferencia de sus predecesores, que requerían un entrenamiento específico y exhaustivo para la tarea de traducción a SQL, los LLM modernos poseen una profunda comprensión semántica preexistente. Como afirma Liu et al. (2020) "los LLMs demuestran capacidades emergentes únicas que superan a los PLMs tradicionales en tareas de PLN, marcando un nuevo paradigma para las soluciones NL2SQL". Hoy en día, los sistemas Text-to-SQL de vanguardia dependen en gran medida del aprendizaje en contexto y la ingeniería de prompts, logrando resolver consultas en esquemas de bases de datos de dominio cruzado de alta complejidad, lo cual constituye el núcleo tecnológico del artefacto evaluado en la presente investigación.

3.2. Investigaciones antecedentes relacionadas con el tema

Al revisar la literatura sobre cómo el procesamiento de lenguaje natural (PLN) se aplica para interactuar con bases de datos relacionales, se han encontrado varios estudios que proponen soluciones innovadoras para hacer que los sistemas de consulta

sean más accesibles, especialmente para usuarios sin conocimientos técnicos. A continuación, se presentan investigaciones relevantes que evidencian avances en el desarrollo de intérpretes y modelos de traducción de lenguaje natural a consulta, organizadas según su enfoque metodológico, aportes teóricos y resultados obtenidos, permitiendo contextualizar el estado actual de esta línea de investigación y fundamentar la pertinencia del presente estudio.

3.2.1. Antecedentes Locales

No se encontraron estudios publicados a nivel local que abordan la traducción directa de lenguaje natural a SQL con las técnicas específicas de este proyecto.

3.2.2. Antecedentes Nacionales

Con la cita “El chatbot procesó consultas de SQL básico usando procesamiento de lenguaje natural y brindó respuestas inmediatas y coherentes al usuario.” Salazar (2020), presenta el artículo de investigación titulado “Chatbot para el aprendizaje de SQL básico”, abordó el problema de investigación central: ¿Cuál fue el tiempo de interpretación de las consultas del Chatbot para el aprendizaje del SQL básico?. El objetivo general del estudio fue determinar el tiempo de interpretación de las consultas del Chatbot para el aprendizaje del SQL básico, específicamente midiendo cuánto demora el Chatbot en interpretar las consultas realizadas por el usuario. La metodología empleada fue de tipo aplicada, con un enfoque cuantitativo y un diseño no experimental transversal de tipo descriptivo. Para la medición de la variable (tiempo de interpretación de la consulta al Chatbot), se utilizó como técnica la observación y como instrumento la ficha de recolección de datos. Se utilizó Telegram como canal de mensajería y Visual Studio Code como plataforma para implementar el chatbot, empleando herramientas como SQL, Telegraf y Node.js. El Chatbot se

creó para llevar a cabo el procesamiento de lenguaje natural (PLN) con el fin de interpretar las preguntas y ofrecer una respuesta lógica.

La investigación reveló, mediante datos cuantitativos, que la utilización del Chatbot para el aprendizaje de SQL básico ocasionó un tiempo medio de 0.085 milisegundos en la interpretación de las preguntas planteadas por el usuario. Este resultado llevó a la conclusión de que el tiempo de interpretación fue mayor al de otros Chatbots similares encontrados en estudios previos, lo que resultó en el rechazo de la hipótesis planteada. Esta diferencia se atribuyó a que los Chatbots similares usaban algoritmos más desarrollados e inteligentes, con mayor integración de inteligencia artificial, como el algoritmo Random Forest. Un estudio similar que usó la tecnología AIML versión 2.0 (Artificial Intelligence Mark-up Language), la cual se especializa en la creación de agentes software con Procesamiento de Lenguaje Natural (PLN), logró un tiempo favorable de 0.060 ms. Este antecedente nacional establece una línea base sobre la implementación de interfaces de procesamiento de lenguaje natural a SQL en nuestro entorno. Sin embargo, justifica metodológicamente la necesidad de la presente investigación al evidenciar que las evaluaciones locales previas se han limitado a medir tiempos de respuesta (latencia) en esquemas de SQL básico. Esto fundamenta nuestro salto hacia un diseño tecnológico evaluativo centrado en la complejidad funcional y la exactitud de ejecución en bases de datos relacionales multitable, elevando el rigor de medición del ámbito nacional hacia los estándares internacionales.

3.2.3. Antecedentes Internacionales

Como primer antecedente internacional, Baig et al. (2022) en su investigación realizada en Pakistán, titulada Natural Language to SQL Queries: A Review, afirman que "en

particular, las personas con conocimientos básicos limitados no pueden acceder a las bases de datos con facilidad". A partir de esta premisa, la problemática abordada en su estudio radica en la profunda barrera técnica que enfrentan los usuarios sin formación en lenguajes formales estructurados al intentar extraer información de bases de datos relacionales. Para analizar posibles soluciones, los autores emplearon un diseño de investigación basado en una revisión analítica y comparativa de los principales marcos de trabajo para la traducción de Texto a SQL (tales como SQL-Net, IR-Net, Edit-SQL y RAT-SQL), evaluando sus algoritmos, clasificadores de agregación y punteros de columnas utilizando el conjunto de datos de dominio cruzado Spider como estándar de medición. En cuanto a los resultados cuantitativos, el estudio demostró que el modelo RAT-SQL integrado con representaciones de lenguaje (BERT) superó significativamente a los demás marcos, alcanzando la mayor precisión general con un 65.6% en el dataset Spider, seguido por el modelo Edit-SQL con un 53.4%. Cualitativamente, los investigadores concluyeron que las consultas complejas de dominio cruzado siguen representando el principal reto algorítmico y determinaron que enfoques como la depuración manual de consultas delegada al usuario resultan inviables para personas sin experiencia previa en SQL. Esta investigación justifica directamente la problemática al confirmar que las soluciones de depuración manual son inviables para los usuarios no técnicos, reforzando la necesidad de un intérprete con alta exactitud funcional automatizada. Asimismo, establece un marco de referencia empírico fundamental al validar al benchmark Spider como el estándar idóneo para evaluar bases de datos de dominio cruzado, proporcionándonos una línea base cuantitativa histórica (65.6%) que justifica la transición hacia

arquitecturas más modernas para romper dicha barrera de rendimiento.

Como siguiente antecedente internacional, Rajesh Sura (2025) en su investigación realizada en India, titulada *Natural language interfaces for business intelligence at scale: A review*, sostiene textualmente que "las Interfaces de Lenguaje Natural (NLI) son una parte crucial para democratizar la analítica de negocios, pero su arquitectura subyacente debe ser capaz de conectarse sin problemas entre las consultas no estructuradas del usuario y un sistema de datos estructurado". Partiendo de esta premisa, la problemática del estudio se enfoca en las barreras operativas que enfrentan los usuarios no técnicos en entornos empresariales y la dificultad algorítmica de los sistemas actuales para manejar consultas ambiguas y cruces de múltiples tablas (JOINS) a gran escala. Para abordar esto, el diseño de investigación consistió en una revisión exhaustiva y analítica que propone un modelo teórico y arquitectónico de siete capas para sistemas NLI en plataformas de business intelligence, evaluando el rendimiento de distintas arquitecturas de traducción (modelos Seq2SQL, transformadores preentrenados y LLMs como GPT-4) ante diversos niveles de complejidad de consulta. En cuanto a los resultados cuantitativos, la evaluación demostró que modelos avanzados como GPT-4 lograron la mayor exactitud de ejecución (Execution Accuracy), alcanzando cerca del 90% de acierto en consultas simples y manteniendo un desempeño superior al 80% en consultas complejas, superando significativamente a modelos anteriores como Seq2SQL. Cualitativamente, el autor concluyó que, si bien estas interfaces logran reducir la barrera de entrada para usuarios no técnicos, los sistemas requieren urgentemente representaciones intermedias

interpretables y validaciones rigurosas para generar confianza en la toma de decisiones corporativas. Este antecedente otorga un respaldo fundamental a la pertinencia y viabilidad de nuestro diseño metodológico. Por un lado, ratifica que los grandes modelos de lenguaje son la arquitectura idónea a evaluar frente a bases de datos empresariales. Por otro lado, la conclusión del autor sobre la necesidad imperativa de aplicar "validaciones rigurosas" para generar confianza corporativa justifica de manera directa nuestro objetivo central: la implementación de un módulo de evaluación determinista basado en la exactitud funcional. Esto demuestra que, sin el nivel de auditoría algorítmica que propone nuestra tesis, la integración de estos intérpretes en la industria resulta riesgosa.

Como tercer antecedente internacional, Lima et al. (2025) en su investigación desarrollada en Brasil, titulada *Converting Natural Language to Query Languages Using Large Language Models: A Systematic Literature Review*, afirman textualmente que "la tarea de convertir comandos de lenguaje natural en lenguajes de consulta ha ganado atención debido a su potencial para mejorar la accesibilidad de los datos para usuarios no técnicos". En sintonía con esta idea, la problemática del estudio se enfoca en la necesidad de mapear y consolidar los avances de los grandes modelos de lenguaje en esta área, identificando vacíos críticos en la actualidad como la generalización ante esquemas de bases de datos heterogéneos, la ambigüedad del usuario y la urgencia de mitigar "alucinaciones" algorítmicas. Para dar respuesta a estos retos, el diseño de investigación se estructuró como una revisión sistemática de la literatura, en la cual se analizaron a profundidad 33 estudios primarios publicados entre 2020 y 2024, extrayendo métricas de

evaluación, conjuntos de datos y técnicas de optimización aplicadas. Respecto a los hallazgos cuantitativos, el análisis determinó que el benchmark Spider se posiciona como el estándar internacional indiscutible, siendo empleado en el 70% de las investigaciones modernas del área. En el ámbito cualitativo, los autores concluyeron que los enfoques de evaluación basados en la coincidencia exacta de texto resultan insuficientes para capturar la corrección semántica, destacando que las métricas basadas en la ejecución proporcionan una evaluación mucho más idónea y realista, superando las penalizaciones injustas por simples variaciones sintácticas. Esta revisión sistemática constituye un pilar fundamental para la justificación metodológica de nuestra investigación. Por un lado, legitima estadísticamente la elección del benchmark Spider como el entorno de validación idóneo al ser el estándar utilizado por el 70% del estado del arte. Por otro lado, la conclusión de los autores respecto a la insuficiencia de la coincidencia exacta de texto respalda directamente nuestro diseño de evaluación tecnológica, confirmando que la implementación de métricas basadas en la exactitud funcional es el único camino riguroso para evaluar el rendimiento real de los modelos y mitigar el riesgo de alucinaciones algorítmicas en bases de datos relacionales.

Como cuarto antecedente internacional, Kanburoğlu & Tek (2024) en su investigación desarrollada en Turquía, titulada Text-to-SQL: A methodical review of challenges and models, establecen textualmente que "si bien los modelos de redes neuronales para Text-to-SQL han logrado un progreso notable, aún enfrentan desafíos para generar consultas precisas y ejecutables en tiempo de ejecución". Bajo este contexto, la problemática del estudio se enfoca en las múltiples deficiencias algorítmicas que surgen al traducir

consultas a bases de datos de dominio cruzado, destacando el problema de desajuste léxico y la incapacidad de las métricas tradicionales de coincidencia de texto para medir el éxito real de una traducción. Para hacer frente a estos retos, el diseño de investigación consistió en una revisión sistemática basada en la metodología PRISMA, complementada con un marco evaluativo cuantitativo que sometió a prueba modelos de aprendizaje profundo y grandes modelos de lenguaje (como Chat GPT y Llama-2) frente a los benchmarks Spider y Wiki SQL. En cuanto a los resultados cuantitativos, la evaluación demostró que la incorporación de validaciones guiadas por ejecución incrementa la precisión real del sistema; por ejemplo, modelos como Chat GPT lograron un 73.83% de exactitud de ejecución en Spider, mientras que arquitecturas optimizadas como SeaD alcanzaron un 92.8% en Wiki SQL. A nivel cualitativo, los investigadores concluyeron que, aunque los modelos actuales tienen una gran capacidad deductiva, continúan fallando al emparejar entidades del lenguaje natural con esquemas complejos, determinando que ejecutar la consulta en el motor de base de datos es el único camino viable para filtrar predicciones semánticamente inválidas. Esta revisión sistemática justifica de manera directa el núcleo metodológico de nuestro proyecto al evidenciar que las métricas tradicionales de coincidencia de texto son incapaces de medir el éxito real de una traducción. Al concluir que la ejecución de la consulta en el motor de base de datos es la única alternativa viable para filtrar predicciones semánticamente inválidas, los autores respaldan y exigen la implementación de nuestro módulo de evaluación automatizado basado en la exactitud funcional. Esto consolida nuestro diseño como el enfoque más riguroso frente al problema de desajuste léxico en bases de datos de dominio cruzado.

Como quinto antecedente internacional, Mitsopoulou & Koutrika (2025), en su investigación desarrollada en Grecia bajo el título *Analysis of Text-to-SQL Benchmarks: Limitations, Challenges and Opportunities*, señalan textualmente que "un número de exactitud absoluto no proporciona mucha información a menos que consideremos las características del conjunto de datos de evaluación, como los tipos y distribuciones de las consultas en lenguaje natural y SQL". A partir de esta observación, la problemática abordada radica en que los sistemas de traducción suelen ser evaluados de manera global sin considerar a profundidad la estructura gramatical o el grado de dificultad intrínseco de los conjuntos de datos, lo cual enmascara el origen real de los errores del algoritmo y genera falsas expectativas sobre su rendimiento en entornos del mundo real. Para hacer frente a esta deficiencia, el diseño de investigación consistió en un estudio analítico que propone una nueva metodología formal basada en múltiples dimensiones para evaluar exhaustivamente la riqueza sintáctica y la distribución de las sentencias en diversos benchmarks, logrando identificar las vulnerabilidades operativas de distintos modelos. Respecto a los hallazgos cuantitativos, el análisis evidenció que incluso modelos de lenguaje avanzados (como las variantes de T5) presentan tasas de error significativamente mayores al enfrentarse a combinaciones estructurales complejas, observándose caídas drásticas de desempeño cuando la sentencia incluye subconsultas anidadas u operadores de conjuntos. A nivel cualitativo, las investigadoras concluyeron que la mayoría de los conjuntos de datos actuales están fuertemente desequilibrados favoreciendo a las consultas simples, determinando que resulta imperativo categorizar los errores según los componentes estructurales para obtener un

diagnóstico transparente y fiable. Esta investigación constituye el pilar teórico fundamental para justificar el uso de nuestra matriz de ponderación de complejidad. Al advertir que los puntajes globales de exactitud ocultan las vulnerabilidades de los modelos algorítmicos, las autoras legitiman la necesidad metodológica de estratificar nuestra muestra del benchmark Spider en niveles de dificultad. Asimismo, su conclusión sobre la urgencia de categorizar los errores basándose en los componentes estructurales de la consulta respalda directamente nuestro análisis granular, confirmando que nuestro diseño de investigación es el enfoque más adecuado en el estado del arte para obtener un diagnóstico transparente y riguroso de la fiabilidad del intérprete.

Como sexto antecedente internacional, Zhang et al. (2023) en su investigación desarrollada de forma conjunta entre Suiza y Grecia, titulada ScienceBenchmark: A Complex Real-World Benchmark for Evaluating Natural Language to SQL Systems, afirman textualmente que "las bases de datos complejas del mundo real con contenido específico de dominio tienen muy pocos o ningún dato de entrenamiento disponible [...] lo que conduce a un rendimiento deficiente de los sistemas NL-to-SQL existentes". Bajo este contexto, la problemática del estudio se enfoca en que los modelos actuales, a pesar de alcanzar altas precisiones en benchmarks populares de la academia, fracasan drásticamente al enfrentarse a entornos científicos y empresariales reales debido a la falta de conocimiento especializado y la extrema complejidad relacional de los esquemas. Para dar solución a esta brecha, el diseño de investigación consistió en la creación y validación de un nuevo marco de evaluación compuesto por más de 6,000 pares de consultas sobre tres bases de datos científicas masivas, combinando la anotación manual de

expertos con la generación automática de datos sintéticos mediante grandes modelos de lenguaje. Respecto a los hallazgos cuantitativos, el estudio evaluó sistemas del estado del arte y demostró que, en configuraciones iniciales, el rendimiento fue extremadamente bajo, sin superar el 16% de exactitud de ejecución en dominios complejos como la astrofísica. No obstante, al inyectar datos de entrenamiento sintéticos, la exactitud de ejecución mejoró significativamente en un 45%, aunque el tope máximo solo alcanzó el 60% mediante el uso de GPT-3.5. En el ámbito cualitativo, los investigadores concluyeron que los algoritmos que funcionan excepcionalmente bien en bases de datos simples no logran generalizar su aprendizaje hacia esquemas con múltiples tablas y nombres técnicos crípticos, requiriendo urgentemente estrategias algorítmicas que manejen cruces relacionales avanzados y funciones matemáticas. Este antecedente proporciona un sustento empírico invaluable para la hipótesis de nuestra investigación. Al demostrar que los modelos del estado del arte fracasan drásticamente al pasar de entornos académicos a bases de datos reales con esquemas complejos, los autores justifican la necesidad ineludible de evaluar el rendimiento del intérprete en función de la complejidad estructural y relacional. Asimismo, su conclusión sobre la incapacidad de los algoritmos para manejar cruces avanzados y nombres técnicos crípticos respalda la implementación de nuestra matriz de ponderación de complejidad, confirmando que la exactitud funcional debe medirse de forma estratificada para identificar las verdaderas vulnerabilidades del sistema en escenarios reales.

En esta misma línea de investigación, como séptimo antecedente internacional, Nascimento et al. (2024) en su estudio desarrollado en Brasil, titulado Text-to-SQL Meets the

Real-World, advierten textualmente que "cuando se adoptan para bases de datos de tamaño industrial, con un gran número de tablas, columnas y llaves foráneas, el rendimiento de las herramientas Text-to-SQL basadas en LLM es, sin embargo, significativamente menor que el reportado para los benchmarks". A partir de esta afirmación, la problemática se centra en la brecha existente entre los entornos académicos controlados y la realidad de los ecosistemas empresariales masivos, donde los intérpretes semánticos colapsan ante la intrincación relacional. Para analizar este fenómeno, el diseño de investigación consistió en un estudio evaluativo riguroso que sometió a prueba nueve estrategias distintas de traducción semántica (incluyendo arquitecturas impulsadas por GPT-3.5 y GPT-4) sobre dos bases de datos altamente desafiantes. Para ello, emplearon un corpus de prueba estructurado exactamente en una muestra de 100 preguntas en lenguaje natural, segmentadas explícitamente en tres niveles de dificultad: simple, media y compleja. En lo referente a los hallazgos cuantitativos, la evaluación evidenció que el modelo con mejor rendimiento alcanzó un 78% de exactitud global en la base de datos abierta, pero al enfrentarse a la base de datos industrial, la precisión de la inmensa mayoría de las estrategias cayó estrepitosamente a menos del 15%, logrando procesar correctamente solo aquellas peticiones que requerían una única tabla. Por su parte, a nivel cualitativo, los investigadores concluyeron que proveer el esquema completo al algoritmo mejora la traducción, pero esta técnica se ve severamente limitada por la restricción de tokens de los modelos de lenguaje, lo que exige la creación de enfoques diferentes para aplicaciones en el mundo real. Este antecedente justifica de forma directa y contundente la estructura de nuestro diseño de validación. Por un lado, legitima empíricamente el tamaño y la segmentación de nuestra muestra, demostrando que el uso

de un corpus acotado (~100 preguntas) y estratificado en tres niveles de dificultad es un estándar metodológico riguroso y actual para someter a estrés a intérpretes semánticos. Por otro lado, al evidenciar que las arquitecturas LLM colapsan a un 15% de precisión cuando se enfrentan a múltiples tablas reales, los autores respaldan nuestra hipótesis sobre la fuerte dependencia inversa entre la complejidad relacional y la exactitud funcional, confirmando que las altas métricas reportadas globalmente en la literatura suelen enmascarar una deficiencia operativa crítica frente a cruces de tablas complejos.

Como octavo antecedente internacional, Pourreza & Rafiei (2023) en su investigación desarrollada en la Universidad de Alberta, Canadá, titulada *Evaluating Cross-Domain Text-to-SQL Models and Benchmarks*, sostienen textualmente que "alcanzar un rendimiento perfecto en estos bancos de pruebas es inviable debido a las múltiples interpretaciones que pueden derivarse de las muestras proporcionadas". A la luz de esta afirmación, la problemática del estudio aborda las deficiencias críticas de las métricas de evaluación tradicionales al momento de calificar modelos Text-to-SQL. Los autores evidencian que el rendimiento real de los algoritmos suele subestimarse enormemente debido a la ambigüedad del usuario, a las suposiciones erróneas sobre los registros y a la naturaleza no determinista de los resultados en la base de datos. Para comprobar estas fallas, el diseño de investigación se estructuró como un estudio evaluativo profundo sobre los benchmarks Spider, Spider-DK y BIRD, en el cual se reevaluaron las consultas generadas por sistemas de última generación (como DIN-SQL y T5+PICARD) combinando técnicas de reescritura de código, validación estándar en motores PostgreSQL y revisión

humana experta para descartar falsos negativos. En el plano cuantitativo, los resultados revelaron una disonancia preocupante: al analizar una muestra de las consultas marcadas como "incorrectas" por el sistema del benchmark, los expertos determinaron que el modelo DIN-SQL realmente había generado una sentencia funcional y semánticamente válida en el 81.6% de los casos, superando incluso la validez de las consultas de referencia, las cuales solo alcanzaron un 67.3% de corrección sin errores. Desde una perspectiva cualitativa, los investigadores concluyeron que ninguna métrica de coincidencia textual es completamente fiable por sí sola, lo que hace imperativo adoptar evaluaciones basadas en resultados de ejecución funcional para no penalizar consultas que resuelven correctamente la misma petición empleando estructuras SQL diferentes. Este antecedente representa una de las justificaciones metodológicas más críticas de nuestra investigación. Al demostrar empíricamente que los sistemas de evaluación tradicionales subestiman el rendimiento real de los modelos y que incluso el estándar de referencia de los benchmarks contiene errores de lógica, los autores legitiman la necesidad absoluta de abandonar la métrica de coincidencia exacta de texto. Esto respalda de forma directa nuestro enfoque de Design Science Research (DSR) y justifica la construcción de un módulo de evaluación automatizado basado estrictamente en la exactitud funcional, confirmando ante la comunidad científica que esta es la única vía estadísticamente rigurosa para no penalizar traducciones que son semánticamente válidas.

Continuando con la necesidad de establecer métricas robustas, como noveno antecedente internacional, Abedini (2026) en su investigación desarrollada en la Universidad de Waterloo, Canadá, titulada SQLyze: A Comprehensive

Benchmark and Framework for Evaluating Text-to-SQL Systems, afirma textualmente que "los estándares de evaluación existentes normalmente dependen de una única métrica de exactitud, carecen de alineación con los patrones de uso del mundo real y no evalúan la escalabilidad de las consultas generadas, lo cual limita su capacidad para proporcionar una evaluación realista". Partiendo de esta aseveración, la problemática de esta tesis de maestría se enfoca en las deficiencias críticas de los entornos de prueba actuales, los cuales, al depender de puntajes globales estáticos o comparaciones superficiales de texto, enmascaran las vulnerabilidades de los algoritmos ante distintas estructuras SQL y omiten factores vitales como la eficiencia operativa. Para resolver esto, el diseño de investigación se basó en el desarrollo de software experimental, construyendo SQLyzer, un marco de evaluación automatizado que categoriza la sintaxis de las consultas y mide su exactitud ejecutándolas directamente en motores de bases de datos. Bajo este entorno, se sometieron a prueba dos modelos de vanguardia (DIN-SQL y DAIL-SQL) para someter a estrés sus traducciones. A nivel cuantitativo, el uso de este módulo automatizado reveló métricas mucho más precisas y granulares; por ejemplo, demostró que DAIL-SQL supera a DIN-SQL en exactitud de ejecución global (60.88% frente a 59.15%), pero además evidenció variaciones drásticas de rendimiento dependiendo del nivel de complejidad de las cláusulas exigidas. Cualitativamente, la autora concluyó que evaluar sistemas Text-to-SQL requiere imperativamente la ejecución en la base de datos para anular falsos negativos y que desglosar el desempeño algorítmico por categorías estructurales revela debilidades ocultas que un puntaje tradicional jamás detectaría. Esta investigación fundamenta y valida directamente el diseño metodológico DSR de nuestro proyecto. Por un lado, justifica la urgencia de abandonar las

métricas tradicionales basadas en la mera coincidencia de texto, respaldando la necesidad técnica de construir nuestro propio módulo de evaluación automatizado que mida la exactitud de ejecución funcional para evitar falsos negativos. Por otro lado, su conclusión sobre cómo los puntajes globales enmascaran las debilidades estructurales de los algoritmos respalda de forma irrefutable la implementación de nuestra matriz de ponderación de complejidad, demostrando que el rendimiento de un modelo Text-to-SQL solo puede diagnosticarse de manera realista y transparente si se evalúa y desglosa en función de su nivel de dificultad relacional.

Como décimo antecedente internacional, Raut et al. (2025), en su investigación desarrollada en la India titulada Natural Language to SQL Interfaces for Databases, establecen textualmente que "la evaluación del sistema NL-to-SQL propuesto se basa en métricas de rendimiento estándar como la precisión, la recuperación, el F1-Score, la exactitud y la exactitud de ejecución". En consonancia con esta directriz, la problemática del estudio aborda los nuevos obstáculos que surgen con la adopción de grandes modelos de lenguaje aplicados a bases de datos. Los autores evidencian que, a pesar de las mejoras algorítmicas, la falta de directrices estandarizadas de evaluación dificulta medir el verdadero éxito de los modelos ante consultas ambiguas y mapeos de esquemas complejos en entornos reales. Para dar respuesta a esta necesidad, el diseño de investigación consistió en un estudio analítico exhaustivo que evaluó arquitecturas modernas (como T5+PICARD, RAT-SQL y DIN-SQL) frente a los benchmarks WikiSQL y Spider, analizando su rendimiento a través de un riguroso marco de métricas estadísticas y proponiendo una arquitectura de validación híbrida. En el ámbito cuantitativo, el análisis demostró que las arquitecturas

modernas impulsadas por LLMs superan el 75% de exactitud de ejecución y logran mejoras del 30% al 40% frente a modelos tradicionales de secuencia a secuencia. Asimismo, el uso de la métrica F1-Score permitió medir de manera granular el rendimiento real de los modelos, evidenciando, por ejemplo, que sistemas como DIN-SQL alcanzan un F1-Score del 85.3% en el conjunto de validación de Spider. Cualitativamente, los investigadores concluyeron que el establecimiento de métricas de evaluación multidimensionales es indispensable para diagnosticar consistentemente el desempeño de los algoritmos y garantizar su fiabilidad para usuarios no técnicos. Este estudio respalda directamente nuestra matriz de operacionalización de variables, ya que establece un precedente internacional que valida el uso conjunto de la exactitud de ejecución y el F1-Score como los estándares estadísticos idóneos, rigurosos y multidimensionales para diagnosticar de forma granular el desempeño de los modelos Text-to-SQL frente a consultas de alta complejidad. Esto justifica nuestra decisión metodológica de integrar ambas métricas en el módulo de evaluación automatizado, garantizando que el diagnóstico del intérprete semántico sea robusto y alineado con la literatura de frontera.

Finalmente, como undécimo antecedente internacional y de carácter aplicativo en idioma español, Karadjian & Blasco (2024), bajo la dirección de Santos Blasco en la Universidad Europea de Valencia, España, en su tesis titulada Sistema de Generación de Consultas SQL Basado en Peticiones de Lenguaje Natural a partir de un Chatbot, afirman textualmente que "muchos usuarios se encuentran limitados por la necesidad de poseer conocimientos especializados en programación y consultas SQL para poder realizar consultas

y extraer la información deseada". A partir de esta premisa, la problemática se centra en cómo esta barrera técnica impide a los usuarios no programadores aprovechar las bases de datos para la toma de decisiones, generando una alta dependencia de intermediarios técnicos. Para resolver esto, el diseño de la investigación consistió en un proyecto aplicativo donde se desarrolló y evaluó un sistema intérprete conversacional impulsado por grandes modelos de lenguaje (OpenAI GPT-3.5) orquestados mediante LangChain. La validación del sistema se efectuó en un entorno controlado conectado a una base de datos relacional sobre gestión de vuelos, donde se ejecutó una muestra de consultas formuladas en lenguaje cotidiano para medir empíricamente la calidad y veracidad de las traducciones algorítmicas. En el plano cuantitativo, el sistema validó su alta fiabilidad al lograr una "tasa de éxito" del 94% en la generación operativa de consultas. Más importante aún, el estudio midió su rendimiento a través de los indicadores de una matriz de confusión, alcanzando una precisión del 85.1%, una recuperación perfecta del 100% y un F1-Score general de 0.8536. Desde la perspectiva cualitativa, el autor concluyó que, si bien la integración de modelos de lenguaje natural democratiza el acceso a la información, estos sistemas algorítmicos siguen siendo susceptibles a errores humanos, como solicitudes de información inexistente o ambigüedades léxicas, lo que hace vital diagnosticarlos estadísticamente. Este antecedente aplicativo resulta de vital importancia metodológica y práctica para nuestra investigación. Por un lado, demuestra la viabilidad de utilizar grandes modelos de lenguaje como intérpretes semánticos frente a bases de datos relacionales estructuradas. Por otro lado, valida empíricamente nuestro diseño de evaluación, al confirmar que el uso de los indicadores de una matriz de confusión es el estándar estadístico idóneo y necesario para diagnosticar

el rendimiento de las traducciones algorítmicas. Esto justifica la elección de estas métricas para nuestro módulo de evaluación automatizado, elevando el rigor de la medición más allá de la simple coincidencia de texto.

3.2.4. Síntesis integradora de antecedentes

La revisión exhaustiva de la literatura expone un consenso fundamental en la comunidad científica actual: las interfaces de lenguaje natural impulsadas por grandes modelos de lenguaje representan la arquitectura tecnológica idónea para democratizar el acceso a bases de datos, eliminando los cuellos de botella que enfrentan los usuarios no técnicos. Metodológicamente, autores como Pourreza y Rafiei (2023), Lima et al. (2025) y Abedini (2026) convergen de manera unánime en que la evaluación algorítmica basada en la simple coincidencia de texto es una métrica obsoleta e insuficiente, ya que genera falsos negativos al penalizar injustamente traducciones que son semánticamente válidas y operativas. Como resultado de esta convergencia, la literatura establece como exigencia ineludible la adopción de métricas deterministas basadas en la exactitud funcional, respaldando conjuntamente al benchmark Spider como el estándar de medición internacional indiscutible para esquemas de dominio cruzado.

A pesar de este consenso metodológico de evaluación, los estudios revelan una divergencia crítica y preocupante respecto a la generalización del rendimiento de los intérpretes en el mundo real. Investigaciones empíricas como las de Zhang et al. (2023), Nascimento et al. (2024) y Mitsopoulou y Koutrika (2025) difieren de las posturas sumamente optimistas del estado del arte, advirtiendo que, si bien los algoritmos alcanzan niveles de precisión sobresalientes frente a consultas y esquemas simples, su desempeño colapsa estrepitosamente (cayendo a umbrales menores al 16% de

exactitud) al enfrentarse a entornos industriales masivos, cruces relacionales complejos (JOINS) y terminologías especializadas. Esta disparidad confirma la advertencia de que reportar puntajes de rendimiento globales estáticos tiende a enmascarar las verdaderas deficiencias y vulnerabilidades operativas de los modelos frente a la intrincación estructural.

A partir de la síntesis expuesta, se identifica un vacío de investigación crítico en el estado del arte: la carencia de un marco de evaluación tecnológica que operacionalice y diagnostique la fiabilidad del intérprete semántico de forma estrictamente granular y estratificada según la complejidad sintáctica y relacional de las peticiones. Mientras que los antecedentes locales como (Salazar, 2020) se han limitado a medir latencias de respuesta algorítmica frente a sentencias de SQL básico, la presente investigación cubre este GAP a través del diseño de un estudio tecnológico evaluativo. El aporte fundamental de esta tesis radica en la implementación empírica de un módulo de evaluación automatizado y una matriz de ponderación de complejidad. Este diseño permitirá auditar el nivel de fiabilidad del algoritmo frente a entornos de estrés multitabla bajo el rigor estadístico del F1-Score, eliminando la subjetividad del juicio humano y garantizando que las conclusiones sobre la viabilidad del intérprete sean transparentes, deterministas y completamente replicables.

A nivel de desempeño algorítmico, la literatura establece una línea base clara sobre la cual esta investigación debe contrastarse. Modelos que representan el estado del arte (SOTA) actual, tales como DAIL-SQL y DIN-SQL, han logrado posicionarse como líderes al alcanzar umbrales del 86.6% y 85.3% de exactitud de ejecución, respectivamente, sobre el benchmark Spider (Abedini, 2026; Pourreza y Rafiei, 2023). No obstante, tal como advierten Nascimento et al. (2024) y

Zhang et al. (2023), estos umbrales de rendimiento globales suelen documentarse bajo entornos académicos controlados y tienden a enmascarar las verdaderas vulnerabilidades operativas de los modelos frente a esquemas de alta complejidad relacional. Por consiguiente, el GAP tecnológico que cubre la presente investigación radica en auditar determinísticamente si este umbral de exactitud funcional (85%) se sostiene de manera consistente al estratificar y someter a estrés al intérprete semántico frente a consultas de alta intrincación sintáctica y multitabla.

3.3. Base teórica – científica

3.3.1. Teorías fundamentales del artefacto (Kernel Theories)

De acuerdo con el paradigma de design science research, el diseño y validación del intérprete semántico evaluado en esta investigación se fundamenta en teorías tecnológicas subyacentes que posibilitan la traducción automatizada, partiendo primariamente del Procesamiento de Lenguaje Natural (PLN) y las Interfaces a Bases de Datos (NLIDB). El PLN es la disciplina de la inteligencia artificial que dota a las computadoras de la capacidad de comprender, interpretar y generar lenguaje humano. En el contexto de las bases de datos, las NLIDB operan como una capa de abstracción que utiliza técnicas de PLN, como la tokenización, el análisis sintáctico y la desambiguación semántica, para mapear intenciones humanas en consultas estructuradas sin que el usuario deba conocer la arquitectura interna del sistema (liu & xu, 2025).

Para materializar esta abstracción lingüística, la presente investigación se apoya estructuralmente en la arquitectura transformer y los grandes modelos de lenguaje. Históricamente, la traducción Text-to-SQL dependía de sistemas basados en reglas o modelos de secuencia a secuencia. Sin embargo, el estado del arte actual se rige por

los grandes modelos de lenguaje impulsados por la arquitectura Transformer. Esta arquitectura emplea mecanismos de autoatención que permiten al algoritmo ponderar dinámicamente la importancia de cada palabra en la consulta, capturando relaciones complejas a largo plazo (Yalova et al., 2025). Esta base teórica es la que explica cómo el modelo es capaz de deducir contextos, enlazar esquemas cruzados y generar sintaxis SQL válida sin necesidad de una programación previa de reglas rígidas (Abedini, 2026).

3.3.2. Complejidad de la consulta

Se define como el grado de dificultad inherente al procesamiento y traducción de una solicitud expresada en lenguaje natural hacia una sentencia formal ejecutable. Esta complejidad surge de la interacción entre la rigidez estructural requerida por el lenguaje de destino (SQL) y la ambigüedad semántica del lenguaje de origen. En este sentido, (Castillo, 2016) describe que una consulta se considera compleja cuando obliga a desglosarla en una serie de pasos lógicos o requiere la inclusión de subconsultas anidadas para poder satisfacer la necesidad de información del usuario. Asimismo, esta complejidad se incrementa drásticamente cuando el sistema algorítmico debe manejar operaciones avanzadas, como agrupamientos, funciones de agregación y cruces relacionales, para lograr interpretar y estructurar la intención original de manera operativa.

Para el análisis formal de los sistemas de traducción de texto a SQL (Text-to-SQL), la literatura contemporánea identifica tres dimensiones clave que componen la complejidad general de una consulta (Abedini, 2026). La primera de ellas es la complejidad estructural o sintáctica, la cual se refiere a los elementos gramaticales del SQL necesarios para resolver la petición; esta dimensión abarca el uso de estructuras de consulta que van más allá de una simple traducción,

incluyendo la presencia de subconsultas anidadas, múltiples operaciones de reunión entre tablas, y lógica condicional avanzada. La segunda dimensión es la complejidad semántica-lingüística, que hace referencia a la dificultad inherente al lenguaje natural de entrada; esta contempla la polisemia y la ambigüedad propias de las expresiones humanas, donde las preguntas suelen estar subespecificadas o carecer de toda la información explícita para una traducción exacta. Finalmente, la tercera es la complejidad relacional o de esquema, que mide el reto que representa para el intérprete realizar un mapeo correcto entre las entidades mencionadas en el lenguaje natural y los elementos del esquema de la base de datos, una tarea crítica denominada *schema linking* que constituye una de las principales fuentes de error.

Para clasificar y evaluar la complejidad de las consultas en la investigación, se establecen niveles alineados directamente con la estructura de la sentencia resultante y los estándares internacionales de benchmarking (Zhang et al., 2023). Basándose en los esquemas de evaluación de dificultad propuestos por datasets de dominio cruzado como Spider, los cuales demuestran que la precisión de los modelos cae a medida que aumentan las dependencias estructurales, esta variable se operacionaliza en niveles estrictos (Mitsopoulou & Koutrika, 2025). El Nivel 1 (Baja) corresponde a consultas simples que involucran una sola tabla en la cláusula FROM y no requieren estructuras sintácticas avanzadas. El Nivel 2 (Media) comprende sentencias de dificultad moderada que exigen la reunión de dos tablas base mediante un JOIN, o en su defecto, el uso explícito de funciones de agregación combinadas con cláusulas de agrupamiento. El Nivel 3 (Alta) abarca consultas estructuralmente sofisticadas que obligan a conectar tres o más tablas en la sentencia final, o que

implican el uso imperativo de subconsultas anidadas y operaciones de filtrado complejas.

La asignación determinista de estos tres niveles a la muestra de consultas resulta ser un paso metodológico fundamental para la evaluación del sistema y la posterior ejecución del análisis de varianza (ANOVA). Toda esta estratificación teórica y operativa permitirá explicar estadísticamente si la variación en las métricas de rendimiento, tales como el F1-Score y la exactitud de ejecución, es atribuible de forma directa y significativa a los distintos grados de dificultad sintáctica y relacional impuestos por los requerimientos del usuario.

3.3.3. Exactitud de la traducción del intérprete semántico

La exactitud de la traducción del intérprete semántico se define como el grado en que la consulta generada por el sistema coincide con la estructura lógica esperada y produce un conjunto de resultados idéntico al de la consulta de referencia. En este sentido, (Karadjian & Blasco, 2024) definen operativamente esta exactitud a través de la "tasa de éxito" para medir la proporción de consultas en lenguaje natural que han sido convertidas correctamente. Sin embargo, para garantizar la fiabilidad del sistema en entornos del mundo real, la literatura actual establece que dicha métrica debe complementarse con la exactitud funcional o exactitud de ejecución. Esta validación asegura que la equivalencia entre la consulta generada y la de referencia no sea meramente sintáctica, sino que se compruebe ejecutando la instrucción en la base de datos para certificar que los datos recuperados coinciden de forma determinista (Pourreza & Rafiei, 2023).

Para llevar a cabo una evaluación rigurosa y estructurada, la operacionalización de esta variable se apoya en los indicadores binarios de la matriz de confusión, aplicados

directamente a los componentes de la sentencia SQL y a su resultado operativo. Tal como formalizan (Raut et al., 2025) para sistemas de traducción de lenguaje natural a SQL, estos indicadores estadísticos permiten desglosar el rendimiento algorítmico en verdaderos positivos, que representan los elementos y cláusulas correctamente generados y funcionales; falsos positivos, que contabilizan los componentes irrelevantes o erróneamente introducidos por el modelo; falsos negativos, referidos a las estructuras requeridas que el intérprete omitió; y verdaderos negativos, que son aquellos elementos no solicitados e ignorados correctamente por el sistema.

Esta metodología de evaluación automatizada, validada mediante la ejecución en la base de datos, permite cuantificar el grado de acierto y diagnosticar con precisión las debilidades del intérprete ante la ambigüedad inherente del lenguaje natural. Aunque métricas tradicionales como la coincidencia exacta de conjuntos resultan útiles para evaluaciones estrictamente binarias, a menudo resultan insuficientes porque penalizan consultas que son semánticamente válidas pero que poseen estructuras sintácticas diferentes a la referencia (Lima et al., 2025). Por ello, esta investigación establece el F1-Score como la métrica estadística estándar para medir el desempeño granular del modelo. Al basarse en los indicadores de la matriz de confusión, el F1-Score no solo registra si una consulta es absolutamente correcta, sino que proporciona un equilibrio armónico entre la precisión y la recuperación, permitiendo así un diagnóstico mucho más profundo sobre el tipo de error y las fortalezas del intérprete.

3.4. Definición de términos básicos

Intérprete semántico de consultas: Componente algorítmico que realiza la traducción de solicitudes formuladas en lenguaje natural a

consultas estructuradas ejecutables (SQL). En el contexto de esta investigación, el desempeño de este artefacto no se evalúa por la simple similitud textual, sino mediante la exactitud funcional y estructural de la sentencia generada, garantizando que el sistema capture la intención semántica del usuario y realice un mapeo correcto hacia el esquema de la base de datos (Liu & Xu, 2025).

Interfaz de lenguaje natural a bases de datos: Sistema diseñado para eliminar la barrera técnica de interacción, permitiendo a los usuarios no expertos extraer información de bases de datos relacionales utilizando su idioma cotidiano. Estas interfaces traducen los requerimientos conversacionales en sentencias SQL, democratizando el acceso a los datos y otorgando autonomía al usuario final al evitar que este deba conocer la estructura interna, las relaciones o la sintaxis de programación del motor de bases de datos (Lima et al., 2025).

Exactitud de ejecución: Métrica de evaluación determinista que establece si la consulta SQL generada produce exactamente el mismo conjunto de resultados que la consulta de referencia al ser ejecutada en el motor de base de datos. En este estudio, representa el estándar principal para validar la fiabilidad algorítmica, ya que mitiga los falsos negativos de la simple coincidencia de texto y garantiza que el sistema proporcione información funcionalmente correcta al usuario (Pourreza, 2024).

F1-Score por complejidad: Estándar de medición estadística granular que proporciona un equilibrio armónico entre las métricas de precisión y recuperación derivado de una matriz de confusión aplicada a los componentes de la consulta. En esta investigación, se utiliza para cuantificar el grado de acierto y diagnosticar la fiabilidad algorítmica del intérprete de manera segmentada, evaluando su

desempeño ante los distintos niveles de dificultad sintáctica y relacional establecidos en la muestra (Raut et al., 2025).

Benchmark Spider: Estándar de evaluación internacional a gran escala utilizado para probar sistemas de traducción de texto a SQL. A diferencia de otros conjuntos de datos, Spider obliga a los modelos a generalizar sobre bases de datos relacionales complejas compuestas por múltiples tablas y segmenta intrínsecamente las consultas en niveles de dureza según su sintaxis, sirviendo como la población base fundamental para extraer la muestra estratificada de este estudio (Mitsopoulou & Koutrika, 2025).

4. Hipótesis y variables

4.1. Supuestos básicos

Para el desarrollo y validación de la presente investigación, se establecen supuestos fundamentales que delimitan y otorgan rigor al diseño experimental. En primer lugar, se asume la integridad y validez del benchmark de referencia. Específicamente, se presupone que las consultas SQL y los resultados lógicos proporcionados por el dataset Spider son técnicamente correctos y han sido validados previamente por expertos humanos, sirviendo así como un estándar de oro inobjetable para medir la exactitud funcional (Lima et al., 2025). Ligado a esto, se asume la representatividad de la complejidad sintáctica y relacional; es decir, que la estratificación de la muestra en tres niveles de complejidad mediante la matriz de ponderación constituye una métrica válida e internacionalmente aceptada para representar los verdaderos desafíos estructurales que enfrentan los usuarios en entornos de gestión de bases de datos.

En segundo lugar, el estudio se fundamenta fuertemente en el supuesto de la equivalencia semántica sobre la equivalencia léxica. La literatura científica establece que existen múltiples formas válidas de estructurar una sentencia SQL para obtener un mismo conjunto de datos (Pourreza, 2024). Por consiguiente, se asume que la simple coincidencia de texto es restrictiva y que la convergencia de los resultados recuperados en el motor de base de datos representa una prueba suficiente y definitiva de exactitud funcional, independientemente de la sintaxis empleada por el intérprete. Para que esta premisa sea evaluable, se establece simultáneamente el supuesto del determinismo en la ejecución de consultas. Esto implica asumir que el motor de base de datos relacional operará de manera determinista; es decir, que ante una misma consulta semánticamente correcta y un mismo estado inalterado de los datos, el resultado devuelto será invariablemente el mismo, permitiendo así

una comparación algorítmica fiable mediante el protocolo de ejecución experimental cruzada.

Finalmente, la investigación se apoya en la estabilidad operativa del modelo de lenguaje durante el periodo de evaluación. Aunque los grandes modelos de lenguaje poseen una naturaleza inherentemente estocástica (Abedini, 2026), se presupone que, bajo un entorno de pruebas controlado, las capacidades de traducción semántica del modelo no fluctuarán. Este supuesto garantiza metodológicamente que cualquier caída o variación observada en el rendimiento algorítmico se deba exclusivamente a la dificultad impuesta por la complejidad intrínseca de la consulta evaluada, y no a alteraciones aleatorias o actualizaciones en los parámetros internos del artefacto durante la ejecución del protocolo.

4.2. Hipótesis general

HG: El intérprete semántico de lenguaje natural a SQL logra una exactitud funcional global superior al 85%, evaluada mediante la métrica F1-Score sobre el corpus validado del benchmark Spider.

H0: El intérprete semántico de lenguaje natural a SQL no logra una exactitud funcional global superior al 85%, evaluada mediante la métrica F1-Score sobre el corpus validado del benchmark Spider.

4.3. Hipótesis específicas

HE1: El intérprete semántico obtiene un nivel de precisión superior al 85%, lo que demuestra una baja generación de elementos SQL irrelevantes o funcionalmente erróneos al ejecutarse en la base de datos.

HE2: El intérprete semántico alcanza un nivel de recuperación superior al 80%, lo cual indica una alta capacidad para recuperar la totalidad de los requisitos semánticos y registros correctos.

HE3: Existe una diferencia significativa e inversa en el desempeño del F1-Score según el nivel de complejidad de la consulta, siendo el rendimiento en el nivel "Alta" al menos un 10% inferior al obtenido en el nivel "Baja".

4.4. Variables

Tabla 1

Operacionalización de variables

Variable	Definición Conceptual	Definición Operacional	Dimensiones	Indicadores	Escalas de medición
Complejidad de la consulta	Grado de dificultad inherente al procesamiento y traducción de una solicitud expresada en lenguaje natural hacia una sentencia formal ejecutable (SQL). Esta complejidad está determinada por la interacción de tres factores críticos: la ambigüedad semántica del usuario, la complejidad estructural requerida por la sintaxis y el reto de mapear correctamente las entidades con el esquema de la base de datos (Abedini, 2026).	Clasificación determinista de las solicitudes en distintos niveles de dificultad basándose en la cantidad de cláusulas, operaciones de reunión de tablas y subconsultas requeridas, tomando como marco de referencia los estándares de estratificación del benchmark internacional Spider (Zhang et al., 2023).	Estructural	Cantidad de subconsultas anidadas y cláusulas SQL requeridas	Ordinal
			Semántica	Grado de ambigüedad léxica presente en la petición de lenguaje natural	
			Relacional	Cantidad de tablas vinculadas mediante cruces relacionales avanzados o JOINS	
			Índice integrador	Nivel de complejidad algorítmica asignado (Baja, Media, Alta).	
Exactitud de la traducción del intérprete semántico	Capacidad algorítmica del sistema para interpretar correctamente la intención del usuario y convertirla en una sentencia estructurada que la máquina pueda	Nivel de equivalencia funcional entre la consulta predicha por el modelo y la consulta de referencia, evaluado cuantitativamente	Rendimiento operativo	Tasa de exactitud de ejecución automatizada frente al estándar de referencia (Execution Accuracy).	Razón

procesar, garantizando que recupere la información precisa sin incurrir en interpretaciones erróneas, desajustes de esquema o falsos negativos (Lima et al., 2025).	mediante la métrica de exactitud de ejecución y complementado de forma granular mediante la métrica del F1-Score sobre la matriz de confusión de sus componentes (Pourreza & Rafiei, 2023)	Precisión de generación	Tasa de Verdaderos Positivos sobre Falsos Positivos (Precisión).
		Capacidad de recuperación	Tasa de elementos semánticos correctamente recuperados sin omisiones (Recall)
		Índice integrador	Porcentaje de F1-Score ponderado.

Nota. De “Operalización de variables”, elaborado en laboratorio.

4.5. Matriz de consistencia

Tabla 2

Matriz de consistencia de la investigación

Problema	Objetivo	Hipótesis	Variables	Dimensiones	Indicadores	Técnica	Instrumento
¿En qué medida los diferentes grados de complejidad sintáctica y relacional influyen en el nivel de exactitud funcional de un intérprete semántico al transformar consultas en lenguaje natural a código SQL estructurado?	Evaluar la exactitud funcional de la traducción del intérprete semántico mediante un protocolo de ejecución automatizada y el análisis de las métricas de precisión, recall y F1-Score, en función de los niveles de complejidad sintáctica y relacional.	El intérprete semántico de lenguaje natural a SQL logra una exactitud funcional global superior al 85%, evaluada mediante la métrica F1-Score sobre el corpus validado del benchmark Spider.	Complejidad de la consulta	Estructural	Cantidad de subconsultas anidadas y cláusulas SQL requeridas	Análisis de contenido sintáctico algorítmico.	Matriz de Ponderación de Complejidad
				Semántica	Grado de ambigüedad léxica presente en la petición de lenguaje natural		
				Relacional	Cantidad de tablas vinculadas mediante cruces relacionales avanzados o JOINS		
				Índice integrador	Nivel de complejidad algorítmica asignado (Baja, Media, Alta).		
			Exactitud de la traducción del intérprete semántico	Rendimiento operativo	Tasa de exactitud de ejecución automatizada frente al estándar de referencia (Execution Accuracy).	Validación por ejecución automatizada experimental cruzada.	Módulo de Evaluación Automatizado
				Precisión de generación	Tasa de Verdaderos Positivos sobre Falsos Positivos (Precisión).		
				Capacidad de	Tasa de elementos		

	recuperación	semánticos recuperados (Recall)	correctamente sin omisiones	
	Índice integrador	Porcentaje ponderado.	de	F1-Score

Nota. De “Operalización de variables”, elaborado en laboratorio.

5. Marco metodológico

5.1. Tipo de investigación

El presente estudio es de tipo aplicado y se enmarca bajo el paradigma de Design Science Research (DSR). Su objetivo principal no es la mera descripción de un fenómeno social, sino la evaluación rigurosa de la exactitud de traducción de un artefacto tecnológico (un intérprete semántico Text-to-SQL) para resolver un problema práctico: facilitar el acceso autónomo a bases de datos relacionales a través de consultas en lenguaje natural.

5.2. Nivel de madurez tecnológica

Basándose en los criterios de CONCYTEC, la presente investigación se sitúa en los niveles TRL 5 y TRL 6. El estudio trasciende la validación conceptual teórica para enfocarse en la evaluación de un prototipo operativo en un entorno relevante. De esta forma, la investigación validará el artefacto al someterlo a pruebas de exactitud funcional mediante la ejecución automatizada de consultas sobre bases de datos relacionales con esquemas complejos, garantizando una demostración técnica objetiva de su capacidad operativa.

5.3. Método de investigación

A nivel analítico y de tratamiento de datos, la investigación sigue el método cuantitativo, el cual es secuencial y probatorio (Hernández Sampieri & Mendoza Torres, 2018). El estudio parte de un problema técnico delimitado, establece métricas de éxito como el 85% de exactitud funcional, y mide las variables funcionales en un entorno controlado y analiza los resultados numéricos de las matrices de confusión utilizando estadística inferencial para establecer patrones definitivos de comportamiento algorítmico ante la complejidad estructural.

5.4. Diseño del estudio

De acuerdo con las exigencias del desarrollo tecnológico, la presente investigación posee un diseño de investigación tecnológica evaluativa de alcance comparativo transversal. A diferencia de los estudios correlacionales tradicionales, este diseño no busca asociar dos variables continuas, sino que estratifica la muestra en tres grupos estáticos independientes para comparar cómo reacciona el rendimiento del artefacto frente a estos distintos estratos de dificultad.

Bajo los lineamientos de Hernández Sampieri & Mendoza Torres (2018), el diseño se concibe para medir la variable dependiente de manera automatizada en un único momento temporal tras someter al algoritmo a las exigencias de la variable independiente. Esta estructura comparativa es la que metodológicamente permite, justifica y viabiliza la posterior ejecución del análisis de varianza (ANOVA) o Kruskal-Wallis para contrastar las hipótesis y determinar si las caídas de rendimiento son estadísticamente significativas.

5.5. Población y muestra

5.5.1. Población

La población objetivo de este estudio está constituida por el conjunto de solicitudes en lenguaje natural y sus correspondientes sentencias estructuradas integradas en el benchmark Spider. Este corpus de evaluación abarca 10,181 consultas distribuidas en 200 bases de datos relacionales complejas que cubren 138 dominios diferentes (Mitsopoulou y Koutrika, 2025; Pourreza y Rafiei, 2023). Esta población tecnológica se selecciona por representar el estándar de oro internacional para la evaluación de sistemas Text-to-SQL en entornos de dominio cruzado, garantizando un ecosistema de prueba inobjetable y con alta variedad estructural (Lima et al., 2025).

5.5.2. Muestra

Dado que la investigación se enmarca en el paradigma Design Science Research (DSR) y emplea un diseño evaluativo comparativo transversal, no resulta metodológicamente aplicable el uso de fórmulas de muestreo sociológicas basadas en probabilidades de ocurrencia. En su lugar, el estudio implementa un muestreo estratificado para benchmarking tecnológico.

La determinación del tamaño de la muestra se fundamentó en garantizar la potencia estadística exigida para ejecutar el análisis de varianza. De acuerdo con las directrices de Hernández Sampieri y Mendoza Torres (2018), para las pruebas de estadística inferencial se requiere un tamaño mínimo por grupo de comparación para estabilizar la varianza. En este sentido, el tamaño muestral de 96 unidades permite conformar tres estratos perfectamente balanceados de 32 consultas cada uno. Esta distribución supera el umbral mínimo exigido por el teorema del límite central para asumir normalidad asintótica en la distribución poblacional, justificando y viabilizando así la comparación matemática del rendimiento algorítmico.

Tabla 3

Muestra estratificada

Nivel de complejidad	Características SQL	Cantidad (n)
Baja	Consultas simples de traducción léxica directa que involucran una sola tabla (SELECT y FROM) sin filtros complejos.	32
Media	Consultas de dificultad moderada que requieren inferencia semántica, inclusión de cláusulas WHERE,	32

	operadores ordenamiento.	lógicos	y	
Alta	Consultas de resolución relacional sofisticada que obligan a conectar tablas mediante JOINS, funciones de agregación y/o subconsultas anidadas.			32
Total				96

Nota. Adaptado de “Text-to-SQL Meets the Real-World”, por (Nascimento et al., 2024).

5.6. Técnicas e instrumentos de recolección de datos

5.6.1. Técnicas

Análisis de contenido sintáctico

Esta técnica consiste en procesar las consultas de la muestra para determinar su estructura gramatical y operativa respecto a la sintaxis formal de SQL. De acuerdo con Mitsopoulou & Koutrika (2025), este proceso permite desglosar y categorizar cada consulta basándose en la presencia y combinación de sus componentes estructurales subyacentes, tales como las cláusulas SELECT, FROM, WHERE, operadores JOIN, agrupaciones y anidamientos. En el contexto de esta investigación, y apoyándose en los fundamentos de Abedini (2026) sobre el uso de la sintaxis abstracta para aislar patrones y medir la dificultad, esta técnica se utiliza para descomponer las sentencias SQL en sus cláusulas operativas y así asignarles deterministamente un nivel de complejidad objetivo, lo cual es indispensable para la posterior evaluación granular del intérprete semántico.

Validación por ejecución automatizada

Es la técnica metodológica central de la investigación empleada para determinar la verdadera fiabilidad algorítmica del sistema. Consiste en la ejecución automatizada de las

sentencias SQL generadas por el intérprete semántico dentro de un entorno de base de datos controlado, para luego contrastar de forma determinista los resultados arrojados contra los resultados producidos por la consulta del estándar de referencia. Como exponen Pourreza & Rafiei (2023) junto con Kanburoğlu & Tek (2024), esta técnica de validación basada en la exactitud de ejecución resulta imperativa para entornos reales. Al comprobar la equivalencia funcional de los datos recuperados, esta técnica supera directamente las deficiencias y los falsos negativos de las evaluaciones tradicionales por simple coincidencia de texto, garantizando que una consulta sea evaluada como correcta siempre que cumpla con recuperar la información exacta que el usuario solicitó, independientemente de su estructura sintáctica intermedia.

5.6.2. Instrumentos

Matriz de ponderación de complejidad

Es un instrumento técnico y documental diseñado para la categorización objetiva del corpus de prueba a través del análisis de sus constituyentes. Este instrumento permite clasificar la estructura sintáctica de las consultas, ponderando elementos técnicos como el número de tablas involucradas, los niveles de anidamiento, los cruces relacionales y las funciones de agregación. De acuerdo con Mitsopoulou & Koutrika (2025) y Zhang et al. (2023), el análisis de estas dependencias estructurales es indispensable para determinar el grado de dificultad gramatical y relacional de las sentencias frente a los esquemas de las bases de datos. En esta investigación, la matriz permite estratificar la muestra de manera estandarizada y coherente con los niveles de complejidad establecidos por benchmarks internacionales como Spider. Asimismo, los pesos técnicos asignados a cada elemento sintáctico han sido validados y heredados de las

taxonomías de los modelos de frontera y la literatura del estado del arte (Abedini, 2026; Kanburoğlu & Tek, 2024; Mitsopoulou & Koutrika, 2025; Nascimento et al., 2024; Zhang et al., 2023), lo cual dota al instrumento de una estricta validez de constructo sin depender de juicios subjetivos.

Módulo de evaluación automatizado

Es un conjunto de scripts y herramientas de software diseñados para medir cuantitativamente el rendimiento y la exactitud funcional del sistema intérprete mediante un entorno controlado. Siguiendo los principios de frameworks de evaluación modernos propuestos por Abedini (2026) y la validación funcional de Pourreza & Rafiei (2023), este instrumento automatiza la ejecución directa de las sentencias SQL generadas en el motor de la base de datos y compara sus resultados determinísticamente contra la salida del estándar de referencia. Este enfoque descarta los falsos negativos de la simple coincidencia de texto y permite calcular métricas estadísticas granulares derivadas de una matriz de confusión, validando científicamente la fiabilidad algorítmica y la calidad de recuperación del artefacto.

5.7. Procedimientos de ejecución del estudio

El desarrollo operativo de la evaluación tecnológica se llevó a cabo mediante un protocolo estrictamente automatizado, diseñado para suprimir el sesgo humano y garantizar la replicabilidad del experimento. Bajo el paradigma Design Science Research, las pruebas se ejecutaron siguiendo un flujo procedimental secuencial:

5.7.1. Preparación del entorno y corpus de datos

En primer lugar, se inicializó el entorno de experimentación computacional en Google Colab. Posteriormente, se cargó la muestra estratificada de 96 pares de consultas (conformada

por las peticiones en lenguaje natural y sus sentencias SQL de referencia) provenientes del benchmark Spider, junto con los esquemas relacionales correspondientes. La utilización de este corpus garantiza un entorno de prueba realista de dominio cruzado con múltiples bases de datos, el cual es indispensable para someter a evaluación a las interfaces de lenguaje natural en ecosistemas complejos.

A nivel de especificación técnica, el entorno computacional se configuró en la nube a través de Google Colab, aprovisionando una unidad de procesamiento gráfico (GPU) Tesla T4. El núcleo del intérprete semántico fue instanciado utilizando el gran modelo de lenguaje Qwen / Qwen2.5-Coder-3B-Instruct, el cual fue optimizado mediante una cuantización a 4-bit para viabilizar su despliegue y acelerar la inferencia. Asimismo, el entorno de validación se conectó al motor de base de datos relacional nativo del benchmark Spider (SQLite) para garantizar la compatibilidad del dialecto SQL durante la evaluación cruzada.

5.7.2. Ejecución algorítmica de traducción

En esta fase, cada solicitud en lenguaje natural fue ingresada de manera iterativa al intérprete semántico. El algoritmo procesó la petición decodificando la intención del usuario y, basándose de manera exclusiva en los metadatos del esquema relacional proporcionado, generó de manera autónoma la sentencia SQL predicha.

5.7.3. Ejecución cruzada y registro determinista

Finalmente, el módulo de evaluación automatizado ejecutó de manera secuencial tanto la consulta SQL predicha por el intérprete como la consulta SQL de referencia directamente en el motor de base de datos. Los conjuntos de resultados

devueltos por ambas ejecuciones se compararon de forma determinista para comprobar su equivalencia absoluta.

La literatura metodológica establece que este enfoque, basado en la exactitud de ejecución, es crucial porque supera las limitaciones técnicas de la simple coincidencia de texto, evitando generar falsos negativos al no penalizar consultas que presentan una sintaxis distinta pero que son semánticamente equivalentes y operativas (Abedini, 2026; Lima et al., 2025; Pourreza y Rafiei, 2023). Tras la comparación automatizada, las consultas cuyos resultados coincidieron de manera exacta con el estándar de referencia se registraron de forma binaria como aciertos o verdaderos positivos (1), mientras que las discrepancias funcionales se marcaron como errores o fallos en la recuperación (0). Estos registros se consolidaron en una matriz de datos temporal clasificada estrictamente según el nivel de complejidad estructural asignado a cada petición, dejando la información lista para su tratamiento estadístico.

5.8. Técnicas de procesamiento y análisis de datos

Una vez extraídos los registros binarios de la ejecución automatizada en la base de datos, el tratamiento cuantitativo de la información se dividió en dos fases metodológicas orientadas a la evaluación exhaustiva del intérprete semántico:

5.8.1. Análisis estadístico descriptivo

Utilizando los registros de la ejecución cruzada, se construyó una matriz de confusión funcional para clasificar los resultados arrojados en verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN). A partir de estos registros, se calcularon las métricas globales y estratificadas del modelo algorítmico.

Se determinó la precisión de generación según la capacidad del intérprete para generar sólo los datos requeridos sin incluir información irrelevante:

$$Precisión (P) = \frac{\sum TP}{\sum TP + \sum FP}$$

El recall determinará la capacidad de recuperar la totalidad de los registros exigidos por la consulta de referencia:

$$Recall (R) = \frac{\sum TP}{\sum TP + \sum FN}$$

Y, como índice integrador, el F1-Score que se calculará como la media armónica entre ambos, representando la exactitud funcional general del intérprete:

$$F1 - Score (F1) = 2 \times \left(\frac{P \times R}{P + R} \right)$$

La adopción de este conjunto matemático se fundamenta en la literatura especializada actual, la cual establece que el uso combinado del F1-Score derivado de una matriz de confusión es el estándar estadístico indispensable para cuantificar rigurosamente el rendimiento de los sistemas Text-to-SQL, ya que permite equilibrar la calidad de los datos recuperados penalizando simultáneamente las omisiones operativas (Karadjian y Blasco, 2024; Raut et al., 2025).

5.8.2. Análisis estadístico inferencial y multivariado

Para el contraste empírico de la hipótesis de complejidad, el protocolo de análisis procedió inicialmente con la verificación de los supuestos paramétricos. Se evaluó la normalidad de la distribución muestral mediante la prueba de Shapiro-Wilk y la homogeneidad de las varianzas a través de la prueba de Levene. La literatura metodológica dicta que, ante la ausencia de normalidad asintótica en la distribución de los datos, es imperativo descartar el análisis de varianza (ANOVA de un factor) y sustituirlo por pruebas de libre distribución para

evitar sesgos en el contraste (Hernández-Sampieri y Mendoza Torres, 2018). Consecuentemente, se determinó el uso de la prueba no paramétrica de Kruskal-Wallis para evaluar con rigor matemático si las diferencias del F1-Score y exactitud funcional entre los tres estratos de complejidad (Baja, Media y Alta) eran estadísticamente significativas.

De manera complementaria a la estadística inferencial, se aplicó un análisis exploratorio multivariado mediante Análisis de componentes principales (PCA) y agrupamiento (clustering) K-Means. Este tratamiento analítico adicional se implementó para reducir la dimensionalidad de las métricas obtenidas e identificar patrones subyacentes de fallo funcional (como los desajustes léxicos o fallos de schema linking) que no son atribuibles de manera exclusiva a la dificultad de la estructura relacional impuesta por el benchmark.

6. Presentación de resultados

6.1. Resultados de la investigación

6.1.1. Resultado del objetivo específico 1

Establecer los parámetros empíricos y requerimientos de exactitud funcional para el intérprete semántico, tomando como marco de referencia los estándares de rendimiento de los benchmarks internacionales.

El objetivo específico 1 permitió establecer el marco técnico de referencia, fundamentando la selección del benchmark Spider y la métrica de exactitud de ejecución como los estándares para validar la fiabilidad algorítmica del intérprete semántico.

Resultado consolidado

Se determinó que el estándar internacional para evaluar sistemas multitabla es el benchmark Spider, debido a su naturaleza de dominio cruzado y su capacidad para segmentar consultas en niveles de dificultad. Asimismo, se identificó que la exactitud de ejecución es la métrica vital para asegurar la autonomía del usuario final, ya que garantiza la integridad de la información recuperada mediante una validación determinista de los datos, superando las limitaciones léxicas de la métrica de coincidencia exacta.

Tabla 4

Evolución del desempeño SOTA y métricas de exactitud funcional en el benchmark Spider

Modelo	Parámetros de entreno	Exactitud funcional		Características técnicas
DAIL-SQL + GPT-4	Few-shot in-context	86.6% (EX)		Estado del arte actual; optimiza la ingeniería de prompts y la selección de ejemplos.
DIN-SQL + GPT-4	Few-shot in-context	85.3% (EX) 60.0% (EM)	/	Descomposición modular: vinculación de esquemas, clasificación de dificultad y autocorrección.
DTS-SQL + DeepSeek 7B	Fine-tuning de 2 etapas (7B)	84.4% (EX) 73.7% (EM)	/	Modelo de código abierto; utiliza un enfoque de ajuste fino desacoplado de dos etapas.
RESDSL-3B + NatSQL	3 Billones (T5)	79.9% (EX) 72.0% (EM)	/	Desacopla la vinculación del esquema mediante la extracción previa de tablas con NatSQL.
T5-3B PICARD	3 Billones (T5)	79.4% (EX) 75.1% (EM)	/	Utiliza decodificación restringida para rechazar errores sintácticos en tiempo real.
RAT-SQL + BERT	PLM (BERT GNN)	65.6% (EX) 73.3% (EX)	-	Pionero en codificación consciente de relaciones (GNN) para vincular llaves foráneas.
IRNet	Bi-LSTM + Atención	44.5% (EX) 53.0% (EX)	-	Emplea la representación intermedia SemQL para cerrar la brecha entre lenguaje natural y SQL.
SQL-Net	Red Neuronal	12.4% (EX)		Enfoque de plantillas (sketch-based); evidencia la limitación histórica ante relaciones multitabla.

Nota: Elaborado a partir de Pourreza, M. (2024), Zhang et al. (2023), Raut et al. (2025), Lan et al. (2023), Baig et al. (2022), y Kanburoğlu, A. B., & Tek, F. B. (2024).

6.1.2. Resultado del objetivo específico 2

Diseñar el protocolo de evaluación automatizada, estructurada sobre una matriz de ponderación de complejidad sintáctica y un corpus estratificado de validación del benchmark Spider.


El logro de este objetivo permitió culminar la fase de diseño operacional de la investigación, garantizando la trazabilidad técnica entre las variables de estudio y estableciendo el mecanismo determinista para la recolección de datos computacionales.

Resultado consolidado

Se finalizó el diseño de los instrumentos de evaluación algorítmica, consistentes en un corpus estratificado de 96 consultas y una matriz de complejidad basada en pesos sintácticos. El flujo procedimental de validación, compuesto por las fases de carga, traducción, ejecución cruzada y clasificación binaria, se encuentra detallado en el Anexo 7; mientras que la herramienta de estratificación y los puntajes técnicos asignados a cada cláusula SQL se presentan en la matriz de complejidad del Anexo 9. El listado completo de las 96 consultas que conforman este corpus se encuentra disponible en el Anexo 10.

Figura 1

Diagrama de flujo del protocolo de evaluación automatizado



Nota: Elaborado y adaptado a partir de Abedini (2026), Pourreza y Rafiei (2023), Karadjian y Blasco (2024), Mitsopoulou y Koutrika (2025), y Raut et al. (2025).

6.1.3. Resultado del objetivo específico 3

Cuantificar la precisión del intérprete mediante la comparación de los resultados de ejecución de las sentencias SQL generadas frente al estándar de referencia.

El objetivo específico 3 tuvo como finalidad cuantificar la precisión del intérprete semántico mediante la comparación automatizada entre los resultados obtenidos por las sentencias SQL generadas y los resultados derivados del SQL referencial. Para ello, se procesó el corpus de validación conformado por 96 consultas, distribuidas en tres niveles de complejidad sintáctica y relacional. La evaluación fue realizada con el modelo Qwen/Qwen2.5-Coder-3B-Instruct, cargado en 4-bit mediante bitsandbytes y ejecutado en Google Colab con GPU Tesla T4.

Resultado consolidado

Como resultado de la ejecución automatizada, se obtuvo una precisión global de 79.43%, calculada a partir de la matriz funcional agregada mediante la relación $TP / (TP + FP)$. En dicha matriz se registraron 278 verdaderos positivos y 72 falsos positivos; por tanto, de los 350 elementos recuperados por las consultas generadas, 278 coincidieron funcionalmente con los resultados esperados del SQL de referencia. El detalle tabulado de este resultado se presenta en la Tabla 9 del Anexo 11.

La Figura 2 sintetiza la matriz funcional agregada de evaluación, mostrando 278 verdaderos positivos, 72 falsos positivos y 282 falsos negativos. Estos valores constituyen la base del análisis de precisión y recall, ya que permiten identificar los elementos correctamente recuperados, los

elementos no esperados incluidos y los elementos esperados omitidos.

De forma complementaria, la precisión por nivel de complejidad presentó valores diferenciados: 82.45% en consultas de nivel bajo, 83.67% en consultas de nivel medio y 72.57% en consultas de nivel alto. Estos valores no reemplazan la precisión global, sino que permiten segmentar el comportamiento del intérprete según la dificultad sintáctica y relacional. El detalle se presenta en la Tabla 10 del Anexo 11.

Figura 2

Matriz funcional agregada de evaluación del intérprete semántico.


Matriz funcional agregada de evaluación		
Elemento	esperado	TP 278 FN 282
	no esperado	FP 72 TN No aplica
		Recuperado No recuperado

Nota. La figura resume los valores agregados de verdaderos positivos, falsos positivos y falsos negativos obtenidos mediante la comparación funcional entre el SQL generado y el SQL referencial. El valor de verdaderos negativos no aplica, debido a que el

universo de elementos no solicitados y no recuperados no es finitamente enumerable dentro del corpus evaluado.

Figura 3

Precisión por nivel de complejidad



Nota. La figura muestra la precisión global por nivel de complejidad calculada mediante la relación $TP / (TP + FP)$.

Docimasia

Para la docimasia del objetivo específico 3, se contrastó la siguiente hipótesis específica:

HE1: El intérprete semántico obtiene un nivel de precisión superior al 85%, lo que demuestra una baja generación de elementos SQL irrelevantes o funcionalmente erróneos en la base de datos.

El criterio de decisión establece que la hipótesis se acepta si la precisión global obtenida es superior al 85%. El resultado alcanzado fue de 79.43%, calculado a partir de 278

verdaderos positivos y 72 falsos positivos, valor inferior al umbral establecido.

Para acompañar la docimasia con un valor estadístico, se aplicó una prueba z unilateral para una proporción, considerando como proporción observada la precisión global obtenida y como proporción de contraste el umbral teórico de 0.85. El estadístico obtenido fue $z = -2.9191$, con un p-valor unilateral aproximado de 0.9982. Debido a que $p > 0.05$, no se evidencia que la precisión observada sea estadísticamente superior al umbral establecido.

Por tanto, no se acepta la hipótesis específica 1. El resultado obtenido se ubicó 5.57 puntos porcentuales por debajo del umbral definido, y el contraste estadístico no permite confirmar que la precisión del intérprete sea superior al 85%.

6.1.4. Resultado del objetivo específico 4

Cuantificar el recall del intérprete para determinar su capacidad de recuperación total de los requisitos semánticos sobre el corpus de prueba.

El objetivo específico 4 tuvo como finalidad cuantificar el recall del intérprete semántico, determinando su capacidad para recuperar la totalidad de los elementos esperados según el SQL de referencia. Para ello, se compararon los conjuntos de resultados generados por el modelo con los conjuntos obtenidos mediante las sentencias referenciales del corpus de validación.

Resultado consolidado

Como resultado de la evaluación automatizada, se obtuvo un recall global de 49.64%, calculado a partir de la matriz


funcional agregada mediante la relación $TP / (TP + FN)$. En dicha matriz se registraron 278 verdaderos positivos y 282 falsos negativos; por tanto, de los 560 elementos esperados por el SQL referencial, el intérprete recuperó correctamente 278 y omitió 282. El detalle tabulado de este resultado se presenta en la Tabla 11 del Anexo 12.

La lectura principal del recall se obtiene de los falsos negativos, ya que estos representan los elementos esperados que el SQL generado no recuperó. En este caso, los 282 falsos negativos evidencian una limitación relevante en la capacidad del modelo para recuperar la totalidad de los requisitos semánticos.

De forma complementaria, el comportamiento por nivel de complejidad fue desigual. En el nivel bajo se obtuvo un recall de 58.27%, en el nivel medio un recall de 25.63% y en el nivel alto un recall de 61.19%. Estos valores se detallan en la Tabla 12 del Anexo 12 y se visualizan en la Figura 4.

Figura 4

Recall por nivel de complejidad.



Nota. La figura muestra el recall global por nivel de complejidad calculado mediante la relación $TP / (TP + FN)$.

Docimasia

Para la docimasia del objetivo específico 4, se contrastó la siguiente hipótesis específica:

HE2: El intérprete semántico alcanza un nivel de recall superior al 80%, lo cual indica una alta capacidad para recuperar la totalidad de los requisitos semánticos y registros correctos.

El criterio de decisión establece que la hipótesis se acepta si el recall global obtenido es superior al 80%. El resultado alcanzado fue de 49.64%, calculado a partir de 278 verdaderos positivos y 282 falsos negativos, valor considerablemente inferior al umbral establecido.

Para acompañar la docimasia con un valor estadístico, se aplicó una prueba z unilateral para una proporción, considerando como proporción observada el recall global obtenido y como proporción de contraste el umbral teórico de 0.80. El estadístico obtenido fue $z = -17.9595$, con un p-valor unilateral aproximado de 1.0000. Debido a que $p > 0.05$, no se evidencia que el recall observado sea estadísticamente superior al umbral establecido.

Por tanto, no se acepta la hipótesis específica 2. Este resultado evidencia que el intérprete no logró recuperar la totalidad de los requisitos semánticos esperados en el corpus evaluado, presentando una cantidad significativa de falsos negativos.

6.1.5. Resultado del objetivo específico 5

Juzgar el desempeño global del F1-Score en función de la complejidad sintáctica y relacional, identificando la sensibilidad del modelo ante estructuras de alta dificultad.

El objetivo específico 5 tuvo como finalidad evaluar el desempeño global del intérprete mediante el F1-Score, considerando los niveles de complejidad sintáctica y relacional definidos en el corpus de validación. Esta métrica permitió integrar precisión y recall en una sola medida, proporcionando una evaluación más equilibrada del rendimiento funcional del modelo.

Resultado consolidado

Como resultado consolidado, el F1-Score global fue de 61.10%. Este valor se obtiene a partir de la integración entre la precisión global de 79.43% y el recall global de 49.64%, ambos derivados de la matriz funcional agregada. Por tanto, el F1-Score resume el equilibrio entre los elementos correctamente recuperados, los elementos no esperados incluidos y los elementos esperados omitidos.

La exactitud de ejecución global fue de 61.46%, lo que indica que aproximadamente seis de cada diez consultas generadas produjeron conjuntos de resultados funcionalmente equivalentes al estándar de referencia. Este resultado confirma que el desempeño global del intérprete fue moderado, pero insuficiente para alcanzar el umbral esperado en la hipótesis general.


De forma complementaria, al analizar el comportamiento por nivel de complejidad, se obtuvo un F1-Score promedio de 56.55% en consultas de nivel bajo, 80.40% en consultas de

nivel medio y 60.46% en consultas de nivel alto. El detalle tabulado del F1-Score por complejidad y las métricas complementarias se presenta en la Tabla 13 del Anexo 13.

La Figura 5 permite comparar visualmente el desempeño integrado de precisión y recall por nivel de complejidad. El nivel medio obtuvo el mejor resultado con 80.40%, mientras que el nivel bajo obtuvo 56.55% y el nivel alto 60.46%. Este comportamiento confirma que no existió una degradación estrictamente inversa del desempeño conforme aumentó la complejidad.

Figura 5

F1-Score promedio por nivel de complejidad.



Nota. La figura muestra el desempeño promedio del intérprete por nivel de complejidad, integrando precisión y recall mediante el F1-Score.

Docimasia

Para la docimasia del objetivo específico 5, se contrastó la siguiente hipótesis específica:

HE3: Existe una diferencia significativa e inversa en el desempeño del F1-Score según el nivel de complejidad, siendo el rendimiento en consultas de nivel “Alta” al menos un 10% inferior al obtenido en consultas de nivel “Baja”.

El criterio de decisión establece que la hipótesis se acepta si se evidencia una diferencia significativa entre los niveles de complejidad y si el F1-Score del nivel alto es al menos 10% inferior al del nivel bajo.

Como parte de la docimasia, primero se verificó el supuesto de normalidad del F1-Score para cada nivel de complejidad mediante la prueba de Shapiro-Wilk. Los resultados fueron: nivel bajo, $W = 0.6721$ y $p = 0.000000341$; nivel medio, $W = 0.5061$ y $p = 0.000000003$; y nivel alto, $W = 0.6560$ y $p = 0.000000204$. Debido a que los tres p-valores fueron menores que $\alpha = 0.05$, se rechazó el supuesto de normalidad en los tres grupos. El detalle de esta prueba se presenta en la Tabla 14 del Anexo 14.

Luego, se evaluó la homogeneidad de varianzas mediante la prueba de Levene, obteniéndose un estadístico de 2.8140 y un p-valor de 0.0651. Este resultado indica que no se evidenció diferencia significativa entre las varianzas. Sin embargo, dado que no se cumplió el supuesto de normalidad, la prueba principal para contrastar diferencias entre niveles fue Kruskal-Wallis.

La prueba de Kruskal-Wallis obtuvo un estadístico $H = 5.4831$ y un p-valor de 0.0645. Dado que $p > 0.05$, no se evidenció una diferencia estadísticamente significativa del F1-Score entre los niveles de complejidad. De manera complementaria, el ANOVA obtuvo $F = 2.5100$ y $p = 0.0868$, resultado que también coincide con la ausencia de diferencias significativas.

El detalle de estas pruebas se presenta en la Tabla 15 del Anexo 14.

Además, el F1-Score del nivel alto fue de 60.46%, mientras que el nivel bajo obtuvo 56.55%. Por tanto, el nivel alto no fue inferior al nivel bajo en al menos 10%; por el contrario, presentó un valor ligeramente superior.

Por tanto, no se acepta la hipótesis específica 3. No se evidenció una diferencia estadísticamente significativa del F1-Score entre los niveles de complejidad, ni se confirmó una disminución inversa del rendimiento en el nivel alto respecto al nivel bajo.

6.2. Discusión de resultados

6.2.1. Análisis del resultado del objetivo específico 1

El análisis de la evolución tecnológica en la traducción de lenguaje natural a SQL revela una brecha crítica de rendimiento ligada a la arquitectura del modelo y la complejidad de la base de datos. Mientras que los sistemas fundacionales como SQL-Net evidencian una limitación histórica con apenas un 12.4% de exactitud ante relaciones cruzadas, la introducción de modelos de lenguaje preentrenados (PLMs) y el uso de grafos en RAT-SQL permitieron elevar este umbral por encima del 65%, demostrando que la comprensión de las llaves foráneas es vital para la fiabilidad del sistema (Baig et al., 2022). Actualmente, el SOTA está representado por modelos como DAIL-SQL y DIN-SQL, los cuales han logrado romper la barrera del 85% de exactitud de ejecución mediante el aprendizaje en contexto y la descomposición modular de consultas (Pourreza y Rafiei, 2023). Este nivel de desempeño establece el estándar de rendimiento competitivo para esta investigación, justificando el uso del benchmark Spider como entorno de validación. Finalmente, el contraste entre las

métricas de coincidencia exacta y funcional confirma que la evaluación léxica es insuficiente para entornos multitabla (Lima et al., 2025). Por tanto, se establece como estándar de rendimiento la exactitud de ejecución mediante un módulo de evaluación automatizado, garantizando que el intérprete proporcione resultados deterministas y precisos, alineados con las exigencias de fiabilidad en la gestión de datos reales.

Asimismo, debe considerarse que los valores del estado del arte funcionan como referencia global de desempeño y no como comparación directa absoluta con el modelo evaluado en esta investigación. Los modelos SOTA revisados emplean arquitecturas de mayor escala, estrategias avanzadas de prompting o ajuste fino, mientras que la evaluación experimental del presente estudio se realizó con Qwen/Qwen2.5-Coder-3B-Instruct cargado en 4-bit y ejecutado en Google Colab con GPU Tesla T4. Por ello, la comparación con el estado del arte se interpreta como marco de referencia técnico para contextualizar los resultados obtenidos, no como equivalencia estricta de condiciones computacionales.

6.2.2. Análisis del resultado del objetivo específico 2

La definición de este protocolo garantiza el rigor científico de la investigación. Al delegar la comparación del estándar de referencia a un módulo de ejecución cruzada dentro del motor de la base de datos, se asegura la total ausencia de intervención y sesgo humano. Este enfoque metodológico se alinea estrictamente con la métrica de exactitud de ejecución, superando las deficiencias y los falsos negativos inherentes a las evaluaciones tradicionales basadas en la simple coincidencia de texto, lo cual es el estándar actual exigido en la literatura para validar sistemas Text-to-SQL en entornos de dominio cruzado (Abedini, 2026; Lima et al., 2025; Pourreza y Rafiei, 2023).

Asimismo, la estratificación del corpus en tres grupos discretos fue diseñada específicamente para cumplir con los requisitos del análisis de varianza. Esta partición asegura que cualquier fluctuación en la exactitud funcional del intérprete pueda ser atribuida de manera directa a la complejidad estructural sintáctica y no al azar; un enfoque taxonómico que resulta imperativo en los marcos de evaluación modernos para no enmascarar las vulnerabilidades algorítmicas frente a distintos componentes relacionales (Hernández-Sampieri y Mendoza Torres, 2018; Mitsopoulou y Koutrika, 2025).

Finalmente, este tamaño de muestra acotado a 96 consultas y su distribución uniforme en tres niveles de dificultad es plenamente consistente con las suites de validación controladas que se aplican a nivel internacional para someter a estrés a intérpretes semánticos en bases de datos complejas e industriales (Nascimento et al., 2024).

6.2.3. Análisis del resultado del objetivo específico 3

El análisis de la precisión debe partir de la matriz funcional agregada, debido a que esta contiene los valores utilizados para calcular la métrica global. En total, el intérprete recuperó 350 elementos, conformados por 278 verdaderos positivos y 72 falsos positivos. A partir de esta relación, la precisión global fue de 79.43%, lo que indica que aproximadamente ocho de cada diez elementos recuperados por el SQL generado coincidieron con los resultados esperados del SQL referencial.

Sin embargo, la presencia de 72 falsos positivos evidencia que el modelo también incluyó elementos no esperados en sus resultados. Por tanto, la lectura principal del objetivo específico 3 no debe centrarse inicialmente en los niveles de complejidad, sino en la capacidad global del intérprete para evitar la inclusión de información irrelevante o funcionalmente errónea. Desde esta perspectiva, el modelo mostró un

desempeño cercano al umbral esperado, aunque insuficiente para confirmar el cumplimiento de la hipótesis específica.

La Figura 3 permite complementar este resultado al observar la precisión por nivel de complejidad. El nivel medio obtuvo la mayor precisión global por nivel con 83.67%, seguido del nivel bajo con 82.45% y del nivel alto con 72.57%. Esta segmentación muestra que la disminución de la precisión fue más evidente en consultas de alto nivel, donde el modelo tuvo mayor tendencia a recuperar datos adicionales o no esperados.

En el nivel bajo, aunque la precisión global por nivel fue de 82.45%, se registraron 33 falsos positivos. Esto evidencia que incluso las consultas simples no estuvieron libres de error, principalmente por problemas de selección de columnas, tablas o atributos. Por ello, el comportamiento del modelo no puede explicarse únicamente por la complejidad sintáctica, sino también por la correspondencia entre la consulta en lenguaje natural y los nombres reales del esquema relacional, un desafío tipificado en la literatura como el problema de schema linking y desajuste léxico (Kanburoğlu y Tek, 2024; Lima et al., 2025).

De manera complementaria, el análisis mediante PCA y clustering K-Means permitió identificar que los falsos positivos se concentraron principalmente en consultas ejecutables pero funcionalmente incorrectas. En particular, el Cluster 1 agrupó 20 consultas con F1-Score promedio de 12.52%, precisión promedio de 17.41% y un total de 72 falsos positivos. Esto confirma que una parte relevante de los errores de precisión no provino de fallos sintácticos, sino de consultas que sí se ejecutaron, pero recuperaron información adicional o no esperada respecto al SQL referencial.

Asimismo, el Cluster 0 agrupó 59 consultas con alto desempeño, alcanzando una precisión promedio de 100.00%

y un F1-Score promedio de 99.44%. Esto evidencia que el intérprete resolvió correctamente una proporción considerable del corpus. No obstante, la existencia de clusters de fallo funcional confirma que la disminución de la precisión global se explica por patrones específicos de generación SQL, principalmente asociados a selección incorrecta de tablas, columnas, relaciones o condiciones. Esto concuerda con los hallazgos empíricos del estado del arte, los cuales advierten que la predicción errónea de variables y las fallas en el emparejamiento de entidades representan la principal fuente de error en los modelos Text-to-SQL (Mitsopoulou y Koutrika, 2025; Pourreza, 2024). El detalle del análisis PCA y clustering se presenta en el Anexo 16.

6.2.4. Análisis del resultado del objetivo específico 4

El análisis del recall debe partir de la matriz funcional agregada, debido a que esta métrica mide la proporción de elementos esperados que fueron efectivamente recuperados. En total, el SQL referencial esperaba 560 elementos, conformados por 278 verdaderos positivos y 282 falsos negativos. A partir de estos valores, el recall global fue de 49.64%, lo que evidencia que el intérprete omitió una proporción ligeramente mayor de elementos de los que logró recuperar correctamente.

Este resultado muestra que la principal debilidad del modelo no fue únicamente la inclusión de información no esperada, sino la omisión de registros o elementos requeridos por el SQL referencial. En términos funcionales, un falso negativo representa una parte de la respuesta esperada que no fue devuelta por el SQL generado; por ello, la presencia de 282 falsos negativos constituye el principal factor que explica el bajo recall global.

La Figura 4 permite observar esta métrica por nivel de complejidad. En el nivel bajo, el recall fue de 58.27%, con 155

verdaderos positivos y 111 falsos negativos. Esto evidencia que incluso en consultas sintácticamente simples el modelo no recuperó la totalidad de los registros esperados. Por tanto, el bajo recall no puede atribuirse únicamente a consultas relacionalmente complejas, sino también a errores de interpretación semántica o selección incorrecta de atributos en consultas de menor dificultad (Kanburoğlu y Tek, 2024; Lima et al., 2025).

En el nivel medio, el recall descendió a 25.63%, siendo el valor más bajo entre los tres grupos. Este comportamiento indica una mayor pérdida de elementos esperados en consultas con filtros, condiciones lógicas, conteos o restricciones semánticas moderadas. Por ello, el nivel medio concentró una debilidad importante en términos de recuperación, lo cual coincide con los hallazgos en la literatura que identifican el uso incorrecto de condiciones y filtros (WHERE clause) como una de las principales fuentes de falla funcional, pese a no representar necesariamente el mayor grado de complejidad relacional (Pourreza, 2024; Pourreza y Rafiei, 2023).

En el nivel alto, el recall alcanzó 61.19%, valor superior al obtenido en los niveles bajo y medio. Sin embargo, este resultado no implica que el modelo domine mejor las consultas complejas, sino que debe interpretarse junto con la precisión y el F1-Score. La recuperación de una mayor proporción de elementos esperados no garantiza por sí sola una traducción funcionalmente correcta si también existen errores de precisión o estructuras SQL inválidas.

El análisis complementario mediante clustering permitió precisar que la disminución del recall estuvo asociada principalmente a la acumulación de falsos negativos en determinados grupos de consultas. El Cluster 1 concentró 104 falsos negativos, mientras que el Cluster 3 agrupó 14

consultas con SQL inválido y 64 falsos negativos. Además, el Cluster 4, compuesto por una sola consulta, acumuló 110 falsos negativos. Esto demuestra que el bajo recall global no se debió únicamente a la complejidad general del corpus, sino a patrones específicos de omisión de resultados esperados.

Desde el punto de vista funcional, estos clusters muestran dos tipos de fallos relevantes: consultas ejecutables que no recuperaron todos los registros esperados y consultas inválidas que no pudieron devolver resultados, generando falsos negativos completos. Esta evidencia complementa el recall global de 49.64% y confirma que la principal debilidad del intérprete fue la omisión de elementos requeridos por el estándar de referencia, un colapso de rendimiento ampliamente documentado al evaluar grandes modelos de lenguaje en bases de datos del mundo real (Nascimento et al., 2024; Zhang et al., 2023). El detalle de los clusters y de las consultas con mayor patrón de fallo se presenta en los Anexos 16 y 17.

6.2.5. Análisis del resultado del objetivo específico 5

El análisis del F1-Score debe partir de la matriz funcional agregada, debido a que esta métrica integra el comportamiento conjunto de la precisión y el recall. En la evaluación global, el intérprete obtuvo 278 verdaderos positivos, 72 falsos positivos y 282 falsos negativos. Estos valores produjeron una precisión global de 79.43% y un recall global de 49.64%, cuya media armónica generó un F1-Score global de 61.10%.

Este resultado evidencia que el desempeño funcional del intérprete fue moderado. Aunque la precisión global fue relativamente cercana al umbral planteado, el recall fue considerablemente más bajo debido a la alta cantidad de falsos negativos. Por ello, el F1-Score global se vio reducido

principalmente por la omisión de elementos esperados, más que por la inclusión de elementos no esperados. En consecuencia, el problema principal del modelo no fue únicamente generar resultados incorrectos, sino no recuperar una parte importante de la respuesta esperada, un comportamiento que concuerda con las limitaciones de cobertura semántica documentadas en grandes modelos de lenguaje al operar sobre bases de datos complejas (Pourreza y Rafiei, 2023).

Una vez interpretado el comportamiento global desde la matriz funcional, el análisis por niveles permite observar cómo varió el desempeño según la complejidad sintáctica y relacional. El nivel medio obtuvo el mayor F1-Score promedio con 80.40%, mientras que el nivel bajo obtuvo 56.55% y el nivel alto 60.46%. Este patrón muestra que el rendimiento no disminuyó de forma estrictamente inversa conforme aumentó la complejidad.

En el nivel bajo, el F1-Score de 56.55% evidencia que las consultas simples también presentaron errores funcionales. Estos errores estuvieron asociados principalmente a selección incorrecta de columnas, uso de tablas inexistentes o interpretación inadecuada de atributos simples. Esto ratifica que la generación de datos erróneos no se explica únicamente por la dificultad sintáctica de la sentencia SQL, sino por deficiencias críticas en la vinculación semántica (schema linking) y el desajuste léxico, siendo este el principal factor de fallo reportado en el estado del arte actual (Kanburoğlu y Tek, 2024; Mitsopoulou y Koutrika, 2025).

En el nivel medio, el F1-Score promedio alcanzó 80.40%, siendo el valor más alto entre los tres grupos evaluados. Este resultado indica que el modelo tuvo un mejor equilibrio entre precisión y recall en consultas con dificultad intermedia, especialmente aquellas que requerían filtros, condiciones

lógicas, conteos o restricciones semánticas moderadas. En el nivel alto, el F1-Score fue de 60.46%, lo que evidencia dificultades ante consultas con mayor exigencia relacional. Sin embargo, este valor no fue inferior al nivel bajo; por tanto, no se confirma una caída monotónica del rendimiento conforme aumenta la complejidad.

Para contrastar este comportamiento, se aplicó un análisis exploratorio multivariado mediante PCA y clustering K-Means sobre las métricas obtenidas. El agrupamiento identificó cinco clusters (con un silhouette de 0.5352). El Cluster 0 agrupó 59 consultas de alto desempeño, con F1-Score promedio de 99.44%. En contraste, el Cluster 1 agrupó 20 consultas con desempeño crítico, alcanzando un F1-Score promedio de 12.52%, mientras que el Cluster 3 agrupó 14 consultas inválidas con F1-Score promedio de 0.00%. Este resultado evidencia que los errores del intérprete se explican mejor por patrones funcionales de fallo que por la complejidad asignada de forma aislada.

Asimismo, la matriz de distribución por complejidad mostró que los clusters no estuvieron compuestos exclusivamente por consultas de un solo nivel. Por ejemplo, el Cluster 0 incluyó 18 consultas de nivel alto, 18 de nivel bajo y 23 de nivel medio; mientras que el Cluster 1 agrupó 9 consultas altas, 6 bajas y 5 medias. Esto refuerza y justifica plenamente la decisión estadística de no aceptar la hipótesis específica 3, demostrando que la caída de rendimiento de los intérpretes semánticos en entornos reales obedece a vulnerabilidades de emparejamiento de entidades y alucinaciones de código inválido, más que a una simple regresión inversa por longitud o complejidad gramatical (Nascimento et al., 2024; Zhang et al., 2023).

6.3. Conclusiones

Se concluye que el intérprete semántico presentó un desempeño funcional moderado, logrando un F1-Score global de 61.10% y una exactitud de ejecución del 61.46%. Estos resultados determinan el rechazo de la hipótesis general de la investigación, ya que el sistema no logró superar el umbral del 85% establecido como rendimiento competitivo. El análisis de la matriz funcional determinó que la principal deficiencia del modelo evaluado no radicó en la generación sistemática de datos erróneos, sino en la omisión crítica de la información esperada, acumulando un total de 282 falsos negativos. En consecuencia, se determina que el modelo evaluado aún no posee la madurez técnica suficiente para operar de forma autónoma o sin supervisión humana, ya que su alta tendencia a entregar resultados incompletos representa un riesgo latente para la toma de decisiones basada en datos.

Respecto a los objetivos específicos 1 y 2, se concluye que el diseño e implementación de un protocolo de evaluación automatizada basado en la exactitud funcional constituye un aporte metodológico fundamental e ineludible para el diagnóstico de sistemas Text-to-SQL. Se comprobó que evaluar el rendimiento de estos intérpretes basándose únicamente en la coincidencia exacta de texto (exact match) es una práctica insuficiente que genera falsos negativos y enmascara vulnerabilidades operativas críticas ante el anidamiento avanzado y las relaciones multitable. Por consiguiente, se establece que aplicar un protocolo de ejecución cruzada directamente en el motor de base de datos, apoyado en entornos de prueba estratificados y matrices estadísticas, es la única vía determinista y rigurosa para certificar que el código SQL generado recupera fielmente la información solicitada, garantizando resultados seguros y viables para la toma de decisiones en entornos de datos del mundo real.

Respecto al objetivo específico 3 y la hipótesis específica 1, se concluye que la precisión global del intérprete semántico fue de

79.43%, lo que determinó el rechazo de la hipótesis al no lograr superar el umbral esperado del 85%. De un total de 350 elementos recuperados por el modelo, 278 fueron correctos (verdaderos positivos) y 72 fueron falsos positivos. Esto demuestra que el modelo posee una tendencia considerable a incorporar información adicional e irrelevante que no fue solicitada en la consulta de referencia. Asimismo, se comprobó que la generación de estos datos erróneos no se explica únicamente por la dificultad sintáctica de la sentencia SQL, sino por fallas directas en la vinculación semántica y desajustes léxicos al intentar emparejar la intención del usuario con el esquema relacional de la base de datos, lo que generó predicciones de código operativas pero funcionalmente inexactas.

En relación con el objetivo específico 4 y la hipótesis específica 2, se concluye que el nivel de recuperación (recall) global del intérprete semántico fue de apenas 49.64%, lo que determina el rechazo absoluto de la hipótesis al no alcanzar el umbral exigido superior al 80%. El análisis de la matriz funcional agregada evidenció que la principal debilidad algorítmica del modelo evaluado no radica en la invención de datos, sino en la omisión de información: de un total de 560 elementos esperados por el estándar de referencia, el sistema recuperó correctamente 278 (verdaderos positivos) y omitió de forma crítica 282 elementos (falsos negativos). Esto demuestra que el modelo es altamente propenso a entregar respuestas incompletas o a generar sentencias SQL inválidas que no devuelven resultados, una limitación operativa que afectó de manera transversal al corpus, presentando su peor desempeño en el nivel de complejidad medio (donde el recall cayó drásticamente a 25.63%).

Respecto al objetivo específico 5 y la hipótesis específica 3, se concluye el rechazo de la hipótesis al no evidenciarse una diferencia estadísticamente significativa en el rendimiento del intérprete según el nivel de complejidad de la consulta, respaldado por un p-valor de 0.0645 en la prueba de Kruskal-Wallis. Contrario a la proyección

teórica de que a mayor complejidad estructural habría una menor exactitud funcional, los resultados demostraron que el rendimiento no se degradó de forma inversamente proporcional. El análisis reveló que el nivel de complejidad medio obtuvo el mejor desempeño con un F1-Score promedio de 80.40%, superando tanto al nivel alto (60.46%) como al nivel bajo (56.55%). En consecuencia, se determina que la caída de rendimiento de los sistemas Text-to-SQL no obedece exclusivamente a la intrincación gramatical o longitud de la sintaxis, sino a fallas directas en el emparejamiento de entidades (schema linking). El sistema colapsa principalmente por la incapacidad algorítmica de vincular las intenciones ambiguas expresadas en lenguaje natural con los nombres reales del esquema de la base de datos, generando patrones funcionales de fallo independientemente del nivel de dificultad impuesto.

Finalmente, en relación con el análisis exploratorio multivariado, se concluye que el origen real de los errores del intérprete semántico no se explica exclusivamente por el nivel de complejidad sintáctica asignado, sino por patrones definidos de fallo funcional. La aplicación de clustering mediante K-Means (con un silhouette score de 0.5352) demostró que las consultas no se agruparon según su dificultad teórica, ya que tanto los clusters de alto desempeño como los de fallo crítico integraron de manera transversal sentencias de nivel bajo, medio y alto. En consecuencia, se determina que la causa principal de la inexactitud radica en la selección errónea de atributos o la invención de estructuras. Esto ratifica que la vulnerabilidad más crítica de los modelos Text-to-SQL contemporáneos es el schema linking y el desajuste léxico, haciendo imperativo que el diagnóstico de estas herramientas priorice la evaluación de la correspondencia semántica por encima de la simple categorización gramatical.

6.4. Recomendaciones

Se recomienda que futuras mejoras del intérprete semántico se orienten principalmente al fortalecimiento del proceso de vinculación

entre el lenguaje natural y el esquema relacional de la base de datos, debido a que los resultados evidenciaron que la principal debilidad del modelo no estuvo únicamente asociada a la complejidad sintáctica de las consultas, sino a errores de schema linking, selección incorrecta de tablas o columnas, generación de SQL inválido y omisión de elementos esperados. En ese sentido, se sugiere incorporar mecanismos de validación estructural previa a la ejecución, capaces de verificar la existencia de tablas, columnas, alias y relaciones utilizadas por el SQL generado, así como módulos de corrección automática que aprovechen el mensaje de error del motor de base de datos y el esquema relacional para regenerar consultas funcionalmente válidas. Asimismo, se recomienda ampliar el corpus de evaluación hacia bases de datos reales, con esquemas más extensos, nombres técnicos menos descriptivos y consultas formuladas por usuarios no especializados, con el fin de evaluar el comportamiento del intérprete en escenarios más cercanos al uso empresarial. También resulta pertinente complementar las métricas de precisión, recall, F1-Score y exactitud de ejecución con una clasificación detallada de errores, diferenciando fallas por columna incorrecta, tabla inexistente, condición omitida, JOIN incorrecto, agregación errónea o SQL inválido. Finalmente, se recomienda mantener el protocolo de evaluación automatizada basado en ejecución funcional y complementar su análisis con técnicas exploratorias como PCA y clustering, ya que estas permitieron identificar patrones de fallo no atribuibles únicamente al nivel de complejidad, sino a comportamientos funcionales específicos del modelo evaluado.

7. Referencias bibliográficas

Abedini, S. (2026). *SQLyzer: A Comprehensive Benchmark and Framework for Evaluating Text-to-SQL Systems*.

Baig, M. S., Imran, A., Yasin, A., Butt, A. H., & Khan, M. I. (2022). Natural Language to SQL Queries: A Review. *International Journal of Innovations in Science and Technology*, 4(1), 147-162.
<https://doi.org/10.33411/IJIST/2022040111>

Castillo, G. (2016). *Interfaz de composición de consultas a bases de datos que permita incluir subconsultas*.

Elgohary, A., Hosseini, S., & Hassan Awadallah, A. (2020). Speak to your Parser: Interactive Text-to-SQL with Natural Language Feedback. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2065-2077.
<https://doi.org/10.18653/v1/2020.acl-main.187>

Hernández Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta* (First edition). McGraw-Hill Education.

Kanburoğlu, A. B., & Tek, F. B. (2024). Text-to-SQL: A methodical review of challenges and models. *Turkish Journal of Electrical Engineering and Computer Sciences*, 32(3), 403-419.
<https://doi.org/10.55730/1300-0632.4077>

Karadjian, B. J. B., & Blasco, J. S. (2024). *Sistema de Generación de Consultas SQL Basado en Peticiones de Lenguaje Natural a Partir de un Chat-Bot*.

- Lima, R. R., Vasconcelos, K. C., & Gadelha, E. M. (2025). *Converting Natural Language to Query Languages Using Large Language Models*.
- Liu, M., & Xu, J. (2025). *NLI4DB: A Systematic Review of Natural Language Interfaces for Databases* (Versión 2). arXiv. <https://doi.org/10.48550/ARXIV.2503.02435>
- Mitsopoulou, A., & Koutrika, G. (2025). *Analysis of Text-to-SQL Benchmarks: Limitations, Challenges and Opportunities*.
- Nascimento, E., García, G., Feijó, L., Victorio, W., Izquierdo, Y., R. De Oliveira, A., Coelho, G., Lemos, M., Garcia, R., Leme, L., & Casanova, M. (2024). Text-to-SQL Meets the Real-World: *Proceedings of the 26th International Conference on Enterprise Information Systems*, 61-72. <https://doi.org/10.5220/0012555200003690>
- Pourreza, M. (2024). *Text-to-SQL Systems in the Era of Advanced Large Language Models*.
- Pourreza, M., & Rafiei, D. (2023). Evaluating Cross-Domain Text-to-SQL Models and Benchmarks. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 1601-1611. <https://doi.org/10.18653/v1/2023.emnlp-main.99>
- Rajesh Sura. (2025). Natural language interfaces for business intelligence at scale: A review. *International Journal of Science and Research Archive*, 15(3), 1702-1711. <https://doi.org/10.30574/ijrsra.2025.15.3.1772>
- Raut, A., Shah, M., Patil, R., Patil, Y., & Khodaskar, M. (2025). *Natural Language to SQL Interfaces for Databases*.
- Salazar, O. (2020). *LÍNEA DE INVESTIGACIÓN: Sistema de información y comunicaciones*.

Salem, O. (2024). *Advancing Natural Language to SQL Translation: Integrating Few-Shot Learning, Large Language Models, and Clustering Techniques*.

Yalova, K., Babenko, M., Yashyna, K., & Boyarchuk, A. (2025). *Implementation of transformer model for natural language to SQL query translation*★.

Zhang, Y., Deriu, J., Katsogiannis-Meimarakis, G., Kosten, C., Koutrika, G., & Stockinger, K. (2023). ScienceBenchmark: A Complex Real-World Benchmark for Evaluating Natural Language to SQL Systems. *Proceedings of the VLDB Endowment*, 17(4), 685-698.
<https://doi.org/10.14778/3636218.3636225>

8. Anexos

Anexo 1. Instrumentos de recolección de datos.

Anexo 2. Evidencias de la ejecución de la investigación.

Anexo 3. Resolución de aprobación del proyecto de investigación.

Anexo 4. Constancia de autorización y asentimiento de la organización.

Anexo 5. Constancia del asesor.

Anexo 6. Metodología de desarrollo de software.

Anexo 7. Protocolo de evaluación automatizada.

El presente documento establece la secuencia algorítmica y procedimental estricta que debe seguir el módulo de evaluación automatizado para procesar la muestra, validar la traducción y generar los datos estadísticos de la matriz de confusión. Este diseño replica las arquitecturas de validación funcional estandarizadas en la literatura para sistemas Text-to-SQL.

1. Carga y preparación de datos: El módulo inicializa el entorno cargando el corpus de validación (constituido por 96 pares de consultas) y el esquema de la base de datos relacional. En esta fase, se aísla la consulta en lenguaje natural y se identifica su respectiva sentencia SQL de referencia o Gold Standard
2. Generación de sentencia SQL (Traducción): El módulo introduce la consulta en lenguaje natural como entrada al intérprete semántico. A través del procesamiento algorítmico, el intérprete decodifica la intención del usuario y devuelve una sentencia SQL predicha (output) generada con base en el esquema de la base de datos.
3. Ejecución cruzada (Entorno Controlado): Para evitar las deficiencias de la simple coincidencia de texto, el módulo somete las sentencias a una validación funcional.
 - a. Primero, ejecuta automáticamente la sentencia SQL de referencia (Gold Standard) directamente en el motor de base de datos para obtener la tabla de registros correctos, denominada tabla GT (Ground Truth)
 - b. Acto seguido, ejecuta la sentencia SQL predicha por el intérprete sobre la misma base de datos para obtener la tabla de registros predichos, denominada tabla PT (Predicted Table)
4. Comparación de conjuntos de resultados (Result Sets): El algoritmo de evaluación procede a contrastar de manera determinista los datos recuperados en la tabla GT frente a los de la tabla PT. La validación de la Exactitud de Ejecución exige que ambas tablas sean idénticas; es decir, se

verifica que los registros recuperados coincidan exactamente en contenido, garantizando la equivalencia semántica de las consultas.

5. Clasificación y registro funcional: Con base en la comparación de los conjuntos de resultados, el sistema registra dos niveles de evaluación. Primero, a nivel de consulta completa, se calcula la exactitud de ejecución, asignando 1 cuando la tabla PT es funcionalmente idéntica a la tabla GT y 0 cuando existe una desviación en los registros recuperados.

Segundo, a nivel de conjunto de resultados, se calculan los componentes funcionales de la matriz agregada. Los verdaderos positivos (TP) corresponden a los elementos esperados que fueron recuperados correctamente; los falsos positivos (FP) corresponden a elementos no esperados incluidos por el SQL generado; y los falsos negativos (FN) corresponden a elementos esperados que fueron omitidos. El valor de verdaderos negativos (TN) no se utiliza en el cálculo, debido a que el universo de elementos no solicitados y no recuperados no es finitamente enumerable dentro del corpus evaluado.

6. Consolidación de métricas: El sistema repite este ciclo iterativamente hasta procesar la totalidad de la muestra. Finalmente, el módulo agrega los resultados y genera una matriz de datos estructurada y desglosada según los niveles de complejidad (Baja, Media, Alta). Estos registros binarios permiten calcular las métricas estadísticas derivadas de la matriz de confusión (Precisión, Recuperación (Recall) y F1-Score) necesarias para el diagnóstico algorítmico del intérprete semántico.

Anexo 8. Estándares de rendimiento y métricas NL2SQL

Para cuantificar la exactitud funcional, se utilizan métricas de recuperación de información aplicadas a la generación de código.

1. Fórmulas de Cálculo:

- **Precisión (Precision):** Mide la calidad de las consultas generadas.

$$P = \frac{TP}{TP + FP}$$

- **Exhaustividad (Recall):** Mide la capacidad de cubrir todas las consultas del corpus.

$$R = \frac{TP}{TP + FN}$$

- **Valor F (F1-Score):** Proporciona una media armónica que penaliza los valores extremos.

$$F1 = 2 \times \frac{P \times R}{P + R}$$

2. Umbrales de Éxito:

Tabla 5
Umbrales de Éxito

Métrica	Nivel de aceptación	Justificación técnica
F1-Score Global	> 85%	Meta establecida como el estado del arte internacional para diagnosticar el equilibrio de la traducción semántica (Karadjian & Blasco, 2024; Raut et al., 2025).
Precisión (Nivel Bajo)	> 90%	Mínimo de rendimiento funcional esperado para consultas simples de una sola tabla, acorde a las métricas del benchmark WikiSQL (Kanburoğlu & Tek, 2024; Pourreza, 2024).

Precisión (Nivel Alto)	> 60%	Umbral altamente competitivo y límite algorítmico actual para la resolución de sentencias con múltiples cláusulas JOIN y anidamientos (Abedini, 2026 ; Pourreza, 2024).
Exhaustividad (Recall)	> 80%	Mínimo exigido para asegurar una baja tasa de falsos negativos y certificar que el intérprete no omite la recuperación de datos válidos (Karadjian & Blasco, 2024).

Nota. Elaborado a partir de Karadjian y Blasco (2024), Raut et al. (2025), Kanburoğlu y Tek (2024), Pourreza (2024), y Nascimento et al. (2024).

Anexo 9. Matriz de definición operacional de la complejidad

Este anexo formaliza los criterios cuantitativos utilizados para estratificar el corpus de validación. Su objetivo es establecer reglas medibles que permitan agrupar las consultas para el análisis de varianza, garantizando que la clasificación se realice de forma algorítmica mediante el módulo de parsing SQL programado.

1. Criterios Ponderados de Complejidad

Se asigna un peso específico a cada elemento sintáctico presente en la sentencia SQL de referencia. Esta ponderación refleja el grado de dificultad que cada estructura impone al intérprete semántico, basándose en el riesgo de fallo observado empíricamente en la literatura especializada.

Tabla 6
Criterios Ponderados de Complejidad

Elemento Sintáctico		Puntaje	Justificación Técnica
SELECT	Simple / Filtro (WHERE)	1	Bajo riesgo: Requiere un mapeo léxico directo de tokens a columnas y un solo predicado. Es clasificado de manera uniforme como la categoría de complejidad más baja con el mayor porcentaje de exactitud algorítmica (Abedini, 2026 ; Kanburoğlu & Tek, 2024).
Operadores	Lógicos (AND/OR)	2	Riesgo estructural: Exige que el intérprete maneje la polisemia y ambigüedad de las conjunciones en lenguaje natural, requiriendo un nivel adicional de comprensión semántica para el filtrado múltiple (Mitsopoulou & Koutrika, 2025).

Agrupación (GROUP BY)	3	Abstracción semántica: Requiere que el sistema infiera una necesidad de resumen que no siempre es explícita en el texto del usuario. Frecuentemente genera errores críticos de ambigüedad por la selección incorrecta de columnas no agregadas (Pourreza, 2024).
Funciones de Agregación	3	Riesgo Semántico: Demanda la capacidad algorítmica de identificar el indicador de función correcto (MAX, MIN, AVG, SUM, COUNT), lo cual incrementa la "dureza" de la consulta y desafía la generalización del modelo (Zhang et al., 2023).
JOINS (Por cada tabla adicional)	4	Riesgo Relacional: Exige la resolución de relaciones de dominio cruzado y la alineación correcta de llaves primarias/foráneas. Es el principal factor documentado de caída de rendimiento al enfrentar al intérprete a bases de datos empresariales reales (Nascimento et al., 2024 ; Pourreza, 2024).
Anidamiento (Subconsultas)	5	Riesgo estructural complejo: Demanda el manejo de ejecución recursiva y el orden de subordinación lógica. Las consultas anidadas y operaciones de conjuntos son sistemáticamente catalogadas como el nivel máximo de dificultad en la

Nota. De “Criterios Ponderados de Complejidad”, elaborado en laboratorios a través de la revisión de fuentes.

2. Umbrales de nivel y estratificación del corpus

La puntuación total de cada consulta se obtiene mediante la sumatoria de los pesos de sus constituyentes sintácticos. Estos puntajes definen los tres estratos de la investigación, replicando la metodología de partición de dureza del benchmark estándar internacional Spider.

Tabla 7

Umbrales de Nivel

Nivel de complejidad	Rango de puntuación	Requisito operacional	Distribución de la muestra (n)
Nivel Baja	1: 1 a 3 puntos	Consultas de traducción léxica directa. No incluyen operadores lógicos, JOINS ni agregaciones.	32
Nivel Media	2: 4 a 7 puntos	Consultas que requieren inferencia semántica u operadores lógicos. Excluyen JOINS y anidamientos.	32
Nivel 3: Alta	8 o más puntos	Consultas de resolución relacional compleja. Es obligatorio incluir JOINS, agregaciones y/o anidamientos.	32
Total			96

Nota. De “Umbrales del Nivel”, elaborado en laboratorios a través de la revisión de fuentes.

3. Validación del Instrumento

La asignación de pesos se basa en la triangulación de resultados de benchmarks internacionales de dominio cruzado, particularmente Spider, donde la adición de estos elementos relacionales provoca las caídas más drásticas en la exactitud funcional de los modelos de lenguaje actuales ([Nascimento et al., 2024](#); [Zhang et al., 2023](#)). De esta forma, el instrumento posee validez de constructo al medir el incremento real del riesgo de error algorítmico, ya que, como demuestran [Mitsopoulou y Koutrika \(2025\)](#) y [Abedini \(2026\)](#), para diagnosticar transparentemente a un intérprete semántico es indispensable categorizar sus errores según los componentes estructurales a los que se enfrenta, en lugar de depender de una engañosa métrica de rendimiento global.

Anexo 10. Corpus de validación estratificado.

Este anexo contiene el listado maestro de las 96 consultas utilizadas como instrumento de recolección de datos. El corpus ha sido diseñado siguiendo una distribución equitativa de 32 consultas por nivel de complejidad, permitiendo la aplicación posterior de pruebas de comparación de medias.

1. Resumen de Distribución del Corpus

Tabla 8

Resumen del corpus

Nivel de Complejidad	Cantidad de Consultas	Rango de Puntuación
Nivel 1: Baja	32	1 - 3 puntos
Nivel 2: Media	32	4 - 7 puntos
Nivel 3: Alta	32	8+ puntos
Total	96	

Nota. De “Resumen del corpus”, elaborado en laboratorios a través de la revisión de fuentes.

2. Tabla Maestra de Consultas (Muestra de Ejecución)

Tabla 9

Corpus Completo

ID	Consulta NL	SQL referencial	Nivel de complejidad	Puntaje
C01	Muestra el nombre, país y edad de todos los cantantes ordenados por edad de mayor a menor.	SELECT name , country , age FROM singer ORDER BY age DESC	Baja	3

C02	Muestra el nombre y el año de lanzamiento de la canción del cantante más joven.	SELECT song_name , song_release_yea r FROM singer ORDER BY age LIMIT 1	Baja	3
C03	Encuentra el peso del perro más joven.	SELECT weight FROM pets ORDER BY pet_age LIMIT 1	Baja	3
C04	Encuentra el tipo y peso de la mascota más joven.	SELECT pettype , weight FROM pets ORDER BY pet_age LIMIT 1	Baja	3
C05	Muestra todos los fabricantes y modelos.	SELECT Maker , Model FROM MODEL_LIST;	Baja	1
C06	Muestra la potencia del auto con la mayor aceleración	SELECT T1.horsepower FROM CARS_DATA AS T1 ORDER BY T1.accelerate DESC LIMIT 1;	Baja	3
C07	Ordena los nombres de los empleados por edad de forma ascendente.	SELECT name FROM employee ORDER BY age	Baja	3

C08	Encuentra el nombre del gerente y el distrito de la tienda con mayor cantidad de productos.	SELECT manager_name , district FROM shop ORDER BY number_products DESC LIMIT 1	Baja	3
C09	Lista los IDs, nombres y descripciones de todos los documentos.	SELECT document_id , document_name , document_descrip tion FROM Documents	Baja	1
C10	Muestra los IDs de plantilla, números de versión y códigos de tipo de plantilla.	SELECT template_id , version_number , template_type_co de FROM Templates	Baja	1
C11	Lista los nombres de los profesores en orden ascendente de edad.	SELECT Name FROM teacher ORDER BY Age ASC	Baja	3
C12	Muestra la edad y ciudad natal de los profesores.	SELECT Age , Hometown FROM teacher	Baja	1

C13	Encuentra el ID y nombre del museo que tiene la mayor cantidad de personal.	SELECT museum_id , name FROM museum ORDER BY num_of_staff DESC LIMIT 1	Baja	3
C14	Encuentra el nombre y código de país del jugador más antiguo.	SELECT first_name , country_code FROM players ORDER BY birth_date LIMIT 1	Baja	3
C15	Lista el nombre y apellido de todos los jugadores ordenados por fecha de nacimiento.	SELECT first_name , last_name FROM players ORDER BY birth_date	Baja	3
C16	Lista el nombre y tonelaje de los barcos ordenados por nombre en orden descendente.	SELECT name , tonnage FROM ship ORDER BY name DESC	Baja	3
C17	Lista el nombre, fecha y resultado de cada batalla.	SELECT name , date FROM battle	Baja	1

C18	Muestra todas las direcciones, incluyendo línea 1 y línea 2.	SELECT line_1 , line_2 FROM addresses	Baja	1
C19	Muestra los nombres y descripciones de todas las secciones.	SELECT section_name , section_descriptio n FROM Sections	Baja	1
C20	Lista el título de todos los dibujos animados en orden alfabético.	SELECT Title FROM Cartoon ORDER BY title	Baja	3
C21	Lista todos los títulos de dibujos animados y sus directores ordenados por fecha de emisión.	SELECT title , Directed_by FROM Cartoon ORDER BY Original_air_date	Baja	3
C22	Lista las ganancias de los jugadores de póker en orden descendente.	SELECT Earnings FROM poker_player ORDER BY Earnings DESC	Baja	3

C23	Lista las mesas finales alcanzadas y los mejores resultados de los jugadores de póker.	SELECT Final_Table_Made , Best_Finish FROM poker_player	Baja	1
C24	Lista los números y nombres de los concursantes, ordenados por nombre de concursante descendente.	SELECT contestant_numbr er , contestant_name FROM contestants ORDER BY contestant_name DESC	Baja	3
C25	Lista los IDs de voto, números telefónicos y estados de todos los votos.	SELECT vote_id , phone_number , state FROM votes	Baja	1
C26	Muestra el nombre, año de independencia y área superficial del país con menor población.	SELECT Name , SurfaceArea , IndepYear FROM country ORDER BY Population LIMIT 1	Baja	3

C27	Muestra la población, nombre y jefe de Estado del país con mayor superficie.	la	SELECT Name , population , HeadOfState FROM country ORDER BY SurfaceArea DESC LIMIT 1	Baja	3
C28	Lista los nombres de los directores de orquesta en orden ascendente de edad.	los	SELECT Name FROM conductor ORDER BY Age ASC	Baja	3
C29	Muestra las compañías discográficas de las orquestas en orden descendente por año de fundación.	las	SELECT Record_Company FROM orchestra ORDER BY Year_of_Founded DESC	Baja	3
C30	Muestra los nombres y grados de cada estudiante de secundaria.	los	SELECT name , grade FROM Highschooler	Baja	1
C31	Muestra la fecha de	la	SELECT date_arrived ,	Baja	1

	llegada y salida de todos los perros.	date_departed FROM Dogs			
C32	Lista los nombres de los cantantes en orden ascendente de patrimonio neto.	SELECT Name FROM singer ORDER BY Net_Worth_Million s ASC	Baja		3
C33	¿Cuántos cantantes hay?	SELECT count(*) FROM singer	Media		4
C34	¿Cuál es la edad promedio, mínima y máxima de todos los cantantes de Francia?	SELECT avg(age) , min(age) , max(age) FROM singer WHERE country = 'France'	Media		7
C35	Encuentra la cantidad de mascotas cuyo peso es mayor que 10.	SELECT count(*) FROM pets WHERE weight > 10	Media		7
C36	Encuentra la cantidad de tipos distintos de mascotas.	SELECT count(DISTINCT pettype) FROM pets	Media		4

C37	¿Cuántos continentes hay?	SELECT count(*) FROM CONTINENTS;	Media	4
C38	¿Cuántos países están registrados?	SELECT count(*) FROM COUNTRIES;	Media	4
C39	¿A qué país pertenece la aerolínea "JetBlue Airways"?	SELECT Country FROM AIRLINES WHERE Airline = "JetBlue Airways"	Media	4
C40	¿Cuál es la abreviatura de la aerolínea "JetBlue Airways"?	SELECT Abbreviation FROM AIRLINES WHERE Airline = "JetBlue Airways"	Media	4
C41	¿Cuántos empleados hay?	SELECT count(*) FROM employee	Media	4
C42	Encuentra el número mínimo y máximo de productos de todas las tiendas.	SELECT min(Number_products), max(Number_products) FROM shop	Media	5
C43	¿Cuántos documentos hay?	SELECT count(*) FROM Documents	Media	4

C44	¿Cuál es el nombre del documento y el ID de plantilla del documento cuya descripción contiene la letra "w"?	SELECT document_name , template_id FROM Documents WHERE Document_Description LIKE "%w%"	Media	4
C45	¿Cuántos profesores hay?	SELECT count(*) FROM teacher	Media	4
C46	Lista los nombres de los profesores cuya ciudad natal no es "Little Lever Urban District".	select name from teacher where hometown != "little lever urban district"	Media	4
C47	¿Cuántos visitantes menores de 30 años hay?	SELECT count(*) FROM visitor WHERE age < 30	Media	7
C48	Encuentra los nombres de los visitantes cuyo nivel de membresía es mayor que 4 y ordena los	SELECT name FROM visitor WHERE Level_of_membership > 4 ORDER BY	Media	6

	resultados de mayor a menor nivel.	Level_of_member ship DESC			
C49	Encuentra el número total de jugadores.	SELECT count(*) FROM players	Media	4	
C50	Encuentra el número total de partidos.	SELECT count(*) FROM matches	Media	4	
C51	¿Cuántos barcos terminaron como "Captured"?	SELECT count(*) FROM ship WHERE disposition_of_ship = 'Captured'	Media	7	
C52	¿Cuál es el número máximo y mínimo de muertes causadas cada vez?	SELECT max(killed), min(killed) FROM death	Media	5	
C53	¿Cuántos cursos hay en total?	SELECT count(*) FROM Courses	Media	4	
C54	¿Cómo se describe el curso de matemáticas?	SELECT course_description FROM Courses WHERE	Media	4	

		course_name = 'math'			
C55	Lista todos los dibujos animados dirigidos por "Ben Jones".	SELECT Title FROM Cartoon WHERE Directed_by = "Ben Jones";	Media	4	
C56	¿Cuántos dibujos animados fueron escritos por "Joseph Kuhr"?	SELECT count(*) FROM Cartoon WHERE Written_by = "Joseph Kuhr";	Media	7	
C57	¿Cuántos jugadores de póker hay?	SELECT count(*) FROM poker_player	Media	4	
C58	¿Cuántos estados hay?	SELECT count(*) FROM area_code_state	Media	4	
C59	¿Cuáles son los nombres de todos los países que se independizaron después de 1950?	SELECT Name FROM country WHERE IndepYear > 1950	Media	4	
C60	¿Cuántos directores de orquesta hay?	SELECT count(*) FROM conductor	Media	4	

C61	¿Cuántos estudiantes de secundaria hay?	SELECT count(*) FROM Highschooler	Media	4
C62	Lista los correos electrónicos de los profesionales que viven en el estado de Hawaii o Wisconsin.	SELECT email_address FROM Professionals WHERE state = 'Hawaii' OR state = 'Wisconsin'	Media	6
C63	Lista los nombres de los cantantes cuya ciudadanía no es "France".	SELECT Name FROM singer WHERE Citizenship != "France"	Media	4
C64	¿Cuántas características disponibles hay en total?	SELECT count(*) FROM Other_Available_ Features	Media	4
C65	Muestra todos los países y el número de cantantes en cada país.	SELECT country , count(*) FROM singer GROUP BY country	Alta	9
C66	Lista todos los nombres de canciones de	SELECT song_name FROM singer	Alta	9

	cantantes con edad superior al promedio.	WHERE age > (SELECT avg(age) FROM singer)		
C67	Encuentra el peso máximo para cada tipo de mascota, mostrando el peso máximo y el tipo de mascota.	SELECT max(weight) , petType FROM pets GROUP BY petType	Alta	9
C68	Encuentra el número de mascotas pertenecientes a estudiantes mayores de 20 años.	SELECT count(*) FROM student AS T1 JOIN has_pet AS T2 ON T1.stuid = T2.stuid WHERE T1.age > 20	Alta	9
C69	¿Cuántos países tiene cada continente? Lista el ID del continente, el nombre del continente y el número de países.	SELECT T1.Contld , T1.Continent , count(*) FROM CONTINENTS AS T1 JOIN COUNTRIES AS T2 ON T1.Contld = T2.Continent GROUP BY T1.Contld;	Alta	10

C70	¿Cuántos modelos produce cada fabricante de autos? Lista el nombre completo del fabricante, su ID y la cantidad.	SELECT T1.FullName , T1.Id , count(*) FROM CAR_MAKERS AS T1 JOIN MODEL_LIST AS T2 ON T1.Id = T2.Maker GROUP BY T1.Id;	Alta	10
C71	¿Cuántos vuelos salen de la ciudad de Aberdeen?	SELECT count(*) FROM FLIGHTS AS T1 JOIN AIRPORTS AS T2 ON T1.SourceAirport = T2.AirportCode WHERE T2.City = "Aberdeen"	Alta	9
C72	¿Cuántos vuelos llegan a la ciudad de Aberdeen?	SELECT count(*) FROM FLIGHTS AS T1 JOIN AIRPORTS AS T2 ON T1.DestAirport = T2.AirportCode WHERE T2.City = "Aberdeen"	Alta	9
C73	¿Cuál es el número de	SELECT count(*) , city FROM	Alta	9

	empleados por cada ciudad?	employee GROUP BY city		
C74	¿De qué ciudades proviene más de un empleado menor de 30 años?	SELECT city FROM employee WHERE age < 30 GROUP BY city HAVING count(*) > 1	Alta	10
C75	¿Cuántos documentos usan la plantilla con código de tipo "PPT"?	SELECT count(*) FROM Documents AS T1 JOIN Templates AS T2 ON T1.Template_ID = T2.Template_ID WHERE T2.Template_Type_Code = 'PPT'	Alta	9
C76	Muestra todos los IDs de plantilla y el número de documentos que usa cada plantilla.	SELECT template_id , count(*) FROM Documents GROUP BY template_id	Alta	9
C77	Muestra las distintas ciudades	SELECT Hometown , COUNT(*) FROM	Alta	9

	natales de los profesores y el número de profesores de cada una.	teacher GROUP BY Hometown		
C78	Lista la ciudad natal más común de los profesores.	SELECT Hometown FROM teacher GROUP BY Hometown ORDER BY COUNT(*) DESC LIMIT 1	Alta	9
C79	Encuentra los nombres de los museos que tienen más personal que el mínimo de personal de todos los museos abiertos después de 2010.	SELECT name FROM museum WHERE num_of_staff > (SELECT min(num_of_staff) FROM museum WHERE open_year > 2010)	Alta	9
C80	Encuentra el ID, nombre y edad de los visitantes que visitaron algunos	SELECT t1.id , t1.name , t1.age FROM visitor AS t1 JOIN visit AS t2 ON t1.id = t2.visitor_id GROUP BY t1.id	Alta	10

	museos más de una vez.	HAVING count(*) > 1		
C81	Encuentra el nombre del torneo que tiene más de 10 partidos.	SELECT tourney_name FROM matches GROUP BY tourney_name HAVING count(*) > 10	Alta	10
C82	Lista los nombres de todos los ganadores que jugaron tanto en 2013 como en 2016.	SELECT winner_name FROM matches WHERE YEAR = 2013 INTERSECT SELECT winner_name FROM matches WHERE YEAR = 2016	Alta	9
C83	¿Cuáles son las muertes y lesiones causadas por el barco con tonelaje "t"?	SELECT T1.killed , T1.injured FROM death AS T1 JOIN ship AS t2 ON T1.caused_by_ship_id = T2.id WHERE T2.tonnage = 't'	Alta	9
C84	¿Cuáles son los diferentes	SELECT DISTINCT T1.id ,	Alta	9

	IDs y nombres de las batallas que perdieron algún barco de tipo "Brig"?	T1.name FROM battle AS T1 JOIN ship AS T2 ON T1.id = T2.lost_in_battle WHERE T2.ship_type = 'Brig'		
C85	¿Qué departamento ofrece el mayor número de carreras? Lista el nombre e ID del departamento.	SELECT T2.department_name, T1.department_id FROM Degree_Programs AS T1 JOIN Departments AS T2 ON T1.department_id = T2.department_id GROUP BY T1.department_id ORDER BY count(*) DESC LIMIT 1	Alta	10
C86	¿Cuántas carreras ofrece el departamento de ingeniería?	SELECT count(*) FROM Departments AS T1 JOIN Degree_Programs AS T2 ON	Alta	9

		T1.department_id = T2.department_id WHERE T1.department_name = 'engineer'		
C87	¿Qué país tiene la mayor cantidad de canales de TV? Lista el país y el número de canales de TV.	SELECT Country , count(*) FROM TV_Channel GROUP BY Country ORDER BY count(*) DESC LIMIT 1;	Alta	9
C88	Lista el idioma usado por la menor cantidad de canales de TV. Muestra el idioma y el número de canales.	SELECT LANGUAGE , count(*) FROM TV_Channel GROUP BY LANGUAGE ORDER BY count(*) ASC LIMIT 1;	Alta	9
C89	¿Cuáles son los nombres de los jugadores de póker?	SELECT T1.Name FROM people AS T1 JOIN poker_player AS T2 ON T1.People_ID = T2.People_ID	Alta	9

C90	¿Cuáles son los números y nombres de los concursantes que tuvieron al menos dos votos?	SELECT T1.contestant_number , T1.contestant_name FROM contestants AS T1 JOIN votes AS T2 ON T1.contestant_number = T2.contestant_number GROUP BY T1.contestant_number HAVING count(*) >= 2	Alta	10
C91	¿En qué región se encuentra la ciudad de Kabul?	SELECT Region FROM country AS T1 JOIN city AS T2 ON T1.Code = T2.CountryCode WHERE T2.Name = "Kabul"	Alta	9
C92	Muestra los nombres de los directores y las orquestas que han dirigido.	SELECT T1.Name , T2.Orchestra FROM conductor AS T1 JOIN orchestra AS T2 ON T1.Conductor_ID	Alta	9

			=		
			T2.Conductor_ID		
C93	Muestra el número de estudiantes de secundaria por cada grado.	SELECT grade , count(*) FROM Highschooler GROUP BY grade	Alta	9	
C94	¿Qué estados tienen tanto propietarios como profesionales viviendo allí?	SELECT state FROM Owners INTERSECT SELECT state FROM Professionals	Alta	9	
C95	Muestra las distintas ciudadanías de los cantantes y el número de cantantes por cada ciudadanía.	SELECT Citizenship , COUNT(*) FROM singer GROUP BY Citizenship	Alta	9	
C96	¿Cuál es el nombre del tipo de característica para la característica AirCon?	SELECT T2.feature_type_name FROM Other_Available_Features AS T1 JOIN Ref_Feature_Types AS T2 ON T1.feature_type_c	Alta	9	

```
ode          =  
T2.feature_type_c  
ode      WHERE  
T1.feature_name  
= "AirCon"
```

Nota. De “Corpus Completo”, elaborado en laboratorio.

Anexo 11. Resultados del objetivo específico 3: precisión

Este anexo presenta los resultados de precisión obtenidos mediante la ejecución automatizada del corpus de validación. Se incluyen la precisión global y la precisión agrupada por nivel de complejidad.

Tabla 9

Precisión global del intérprete semántico

Objetivo	Métrica	Consultas	TP	FP	Precisión Global
OE3	Precisión Global	96	278	72	79.43%

Nota. De “Precisión global del intérprete semántico”, elaborado en laboratorio.

Tabla 10

Precisión por nivel de complejidad

Nivel	Consultas	SQL válidos	TP	FP	Precisión Promedio	Precisión global por nivel
Baja	32	23	155	33	59.38%	82.45%
Media	32	30	41	8	81.25%	83.67%
Alta	32	27	82	31	60.88%	72.57%

Nota. De “Precisión por nivel de complejidad”, elaborado en laboratorio.

OE3 - Precisión global: 79.43 %

	objetivo	metrica	consultas_evaluadas	tp	fp	precision_global	precision_global_porcentaje
0	OE3	Precision global	96	278	72	0.794286	79.428571

	nivel	consultas	sql_validos	tp	fp	precision_promedio	precision_global_por_nivel
0	Alta	32	27	82	31	0.608807	0.725664
1	Baja	32	23	155	33	0.593750	0.824468
2	Media	32	30	41	8	0.812500	0.836735

Figura 2. Captura del bloque OE3 ejecutado en Google Colab.

Anexo 12. Resultados del objetivo específico 4: recall

Este anexo presenta los resultados de recall obtenidos mediante la comparación entre los conjuntos de resultados generados y los conjuntos esperados del SQL referencial.

Tabla 11*Recall global del intérprete semántico*

Objetivo	Métrica	Consultas	TP	FN	Recall Global
OE4	Recall Global	96	278	282	49.64%

Nota. De “Recall global del intérprete semántico”, elaborado en laboratorio.

Tabla 12*Recall por nivel de complejidad*

Nivel	Consultas	SQL Válido	TP	FN	Recall Promedio	Recall global por nivel
Baja	32	23	155	111	55.32%	58.27%
Media	32	30	41	119	79.91%	25.63%
Alta	32	27	82	52	60.17%	61.19%

Nota. De “Recall por nivel de complejidad”, elaborado en laboratorio.

... OE4 - Recall global: 49.64 %

	objetivo	metrica	consultas_evaluadas	tp	fn	recall_global	recall_global_porcentaje	
0	OE4	Recall global	96	278	282	0.496429	49.642857	

	nivel	consultas	sql_validos	tp	fn	recall_promedio	recall_global_por_nivel	
0	Alta	32	27	82	52	0.601664	0.611940	
1	Baja	32	23	155	111	0.553166	0.582707	
2	Media	32	30	41	119	0.799107	0.256250	

Figura 3. Captura del bloque OE4 ejecutado en Google Colab.

Anexo 13. Resultados del objetivo específico 5: F1-Score por complejidad

Este anexo presenta el F1-Score por nivel de complejidad, junto con métricas complementarias de precisión promedio, recall promedio y exactitud de ejecución.

Tabla 13*F1-Score y métricas complementarias por nivel de complejidad*

Nivel	Consultas	SQL válidos	F1 promedio	F1 mediana	Desv. F1	Precisión prom.	Recall prom.	Exactitud de ejecución
Baja	32	23	56.55%	91.67%	0.4866	59.38%	55.32%	50.00%
Media	32	30	80.40%	100.00%	0.3953	81.25%	79.91%	78.13%
Alta	32	27	60.46%	100.00%	0.4823	60.88%	60.17%	56.25%

Nota. De “F1-Score y métricas complementarias por nivel de complejidad”, elaborado en laboratorio.

	nivel	consultas	sql_validos	f1_promedio	f1_mediana	f1_desviacion	precision_promedio	recall_promedio	execution_accuracy_promedio	f1_porcentaje	execution_accuracy_porcentaje
0	Baja	32	23	0.565476	0.916667	0.486599	0.593750	0.553166	0.50000	56.547619	50.000
1	Media	32	30	0.803977	1.000000	0.395327	0.812500	0.799107	0.78125	80.397727	78.125
2	Alta	32	27	0.604640	1.000000	0.482281	0.608807	0.601664	0.56250	60.464015	56.250

Figura 4. Captura del bloque OE5 ejecutado en Google Colab.

Anexo 14. Docimasia estadística del objetivo específico 5

Este anexo presenta las pruebas estadísticas aplicadas para contrastar la existencia de diferencias significativas en el F1-Score según el nivel de complejidad.

Tabla 14

Prueba de normalidad Shapiro-Wilk por nivel de complejidad

Nivel	Estadístico	p-valor	Normalidad
Baja	0.6721	0.000000341	No cumple
Media	0.5061	0.000000003	No cumple
Alta	0.6560	0.000000204	No cumple

Nota. De “Prueba de normalidad Shapiro-Wilk por nivel de complejidad”, elaborado en laboratorio.

Tabla 15

Pruebas inferenciales aplicadas al F1-Score

Prueba	Estadístico	p-valor	Interpretación	
Levene	2.8140	0.0651	Varianzas homogéneas	
ANOVA	2.5100	0.0868	Sin	diferencia significativa
Kruskal -Wallis	5.4831	0.0645	Sin	diferencia significativa

Nota. De “Pruebas inferenciales aplicadas al F1-Score”, elaborado en laboratorio

Shapiro-Wilk:					
	nivel	shapiro_stat	shapiro_p_value	normalidad	
0	Baja	0.672083	3.410990e-07	No cumple	
1	Media	0.506110	3.003043e-09	No cumple	
2	Alta	0.656021	2.035213e-07	No cumple	
Pruebas inferenciales:					
	prueba	estadistico	p_value	interpretacion	
0	Levene	2.814044	0.065077	Varianzas homogéneas	
1	ANOVA	2.510049	0.086757	Sin diferencia significativa o no calculable	
2	Kruskal-Wallis	5.483106	0.064470	Sin diferencia significativa o no calculable	

Figura 5. Captura del bloque OE5 ejecutado en Google Colab.

Anexo 15. Resumen global de ejecución automatizada

Este anexo presenta el resumen global de la ejecución automatizada sobre el corpus de 96 consultas utilizado para los objetivos específicos 3, 4 y 5.

Tabla 16***Resumen global de la evaluación automatizada***

Indicador	Valor
Consultas evaluadas	96
Verdaderos positivos (TP)	278
Falsos positivos (FP)	72
Falsos negativos (FN)	282
Precisión global	79.43%
Recall global	49.64%
F1-Score global	61.10%
Exactitud de ejecución global	61.46%
SQL válidos	80
SQL inválidos	16
Consultas reparadas	19

Nota. De “Resumen global de la evaluación automatizada”, elaborado en laboratorio.

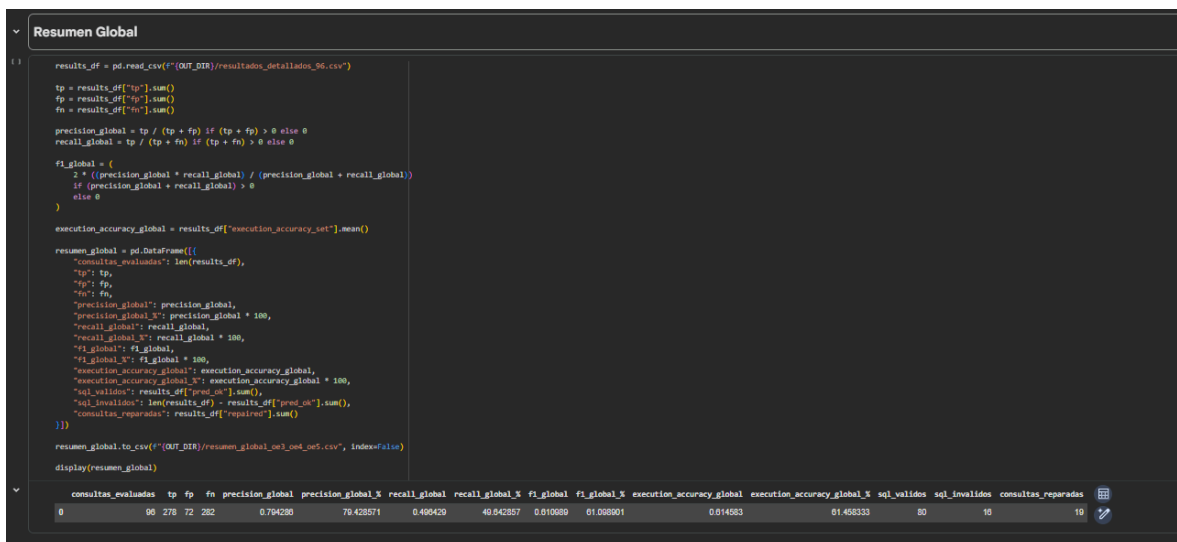


Figura 6. Captura del bloque final de resumen global ejecutado en Google Colab.

Anexo 16. Análisis complementario mediante PCA y clustering

Este anexo presenta el análisis complementario aplicado sobre las métricas obtenidas por consulta durante la evaluación automatizada del intérprete semántico. Aunque el agrupamiento K-Means identificó cinco clusters, la interpretación se organiza en función de los tres niveles de complejidad definidos en la investigación: Baja, Media y Alta. De esta manera, el análisis permite observar si los patrones de desempeño y fallo se explican por la complejidad sintáctica asignada o por otros comportamientos funcionales del SQL generado.

Tabla 17

Varianza explicada por los componentes principales

Componente	Varianza explicada	Varianza explicada (%)
PCA1	0.4408	44.08%
PCA2	0.1578	15.78%

Nota. De “Varianza explicada por los componentes principales”, elaborado en laboratorio.

Tabla 18

Evaluación de número de clusters mediante silhouette

k	Silhouette score
2	0.4733
3	0.4776
4	0.4934
5	0.5352
6	0.4577

Nota. De “Evaluación de número de clusters mediante silhouette”, elaborado en laboratorio.

Tabla 19*Resumen de clusters de desempeño y error*

Cluster	Consultas	SQL válidos	SQL inválidos	TP	FP	FN	Precisión promedio	Recall promedio	F1 promedio	Exactitud de ejecución	Interpretación
0	59	58	1	250	0	4	100%	99.03%	99.44%	96.61%	Alto desempeño
1	20	20	0	26	72	104	17.41%	10.49%	12.52%	0%	Fallo funcional
2	2	2	0	2	0	0	100%	100%	100%	100%	Alto desempeño atípico
3	14	0	14	0	0	64	0%	0%	0%	0%	SQL inválido
4	1	0	1	0	0	110	0%	0%	0%	0%	Caso atípico extremo

Nota. De “Resumen de clusters de desempeño y error”, elaborado en laboratorio.

Tabla 20*Distribución de clusters por nivel de complejidad*

Cluster	Alta	Baja	Media	Total
0	18	18	23	59
1	9	6	5	20
2	0	0	2	2
3	5	8	1	14
4	0	0	1	1
Total	32	32	32	96

Nota. De “Distribución de clusters por nivel de complejidad”, elaborado en laboratorio.

La distribución evidencia que los clusters de desempeño y fallo no se concentran exclusivamente en el nivel alto. El Cluster 0, asociado al mayor rendimiento, contiene consultas de los tres niveles: 18 de nivel alto, 18 de nivel bajo y 23 de nivel medio. Asimismo, el Cluster 1, asociado a fallos funcionales, también contiene consultas de los tres niveles: 9 de nivel alto, 6 de nivel bajo y 5 de nivel medio. Esto confirma que los errores del intérprete no dependen únicamente de la complejidad asignada, sino también de la vinculación entre la consulta en lenguaje natural y el esquema relacional.




Figura 7. Distribución PCA de consultas por nivel de complejidad.




Figura 8. Agrupamiento de consultas mediante PCA y K-Means.




Figura 9. F1-Score promedio por cluster.




Figura 10. Distribución de niveles de complejidad por cluster.

Anexo 17. Consultas con mayor patrón de fallo

Este anexo presenta una muestra de las consultas con menor F1-Score identificadas mediante el análisis de clustering. Su finalidad es evidenciar casos concretos donde el SQL generado presentó errores funcionales, omisión de registros esperados o fallos de ejecución.

Tabla 21*Consultas con mayor patrón de fallo*

ID	Base de datos	Nivel	Cluster	Consulta NL	Error	TP	FP	FN	F1-Score
C59	world_1	Media	4	¿Cuáles son los nombres de todos los países que se independizaron después de 1950?	no such column: T2.Name	0	0	110	0%
C10	cre_Doc_Template_Mgt	Baja	3	Muestra los IDs de plantilla, números de versión y códigos de tipo de plantilla.	no such column: T2.Template_ID	0	0	20	0%
C21	tvshow	Baja	3	Lista todos los títulos de dibujos animados y sus directores ordenados por fecha de emisión.	no such column: T2.Director_by	0	0	12	0%

C29	orchestra	Baja	3	Muestra las compañías discográficas de las orquestas en orden descendente por año de fundación.	no such column: T2.Record _Company	0	0	11	0%
C23	poker_player	Baja	3	Lista las mesas finales alcanzadas y los mejores resultados de los jugadores de póker.	no such column: T2.Best_Finish	0	0	5	0%
C66	concert_singer	Alta	3	Lista todos los nombres de canciones de cantantes con edad superior al promedio.	no such column: T2.Song_Name	0	0	3	0%
C94	dog_kennels	Alta	3	¿Qué estados tienen tanto propietarios como	no such column: T2.owner_id	0	0	3	0%

				profesionales viviendo allí?							
C62	dog_kennels	Media	3	Lista los correos electrónicos de los profesionales que viven en el estado de Hawaii o Wisconsin.	no such table: States		0	0	2	0%	
C67	pets_1	Alta	3	Encuentra el peso máximo para cada tipo de mascota, mostrando el peso máximo y el tipo de mascota.	no such column: T2.pet_type		0	0	2	0%	
C02	concert_singer	Baja	3	Muestra el nombre y el año de lanzamiento de la canción del cantante más joven.	no such table: song		0	0	1	0%	

Nota. De “Consultas con mayor patrón de fallo”, elaborado en laboratorio.